

电 子 科 技 大 学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

博士学位论文

DOCTORAL DISSERTATION



论文题目 _____

学科专业 _____

学 号 _____

作者姓名 _____

指导教师 _____

学 院 _____

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

博士学位论文
DOCTORAL DISSERTATION



论文题目 城市计算中的高效算法研究

学科专业 计算机科学与技术

学 号 202211081351

作者姓名 李 科

指导教师 商烁 教 授

学 院 计算机科学与工程学院 (网络空间安全学院)

分类号 _____ 密级 _____

UDC^{注1} _____

学 位 论 文

(题名和副题名)

(作者姓名)

指导教师 _____

(姓名、职称、单位名称)

申请学位级别 _____ 学科专业 _____

提交论文日期 _____ 论文答辩日期 _____

学位授予单位和日期 _____

答辩委员会主席 _____

评阅人 _____

注 1：注明《国际十进分类法 UDC》的类号。

分类号 _____ 密级 _____ 公开 _____

UDC^{注1} _____

学 位 论 文

城市计算中的高效算法研究

(题名和副题名)

李科

(作者姓名)

指导教师 _____ 商烁 _____ 教授 _____

(姓名、职称、单位名称)

申请学位级别 _____ 学科专业 _____

提交论文日期 _____ 论文答辩日期 _____

学位授予单位和日期 _____

答辩委员会主席 _____

评阅人 _____

注 1: 注明《国际十进分类法 UDC》的类号。

A Doctoral Dissertation Submitted to
University of Electronic Science and Technology of China

Discipline _____

Student ID _____

Author _____

Supervisor _____

School _____

How to Take Revenge When My Father's Murderer is Suspected to Be a Famous Hero

A Doctoral Dissertation Submitted to
University of Electronic Science and Technology of China

Discipline **Jade Lady Soul Sword Technique Jade Lady Soul**

Sword Technique

Student ID **1182000**

Author **Yang Guo**

Supervisor **Grandmaster Dragondaughter Little**

Grandmaster Northern Beggar

School **Ancient Tomb Sect Ancient Tomb Sect Ancient**

Tomb Sect Ancient Tomb Sect

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知,除了文中特别加以标注和致谢的地方外,论文中不包含其他人已经发表或撰写过的研究成果,也不包含为获得电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名: _____ 日期: _____ 年 _____ 月 _____ 日

论文使用授权

本学位论文作者完全了解电子科技大学有关保留、使用学位论文的规定,同意学校有权保留并向国家有关部门或机构送交论文的复印件和数字文档,允许论文被查阅。本人授权电子科技大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载,可以采用影印、扫描等复制手段保存、汇编学位论文。

(涉密的学位论文须按照国家及学校相关规定管理,在解密后适用于本授权。)

作者签名: _____ 导师签名: _____

日期: _____ 年 _____ 月 _____ 日

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知,除了文中特别加以标注和致谢的地方外,论文中不包含其他人已经发表或撰写过的研究成果,也不包含为获得电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名: 作者签名

日期: 2024 年 08 月 31 日

论文使用授权

本学位论文作者完全了解电子科技大学有关保留、使用学位论文的规定,同意学校有权保留并向国家有关部门或机构送交论文的复印件和数字文档,允许论文被查阅。本人授权电子科技大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载,可以采用影印、扫描等复制手段保存、汇编学位论文。

(涉密的学位论文须按照国家及学校相关规定管理,在解密后适用于本授权。)

作者签名: 作者签名

导师签名: 导师签名

日期: 2024 年 08 月 31 日

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知,除了文中特别加以标注和致谢的地方外,论文中不包含其他人已经发表或撰写过的研究成果,也不包含为获得电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名: 作者签名

日期: 2024 年 08 月 31 日

论文使用授权

本学位论文作者完全了解电子科技大学有关保留、使用学位论文的规定,同意学校有权保留并向国家有关部门或机构送交论文的复印件和数字文档,允许论文被查阅。本人授权电子科技大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载,可以采用影印、扫描等复制手段保存、汇编学位论文。

(涉密的学位论文须按照国家及学校相关规定管理,在解密后适用于本授权。)

作者签名: 作者签名

导师签名: 导师签名

日期: 2024 年 08 月 31 日

摘要

随着 GPS 技术的快速发展和移动智能设备的普及, 移动终端用户得以实时地生成并发送大量的时空数据。时空数据中既包括移动物体的地理位置, 也包括实时更新的城市路网等空间数据。海量且内容丰富的时空数据催生了许多基于地理位置的服务。基于地理位置的服务利用移动终端等用户提供的位置信息, 在特定计算平台支持下为用户提供对应的定制服务, 如个性化的路线规划, 兴趣点搜索和推荐等。作为位置服务中的重要技术, 基于地理位置点的关键字查询以及基于时空-文本大数据的特定的时空-文本对象搜索近年来受到学术界和工业界的广泛关注。然而, 针对用户日渐复杂且频繁的多样化查询, 现有工作存在未考虑时空数据的文本属性、未引入用户隐私保护机制、无法支持数据流查询等缺陷。因此, 它们可能无法保证查询结果的实时性返回。此外, 随着智能手机的普及, 新的应用场景不断出现, 人们获取时空-文本数据的需求越来越大, 查询需求也日益多样化。本文针对用户复杂的个性化查询需求, 对基于时空-文本大数据的关键字查询问题进行了深入研究, 提出并解决了以下三个问题并取得了创新性成果。(1) 提出并解决了与给定路线最相似的空间-文本位置点 (PPRSTL) 查询的问题。给定一组带有文本描述的位置点 O , 一条用户指定的查询路线 q , 以及一组描述用户对位置点偏好的关键字集合, PPRSTL 问题旨在查找与给定路线 q 具有最大空间-文本相似度的位置点。同时, 该查询需要保证用户隐私的安全性。PPRSTL 查询在现实生活中具有十分广泛的应用, 尤其是在许多移动应用中, 比如位置点推荐、兴趣点挖掘等。然而, 该问题面临三个主要的挑战: 其一, 如何对空间相似度和文本相似度进行有效的建模; 其二, 如何在空间域和文本域中将搜索空间限制在一个相对较小的范围内; 其三, 如何在返回查询结果时保护用户的个性化隐私。为解决上述挑战, 本文定义了一个空间-文本相似度函数来衡量位置点与路线在空间域和文本域的相似度, 以及一个两阶段的搜索机制来保护用户隐私。基于过滤-求精 (filter-and-refinement) 的思想, 本文提出了两种高效的网络扩张搜索算法。为了进一步提高查询效率, 本文定义了两组相似度上界和下界用于减小搜索空间。利用扩张中心选择方法计算了最优的扩张中心数目及其位置, 进一步提高了查询效率。最后, 本文在真实和合成空间数据集上进行了广泛的实验。实验结果表明, 针对大规模位置点设计的网络扩展搜索算法不仅能够高效返回查询结果, 而且随着数据规模增大, 查询效率仍具有较高的可扩展性。(2) 提出并解决了大规模空间关键字的连续查询问题。本文设计了一个连续空间关键字查询匹配 (CSKQM) 框架用于高效地处理该问题。该

框架的输入为空间-文本数据流，使用了分层的动态网格划分对每批查询进行索引。首先，本文将该问题定义为一个需满足用户在空间上和文本上的个性化需求的连续的位置点查询。具体来说，本文进行的每次查询都会不间断地向用户提供满足其个性化需求时空-文本对象。这些时空-文本对象需要满足用户给定的空间和文本上的要求。针对该问题，本文提出了有效的算法用于更新网格索引，以及高效的空间-文本匹配算法用于连续处理空间关键字查询。最后，本文在两个真实数据集进行了广泛的实验，研究结果验证了 CSKQM 框架能够大幅度提升查询效率。而且随着数据规模扩大，查询效率仍然能满足实时性要求，具有较高的可扩展性。(3) 提出并解决了连续的相似时空-文本对象连接问题。本文设计了一种基于混合网格索引结构 (HGI) 的三阶段过滤框架。随着基于地理位置的社交媒体和移动应用的不断发展，时空-文本数据的实用价值越来越高。移动用户和基于位置的服务提供商可能希望实时地从海量数据流中接收到与一组特定时空-文本对象匹配的相似连接结果。基于此，给定一组时空-文本对象的集合 Q ，以及时空-文本数据流上的时空-文本对象 P 的动态集合，本文将该问题定义为连续地维护一组最新的连接结果集合，使得该集合中每对时空-文本对象一个来自于 Q ，一个来自于 P ，且两个对象相似度不小于特定的相似度阈值。为此，本文定义了一个有效的轻量级的相似度度量函数，通过考虑空间、文本和时间三个维度来度量两个时空-文本对象之间的相似度。基于该相似度度量，本文设计了一个混合的网格索引结构，以及一个高效处理该问题的过滤框架。本文在两个真实数据集上进行了广泛的实验，实验结果验证了本文所提出的方法的性能优越性。同时，提出的算法能够满足用户实时查询的需求。本文从给定路线下最相似的空间-文本位置点查询、大规模空间关键字的连续查询、连续的相似时空-文本对象连接等三个方面对面向时空文本大数据的高性能搜索方法进行了研究，提出了高效的解决方案，可广泛适用于位置推荐和发现、时空-文本数据管理、数据清洗、位置点隐私保护等场景。

从轨迹中检测共同行为 (co-movement) 模式的问题已经被数据科学领域广泛研究。现有方法主要基于“过滤-精炼” (filter-and-refine) 框架、索引技术、位置点聚类以及搜索算法。尽管这些技术已被广泛应用，但在处理具有复杂群体定义的模式时，往往需要巨大的计算开销，使其难以在大规模轨迹数据上产生及时的结果。在现实应用场景中，尤其是在疫情预警与防控中，实时且高质量的结果尤为重要。

基于此，我们对共同行为模式的定义进行了简化与放宽，在不失一般性的前提下支持快速检测。具体而言，我们通过伴随群体 (companion group) 来定义共同行为模式，该群体由至少 m 个在连续 k 个时间段内共同移动的对象组成。如果某个对象能够与其他对象形成多个伴随群体，则该对象归属于成员数量最大的伴随

群体。给定一组移动对象轨迹，精确算法通过组合满足条件的共同行为对来发现伴随群体，但该过程计算开销较大。为实现高效发现，我们提出了一种快速的、具备社区感知能力的近似算法。基于两个真实世界数据集的大量实验验证了所提出方法的有效性与高效性。

关键词：路线规划；轨迹挖掘；时空数据；城市计算；基于位置服务；相似性查询；
隐私保护

The length of the *Chinese Abstract* has exceeded the maximum limit of 2 page(s).

The length of the *Chinese Abstract* has exceeded the maximum limit of 2 page(s).

The length of the *Chinese Abstract* has exceeded the maximum limit of 2 page(s).

ABSTRACT

When Yang was a teenager, his mother contracted a disease and died, and he then lived a wandering life. When he met Guo Jing and his wife, they took care of him. However, due to the conflict between Yang and Guo Fu, Guo Jing sent him to learn martial arts in the Quanzhen Sect. Later, he escaped from the Quanzhen Sect and met Xiao Longnian at the ancient tomb, where he practised kung fu with Xiao Longnian. He was surrounded by many confidantes who were in love with him, but he only loved Little Dragon Girl, and later married; he and the Guo family feud, several times due to misunderstanding tension, but always stepped forward to help them, lifting the suspicion, turning the gas into peace; ill-fated, separated from Little Dragon Girl for sixteen years, along with the Divine Eagle who is also a teacher and friend of the chivalrous, punishing the evil and promoting the good. Jianghu people “divine eagle hero”. After the little dragon lady is not to perseverance to jump off the cliff to martyrdom, in the bottom of the valley and the little dragon lady reunited with the defence of Xiangyang City, Yang past a show of its unparalleled martial arts power to defeat the Golden Wheel of the Fa Wang, flying stone to kill the Mongolian Khan, to protect the thirteen years of peace in the Great Song Dynasty. He became the world-famous “Divine Eagle Couple”. After the last Mount Hua sword debate, he and his wife Xiaolongnu went into exile.

Keywords: Martial arts; Apostasy; Revenge; Fighting against the enemy; Martial arts; Apostasy; Revenge; Fighting against the enemy

目 录

第一章 基于轨迹数据的群体联合移动模式挖掘	1
1.1 引言	1
1.1.1 研究背景与意义	1
1.1.2 研究内容与挑战	2
1.1.3 研究成果与贡献	5
1.2 问题定义	6
1.3 精确搜索算法	7
1.4 基于近似协同行为计算的社区感知搜索	10
1.4.1 近似协同行为对搜索	11
1.4.2 社区感知聚类	12
1.5 实验评估	13
1.5.1 实验设置	14
1.5.2 实验结果与分析	16
1.6 本章小结	21
第二章 总结与展望	23
2.1 全文总结	23
2.1.1 面向大规模行程请求流的持续最优路线组合规划	23
2.1.2 基于轨迹数据的群体联合移动模式挖掘	24
2.1.3 大规模移动对象上的持续密切接触发现	25
2.1.4 面向时空运动范围的轨迹相似度连接	26
2.2 展望	27
致 谢	30
参考文献	31

图目录

图 1-1	伴随群体发现问题示例	3
图 1-2	轨迹网格编号及网格编号序列示例	12
图 1-3	轨迹数量的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间	16
图 1-4	协同行为持续时间阈值的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间	17
图 1-5	群体规模阈值的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间	19
图 1-6	SCAN 聚类结构相似度参数的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间	20

表目录

表 1-1	主要符号解释.....	6
表 1-2	参数设定.....	15
表 1-3	比较算法.....	15

第一章 基于轨迹数据的群体联合移动模式挖掘

1.1 引言

本章通过对大规模移动轨迹的系统分析，旨在设计高效且可扩展的算法框架，用于识别在特定时间区间内频繁共同出现在相邻空间位置，且在多个时间点存在联合移动的对象集合，即特定群体联合移动模式。该问题有助于为城市规划、交通管理以及社会行为研究等应用场景提供更加深入和精细化的决策支持。

为实现上述目标，本章从数据建模、索引结构设计与算法优化等多个层面展开研究。首先，对特定群体模式检测问题进行形式化定义，明确问题输入、输出及约束条件，并系统分析其在大规模数据环境下面临的计算复杂性与存储开销挑战；其次，结合时空数据挖掘技术，构建适用于大规模轨迹数据的高效索引结构，以支持高性能的候选模式生成与验证过程。在研究背景方面，调研了联合移动模式搜索与轨迹聚类领域的代表性工作，总结其在模式表达能力、计算效率与扩展性方面的优势与不足，从而引出本章研究的核心问题与技术挑战。在问题描述层面，本章依次给出了移动对象及其轨迹的形式化定义，刻画了协同行为的时间持续约束以及空间共现条件，并在此基础上提出了一个更加简化且具有实际意义的伴随群体发现问题定义。

总体而言，大规模性、模式定义的灵活性、算法效率要求以及数据动态变化特征共同构成了该问题的技术难点，也对算法框架设计与系统实现提出了更高要求。针对伴随群体发现问题，首先设计了一种精确求解算法，随后提出了一种新颖的社区感知聚类模型，返回近似解，以有效缩减搜索空间并提升候选群体的质量。基于两个真实世界数据集开展了全面的实验评估，实验结果表明，所提出的社区感知算法能够在用户可交互时间范围内，从大规模轨迹数据中高效发现伴随群体，验证了在实际应用场景中的可行性。

1.1.1 研究背景与意义

随着位置追踪设备，如车载导航系统和智能手机以及 GPS 智能服务的持续普及，轨迹数据的规模呈现爆炸式增长。作为时空数据挖掘中的一项核心任务，联合移动模式挖掘问题已受到广泛关注。一般而言，联合移动模式描述一组在一段时间内在空间上保持接近的对象集合。围绕这一问题，研究者提出了多种具有代表性的模式定义，包括 flock [125, 126]、convoy [118]、swarm [119]、group [123]、platoon [124] 以及 gathering [122, 130] 等。这些模式在时间连续性约束、空间密度

约束以及成员稳定性等方面各有侧重，共同构成了联合移动模式研究的理论基础。

在诸多实际应用中，高效且准确地从移动对象轨迹中发现联合移动模式具有重要意义。例如，在拼车推荐与出行规划中，可以通过识别稳定的同行群体，使其共同出发或考虑彼此对交通的影响等，从而提升资源利用率；在交通拥堵缓解中，可通过及早发现道路上的高密度移动群体来规避潜在拥堵；在新冠病毒等传染病的暴露与风险分析中，可辅助识别潜在高风险接触群体 [139, 176]；此外，在移动行为分析与异常轨迹检测 [133] 等任务中，群体模式挖掘同样发挥着关键作用。

然而，如何在保证模式表达能力的同时提升计算效率，成为该领域亟需解决的重要问题。现有研究大多基于移动对象随时间演化的完整轨迹设计搜索算法。这类方法通常在每一个时间快照上执行聚类或密度计算，以判断对象之间的空间邻近关系。当联合移动模式在时间上不稳定，即对象可能暂时离开群体后又重新加入时，算法需要反复进行候选生成与验证，计算代价显著增加。尤其是在实时或近实时应用场景中，对所有时间快照进行全量聚类将带来极高的时间开销。此外，主流方法多采用“过滤-精炼”的处理框架，在过滤阶段通过建立时空索引排除不可能的数据对象，仅保留可能的候选群体，再在精炼阶段逐一验证其有效性。随着轨迹数据规模的持续增长，候选数量呈指数级膨胀，导致算法性能显著下降，难以满足大规模与在线分析的需求。

1.1.2 研究内容与挑战

在现实应用中，尤其是在公共安全紧急预警与传染病防控等对时效性要求极高的场景下，及时获得最新的联合移动结果至关重要。因此，联合移动模式挖掘任务往往需要以连续或增量的方式执行。这不仅要求算法在时间复杂度上具备良好的可扩展性，还要求其在模式定义上具有一定的灵活性，以适应动态变化的移动行为。然而，现有群体模式定义及其对应方法在同时兼顾模式表达能力与计算效率方面仍存在明显不足，难以在大规模数据环境中实现高效、稳定的持续挖掘。

为了解决上述问题，本文提出了一种联合移动模式概念——伴随群体。相较于已经存在的传统的联合移动模式定义，伴随群体的约束更加宽松且更具实用性。具体而言，一个伴随群体由至少 m 个移动对象组成，这些对象需要在至少 k 个时间段内在空间上保持接近（例如，两两距离不超过预定义的距离阈值 ϵ ），并允许对象在时间维度上暂时离开群体而不破坏整体模式的有效性。基于该模式定义，进一步形式化提出了伴随群体发现问题。给定一组移动对象及其轨迹数据，伴随群体发现问题旨在用户在用户可交互时间范围内高效发现所有满足条件的伴随群体。此外，在问题设定中，若某一对象能够同时参与多个伴随群体，则将其归属于成员规模最大的伴随群体，以保证群体划分结果的确定性与可解释性。伴随群体发现问

题问题具有广泛的应用前景，可服务于交通监测与管理、疫情防控、公共安全预警以及群体行为分析等多种实际场景，为大规模时空数据环境下的群体行为挖掘提供一种高效且可扩展的解决方案。




图 1-1 伴随群体发现问题示例

示例 1.1（伴随群体发现问题示例） 图 1-1给出了一个具体示例以直观说明伴随群体的判定过程。设 o_1, o_2, o_3, o_4 为四个移动对象，且所有对象以固定采样频率每分钟上报一次位置信息。图 1-1 展示了这四个移动对象在时间区间 $[t_1, t_7]$ 内的轨迹变化情况。设空间距离阈值为 $\epsilon = 10$ 米，联合移动的最小持续时间阈值为 $k = 3$ ，群体规模阈值为 $m = 3$ 。首先，从对象两两关系的角度进行分析。可以观察到，对象 o_2 与 o_3 在时间集合 $T = \{t_1, t_2, t_4, t_5, t_6, t_7\}$ 内始终满足两两距离不超过 ϵ 的约束，即在这些时间点保持空间接近关系。由于 $|T| = 6$ ，显著超过持续时间阈值 k ，因此 o_2 与 o_3 构成一个满足条件的联合移动对。同理， o_3 与 o_4 在不少于 k 个时间点内保持空间邻近关系，也可以构成一个联合移动对。在此基础上，进一步考察多对象群体关系。可以发现，在时间点 $\{t_2, t_4, t_5, t_6\}$ 上，对象 o_2, o_3, o_4 的两两距离均不超过 ϵ ，即它们在这些时间点形成一个空间上连通且满足密度约束的三元对象集合。由于该时间集合的规模不少于持续时间阈值 k ，且群体规模 $|g| = 3$ 满足最小规模阈值 m ，因此将 $g = \{o_2, o_3, o_4\}$ 判定为一个有效的伴随群体。需要注意的是，对象 o_1 仅在 t_1 和 t_6 与 o_2 短暂接近，其满足距离约束的时间点数量不足以达到持续时间阈值 k ，且未能与其他对象形成稳定的多对象联合移动模式。因此， o_1 既无法与其他对象构成有效的联合移动对，也不能参与任何满足条件的伴随群体。该

示例说明，伴随群体的判定不仅依赖于空间邻近关系，还同时受到时间持续性与群体规模约束的共同影响，从而能够更全面地刻画移动对象之间的协同行为特征。

为了高效解决伴随群体发现问题，系统在算法设计与工程实现层面面临多方面的关键技术挑战，这些挑战既来源于数据本身的规模与动态特性，也源于模式定义的复杂性与计算代价。具体而言，主要包括以下几个方面：

- **大规模数据处理：**在真实应用场景中，轨迹数据通常来源于海量移动对象，例如车辆、移动终端或各类传感设备，其数据规模可能达到千万级甚至更高。轨迹数据不仅记录频繁，而且具有高维度与强相关性特征，使得存储与计算开销显著增加。如何在如此庞大的数据规模下实现高效的数据组织、索引构建与查询处理，尤其是在需要实时或近实时发现群体模式的场景中，成为首要挑战。这不仅要求算法具备良好的时间复杂度和可扩展性，还需要设计紧凑的空间组织结构与高效的内存管理策略，以降低存储成本并减少 I/O 开销。
- **模式定义的灵活性：**不同应用场景对群体模式的语义需求存在差异。例如，有的应用更关注空间邻近性，有的强调时间持续性，还有的关注成员规模或运动一致性等约束条件。因此，如何构建一个既支持多种群体模式表达，又能够灵活调整参数（如距离阈值、持续时间阈值与最小群体规模）的统一算法框架，是实现方法广泛适用性的关键。同时，该框架在增强表达能力的同时，必须避免因模式定义过于复杂而导致搜索空间急剧膨胀，从而影响整体计算效率。
- **准确性与效率的平衡：**群体模式发现通常涉及复杂的时空约束匹配、多对象关系维护以及候选结构验证等操作。若直接采用精确枚举算法，往往需要在大量时间快照上反复执行聚类或连通性检测，计算代价极高。因此，如何在保证结果准确性的前提下，通过有效的剪枝策略、搜索空间压缩技术、分层索引机制或近似计算方法减少不必要的候选生成与验证，是提升系统性能的核心问题。尤其在数据规模持续增长的背景下，算法必须在结果质量与运行效率之间取得合理且可控的权衡。
- **动态性的处理：**轨迹数据具有天然的动态特征，移动对象的位置与行为随时间持续变化。在流式或持续更新的数据环境中，新轨迹不断到达，历史数据逐渐失效，群体结构也随之演化。若每次更新都重新对全部历史数据进行计算，将带来难以接受的时间开销。因此，如何设计支持增量更新或滑动窗口处理机制的算法，在无需重复计算全部数据的前提下高效维护群体模式结果，是保证系统实时性、稳定性与可扩展性的关键技术挑战。

1.1.3 研究成果与贡献

综上所述,大规模数据处理需求、模式定义的灵活性要求、算法效率约束以及数据动态演化特征,共同构成了伴随群体发现问题的核心技术难点,也对整体算法框架设计与系统实现提出了更高要求。针对伴随群体发现问题,本文从精确算法设计与高效近似算法设计两个层面展开研究。

首先,设计了一种精确搜索算法。该算法基于严格的时空约束判定机制,对候选对象对及候选群体进行精确验证,能够保证结果的完备性与准确性。然而,由于需要在多个时间维度上进行精细化匹配与验证,其计算代价相对较高,更适用于离线分析或数据规模适中的场景。

为进一步提升算法效率并满足实时或近实时应用需求,本文额外提出了一种社区感知的近似搜索算法。该算法在保证结果质量可控的前提下,通过近似计算与结构化聚类方法显著压缩搜索空间,从而在严格的效率约束下有效解决伴随群体发现问题,实现准确性与效率之间的平衡。

近似算法主要包括两个阶段:近似联合移动对搜索阶段与社区感知群体发现阶段。在近似联合移动对搜索阶段,首先采用基于网格划分的空间离散化方法,将每个轨迹位置映射为对应的网格单元编号,从而将连续轨迹转换为离散的网格单元编号序列表示。随后,通过计算不同轨迹之间的公共编号数量来快速估计其潜在的联合移动程度,从而生成候选的近似联合移动对。该过程有效避免了在原始连续空间中进行高代价的距离计算。在社区感知群体发现阶段,将生成的联合移动对视为图结构中的边,并利用 SCAN 算法 [179] 进行结构化聚类,以识别具有高内聚性和清晰社区边界的对象集合。通过引入社区结构约束,算法能够在保证群体结构合理性的同时,进一步降低无效候选的数量,从而提升整体运行效率。本文算法实现已开源发布^①,以便于后续研究复现与扩展。

本文的主要贡献总结如下:

- 提出了伴随群体这一联合移动模式定义。该定义相较于传统模式更加宽松且具备更强的适应性,尤其适用于需要持续结果更新与快速响应的应用场景,例如传染病传播监测与公共安全紧急风险预警。
- 设计并实现了一种精确搜索算法以及一种社区感知的近似搜索算法,系统性地解决了伴随群体发现问题在准确性与效率之间的权衡难题。
- 基于两个真实世界数据集开展了全面的实验评估。实验结果表明,所提出的社区感知算法能够在用户可交互时间范围内,从大规模轨迹数据中高效发现伴随群体,验证了方法在实际应用场景中的有效性与实用价值。

^① https://github.com/Like-China/gathering_mining.git

本文其余部分组织结构如下。第 1.2 节首先形式化给出问题定义，并介绍相关的符号说明与必要的预备知识，为后续算法设计奠定理论基础。第 1.3 节在此基础上提出一种精确算法，详细阐述其核心思想、实现流程以及时间复杂度分析。第 1.4 节进一步给出一种社区感知的高效近似算法，通过结构压缩与候选剪枝策略提升算法的可扩展性，并分析其性能优势与适用场景。第 1.5 节基于真实世界轨迹数据开展系统实验，从有效性与效率两个方面对所提方法进行全方面评估与对比分析。最后，第 1.6 节对全文进行总结，并展望未来的研究方向。

1.2 问题定义

本节介绍所需的基础概念，并给出问题的形式化定义。给定一组移动对象，依次定义移动对象及其轨迹、协同行为持续时间、协同行为对、伴随群体以及伴随群体发现问题。本章所使用的主要符号及其解释如表1-1所示。

表 1-1 主要符号解释

符号	解释
o	一个移动对象
O	一组移动对象集合
s	一个采样位置点
τ	一条轨迹
$\mathcal{T}$	一组轨迹集合
t	某个时刻
ϵ_s/ϵ_t	空间距离阈值/时间距离阈值
k	协同行为持续时间阈值
m	最小群体规模阈值
g	一个伴随群体
$\mathcal{G}$	一组伴随群体

定义 1.1（移动对象及其轨迹） 一个移动对象 o 由其轨迹 $\tau = \{s_1, \dots, s_n\}$ 表示，其中轨迹是一个有限的、按时间顺序排列的离散时空点序列。该序列由位置追踪设备从对象 o 的真实运动轨迹中采样获得。

为简化描述，使用 $s_i = ([x, y], t)$ 表示二维空间中的一个离散采样位置点，其中 $[x, y]$ 表示空间坐标， t 表示该位置被记录时对应的时间戳。对于一组移动对象 O ，记其轨迹集合为 $\mathcal{T} = \{\tau_1, \dots, \tau_{|O|}\}$ ，其中 τ_i 为对象 o_i 的轨迹。本文对移动对象及轨迹的建模方式与已有研究保持一致 [98, 99, 109]。

定义 1.2（协同行为持续时间） 设 o_i 与 o_j 为两个移动对象。当 o_i 与 o_j 之间的空间距离小于等于给定的空间距离阈值 ϵ_s ，且对应时间戳之差不超过给定的时间

距离阈值 ϵ_t 时，称二者在该时刻处于协同行为状态。对象 o_i 与 o_j 的协同行为持续时间定义为所有满足上述条件的长度之和。

定义 1.3 (协同行为对) 设 τ_i 与 τ_j 分别为对象 o_i 与 o_j 的轨迹。给定 k 为协同行为持续时间阈值，若 τ_i 与 τ_j 之间的协同行为持续时间不少于给定阈值 k ，则称对象 o_i 与 o_j 构成一个协同行为对。

定义 1.4 (伴随群体) 给定一组移动对象 $\mathcal{O} = \{o_1, o_2, \dots, o_{|\mathcal{O}|}\}$ 以及最小群体规模阈值 m ，若对象子集 $g \subseteq \mathcal{O}$ 满足以下两个条件，则称 g 为一个伴随群体：

- (1) $|g| \geq m$;
- (2) 对任意两个对象 $o_i, o_j \in g$ ， o_i 与 o_j 均构成协同行为对。

定义 1.5 (伴随群体发现问题) 给定一组移动对象 $\mathcal{O}$ ，伴随群体发现问题旨在从 $\mathcal{O}$ 中发现一组伴随群体 $\mathcal{G}$ ，并满足对任意两个群体 $g_i, g_j \in \mathcal{G}$ ，均有 $g_i \cap g_j = \emptyset$ 。

1.3 精确搜索算法

本节提出一种用于发现伴随群体的精确求解方法——精确联合移动算法 (Exact Search with Exact Co-Movement Computation, 简称 ES-ECMC)。该算法对所有候选对象组合进行精确验证，从而保证结果的完备性与正确性。

ES-ECMC 算法整体上包含三个核心步骤。首先，给定输入数据，即一组移动对象轨迹集合，通过精确的时空约束计算枚举并识别所有满足持续时间阈值 k 的联合移动对；其次，以这些联合移动对为基础，构建对象之间的关联结构，并采用增量扩展策略逐步生成满足条件的伴随群体候选；最后，在所有生成的候选集合中，依据成员规模优先的原则筛选出不可扩展且规模最大的伴随群体作为最终输出结果。该三阶段流程分别对应“协同行为对发现—伴随群体候选集合扩展—结果筛选”三个层次，层层递进，从而实现对搜索空间的系统化遍历与剪枝。在介绍具体流程之前，首先给出伴随群体候选的形式化定义，以便后续算法描述与性质分析。

定义 1.6 (伴随群体候选) 一个伴随群体候选 g' 是一个对象集合，满足其中任意两个对象均可以构成一个联合移动对。若存在至少一个集合外的对象 $o \notin g'$ ，使得扩展后的集合 $g' \cup \{o\}$ 仍然满足上述条件，则称 g' 可以通过加入对象 o 进行扩展；否则，称 g' 为不可扩展的伴随群体候选。

下面将详细介绍 ES-ECMC 算法的整体流程与核心思想。算法 1-1 给出了 ES-ECMC 的完整伪代码描述。该算法以一组轨迹数据 $\mathcal{T}$ 作为输入，同时给定空间距离阈值 ϵ_s 、时间距离阈值 ϵ_t 、最小群体规模阈值 m 以及联合移动持续时间阈值 k 。算法的输出为一组满足定义约束的伴随群体集合 $G = \{g_1, g_2, \dots\}$ ，其中每个

算法 1-1: ES-ECMC

输入: 轨迹集 $\mathcal{T} = \{\tau_1, \tau_2, \dots, \tau_{|\mathcal{O}|}\}$;
 空间距离阈值 ϵ_s ;
 时间距离阈值 ϵ_t ;
 群体规模阈值 m ;
 联合移动持续时间阈值 k 。
输出: 一组满足定义约束的精确的伴随群体集合 G 。

```

1  初始化:  $P \leftarrow \emptyset$ ;                                     // 有效轨迹对集合
2  初始化:  $G_c \leftarrow \emptyset$ ;                             // 候选群体集合
3  初始化:  $G \leftarrow \emptyset$ ;                               // 最终结果集合

4  for  $i = 1$  to  $|\mathcal{T}|$  do                                     /* 生成有效轨迹对 */
5      for  $j = i + 1$  to  $|\mathcal{T}|$  do
6          if  $|\tau_i \cap \tau_j| \geq k$  then
7               $P \leftarrow P \cup \{(\tau_i, \tau_j)\}$ ;

8  foreach  $(\tau_i, \tau_j) \in P$  do                             /* 扩展候选群体 */
9       $g_i \leftarrow \{\tau_i, \tau_j\}$ ;
10     foreach  $(\tau_i, \tau_k) \in P$  do
11         if  $\forall \tau_p \in g_i, (\tau_k, \tau_p) \in P$  then        /* 两两有效且所有成员均在  $g_i$  中 */
12              $g_i \leftarrow g_i \cup \{\tau_k\}$ ;
13     if  $|g_i| \geq m$  then                                     /* 群体规模约束 */
14          $G_c \leftarrow G_c \cup \{g_i\}$ ;

15  $G \leftarrow \text{select\_max}(G_c)$ ;                             // 选择最大或最优群体
16 return  $G$ ;
```

$g_i \subseteq \mathcal{T}$, 表示由若干移动对象轨迹构成的一个伴随群体。在实现层面, 使用一个集合 P 存储所有满足持续时间阈值 k 的协同行为对, 用以刻画对象之间的两两联合移动关系 (第 1 行); 同时, 使用一个集合 G_c 存储在搜索过程中生成的伴随群体候选 (第 2 行)。通过先构建联合移动对集合 P , 再基于 P 进行增量式候选扩展与验证, 算法能够系统地遍历可能的对象组合, 并通过可扩展性判定与规模约束进行有效剪枝, 从而最终得到满足条件的伴随群体集合 G (第 3 行)。该算法包含 3 个主要步骤: 枚举联合移动对, 生成伴随群体候选, 以及选择伴随群体。

步骤 1: (枚举联合移动对)

对于任意一对移动对象 $o_i, o_j \in \mathcal{O}$, 计算其轨迹中任意两个采样位置 $s \in \tau_i$ 与 $s' \in \tau_j$ 之间的精确距离。若空间距离与时间距离分别不超过阈值 ϵ_s 与 ϵ_t , 则将其联合移动持续时间 $|\tau_i \wedge \tau_j|$ 累加 1。具体而言, 对于每一对对象 $\langle o_i, o_j \rangle$, 当其累计的联合移动持续时间不少于阈值 k 时, 将其视为一个联合移动对^①。当所有对象对均被评估完成后, 该步骤结束 (第 4–7 行)。

步骤 2: (生成伴随群体候选)

在获得所有联合移动对之后, 基于这些联合移动对以增量方式生成伴随群体候选。具体而言, 首先选择一个以轨迹 τ_i 为起点的联合移动对, 例如 $\langle \tau_i, \tau_j \rangle$, 然后考察所有与其共享对象 o_i 的联合移动对 $\langle \tau_i, \tau_k \rangle$ 。初始群体记为 $g_i = \{\tau_i, \tau_j\}$ 。若 τ_k 与 g_i 中的所有成员均构成联合移动对, 则将 τ_k 加入 g_i 。当 g_i 仍可扩展时, 重复上述扩展过程。若 $|g_i| \geq m$, 则将其加入候选集合 G_c 。随后选择新的联合移动对作为初始群体并继续扩展。当所有联合移动对均被访问并作为初始群体尝试扩展后, 该步骤结束 (第 8–14 行)。

步骤 3: (选择伴随群体)

在获得所有候选群体之后, 从中选取成员规模最大的伴随群体作为最终结果。具体而言, 若某个对象同时属于多个候选群体, 则仅保留其中成员规模最大的一个。该步骤在遍历完所有候选群体后结束 (第 15 行)。

示例 1.2 (ES-ECMC 算法示例) 再次考虑图 1-1 中的示例。假设首先选择联合移动对 $\langle o_2, o_3 \rangle$ 进行扩展。显然, 联合移动对 $\langle o_2, o_4 \rangle$ 与 $\langle o_2, o_3 \rangle$ 共享对象 o_2 , 且对象 o_2, o_3, o_4 两两之间均可形成联合移动对。因此, 将 $g' = \{o_2, o_3, o_4\}$ 视为一个伴随群体候选。由于对象 o_1 无法与 g' 中的任一对象形成联合移动对, g' 不可进一步扩展。接着, 由于 $|g'|$ 不小于预设的群体规模阈值 3, 将 g' 加入候选集合 G_c 。最终, 由于 g' 具有最大的成员规模, 从 G_c 中选取 g' 并将其加入结果集合 G 。

定理 1.1 (ES-ECMC 算法时间复杂度) ES-ECMC 算法的时间复杂度为

^① 在上下文清晰的情况下, 使用 (o_i, o_j) 或 (τ_i, τ_j) 表示一个联合移动对。

$O(|\mathcal{T}|^2 \times |\tau|^2)$ ，其中 $|\mathcal{T}|$ 表示移动对象或轨迹的数量， $|\tau|$ 表示单条轨迹的平均长度，即采样位置数。

证明：ES-ECMC 的主要时间开销来自三个阶段。

首先，在枚举所有联合移动对时，需要对任意一对轨迹 $\tau_i, \tau_j \in \mathcal{T}$ 进行逐点比较。对于每一对轨迹，需计算其所有采样点对之间的空间距离与时间距离，时间复杂度为 $O(|\tau|^2)$ 。由于轨迹对的数量为 $O(|\mathcal{T}|^2)$ ，因此该阶段的总体时间复杂度为

$$O(|\mathcal{T}|^2 \times |\tau|^2)。$$

其次，在生成伴随群体候选阶段，对于共享同一对象的联合移动对（例如 $\langle o_i, o_j \rangle$ 与 $\langle o_i, o_k \rangle$ ），需要判断其是否能够构成伴随群体候选，并在满足条件时进行扩展。该过程本质上是在联合移动对构成的图结构上进行增量式团扩展。最少情况下（例如不存在任何共享对象的联合移动对），该阶段仅需线性扫描联合移动对集合，时间复杂度为 $O(|\mathcal{T}|)$ ；在最坏情况下，若任意两个对象之间均可形成联合移动对，则候选生成过程可能涉及 $O(|\mathcal{T}|^2)$ 次组合与验证操作。然而，该阶段的复杂度上界仍然不超过前一阶段的 $O(|\mathcal{T}|^2 \times |\tau|^2)$ 。

最后，在候选集合 G_c 中选择最终伴随群体时，仅需遍历所有候选并进行规模比较，时间复杂度为 $O(|G_c|)$ 。由于 $|G_c| < |\mathcal{T}|^2$ ，且通常远小于前两阶段的计算规模，因此该阶段不会改变整体复杂度阶。综上所述，ES-ECMC 算法的总体时间复杂度由联合移动对枚举阶段主导，为

$$O(|\mathcal{T}|^2 \times |\tau|^2)。$$

■

1.4 基于近似协同行为计算的社区感知搜索

尽管 ES-ECMC 精确算法直观且能够保证结果的精确性，但其较高的计算开销使其难以直接应用于大规模实际场景，尤其是在移动对象数量极大的情况下。其主要性能瓶颈在于需要通过精确计算协同行为持续时间来枚举所有协同行为对，该过程涉及大量轨迹间的逐点比较操作，时间代价高昂。为提升算法效率，本文提出一种基于社区感知的搜索算法，并结合近似协同行为计算策略，即 Community-aware Search with Approximate Co-Movement Computation（简称 CS-ACMC）。该方法在保证较高结果质量的同时，显著降低了计算复杂度。CS-ACMC 算法主要包含两个阶段：（1）近似协同行为对搜索阶段，通过构建轨迹的紧凑表示并进行快速相似性筛选，以高效识别潜在的协同行为对；（2）基于社区感知的聚类阶段，在所构建的对象关系图上挖掘结构紧密的对象子集，从而获得伴随群体。接下来，将

依次介绍近似协同行为对搜索策略以及社区感知聚类算法的具体设计。

1.4.1 近似协同行为对搜索

在该阶段中，提出了一种高效的协同行为对搜索方法，用于计算两个对象轨迹之间协同行为持续时间的近似值。所生成的近似协同行为对将作为后续社区感知聚类阶段的输入，从而高效地发现伴随群体。该阶段包含两个子步骤：生成轨迹网格编号序列，以及搜索近似协同行为对。

1.4.1.1 轨迹网格编号序列生成

该方法受到群体（flock）圆形结构思想的启发 [118]。首先将底层时空域进行离散化处理：在空间维度上，将二维欧氏空间划分为边长相等的网格单元；在时间维度上，将时间轴划分为等长的时间片。因此，对于对象轨迹中的每一个数据点（位置） $s = ([x, y], t)$ ，均可映射为一个网格编号，记为 $o(s) = f(x, y, t)$ ，其中 $f(\cdot)$ 为单射函数，用于将三维离散坐标唯一映射为一个整数标识。由此，轨迹 τ 可表示为对应的网格编号序列： $O(\tau) = \{o(s_1), \dots, o(s_{|\tau|})\}$ 。图 1-2 展示了空间与时间维度的划分方式以及轨迹网格编号序列的生成过程。假设空间被划分为 5×4 个网格单元，每个单元边长为 10 米，时间维度被划分为 3 个时间片，每个时间片长度为 10 秒。给定两条轨迹 τ_1 和 τ_2 ，其位置分别落入单元 $\{([0, 0], 0), ([3, 1], 1), ([2, 1], 2)\}$ 。基于上述划分方式，定义单射函数为 $o(s) = f(x, y, t) = t \times (5 \times 4) + y \times 5 + x$ ，其中 $x \in \{0, 1, 2, 3, 4\}$ ， $y \in \{0, 1, 2, 3\}$ ， $t \in \{0, 1, 2\}$ 。

示例 1.3 对于位置 $([3, 1], 1)$ ，其网格编号值为 $1 \times (5 \times 4) + 1 \times 5 + 3 = 28$ 。如图 1-2 所示，尽管 τ_1 与 τ_2 在各时间点的精确空间位置不同，但由于它们落入相同的空间网格单元与时间片，因此可被表示为相同的网格编号序列 $\{0, 28, 47\}$ 。

定理 1.2 若将空间划分为边长为 ϵ 的等大小网格单元，其中 ϵ 等于协同行为距离阈值，则若两个对象 o_i 与 o_j 的轨迹网格编号序列共享 p 个相同网格编号，则它们的协同行为持续时间至少为 p 个时间段。

证明：位置 s 的网格编号值由单射函数 $o(s) = f(x, y, t)$ 唯一确定。若两个位置具有相同的网格编号值，则说明它们位于同一个空间网格单元，并且处于同一时间片内。由于网格单元的边长设置为协同行为距离阈值 ϵ ，因此同一单元内任意两点之间的空间距离不超过 ϵ ，同时其时间差不超过一个时间片长度。若两条轨迹的网格编号序列共享一个网格编号，则表示对应对象在该时间段内保持不超过 ϵ 的空间距离共同移动。因此，共享 p 个网格编号意味着至少存在 p 个满足距离约束的协同行为时间段，从而协同行为持续时间不少于 p 。 ■




图 1-2 轨迹网格编号及网格编号序列示例

1.4.1.2 近似协同行为对搜索

基于轨迹网格编号序列，通过统计两个轨迹之间的公共网格编号数量来近似计算其协同行为持续时间。对于两个轨迹网格编号序列 $O(\tau_i)$ 和 $O(\tau_j)$ ，若其公共网格编号数 $|O(\tau_i) \cap O(\tau_j)|$ 不小于阈值 k ，则将 $\langle \tau_i, \tau_j \rangle$ 记录为一个近似协同行为对。该过程对所有轨迹对执行一次，当全部轨迹网格编号序列均被评估完成后终止。

1.4.2 社区感知聚类

对于轨迹集合 $\mathcal{T} = \{\tau_1, \tau_2, \dots, \tau_{|\mathcal{T}|}\}$ ，通过第一阶段近似协同行为对搜索后可获得轨迹网格编号序列集合 $O(\mathcal{T}) = \{O(\tau_1), O(\tau_2), \dots, O(\tau_{|\mathcal{T}|})\}$ ，以及一组近似协同行为对。在第二阶段中，目标是发现所有满足以下条件的子集 $\mathcal{T}' \subseteq \mathcal{T}$ ：(1)

$|\mathcal{T}'| \geq m$; (2) 对任意 $\tau_i, \tau_j \in \mathcal{T}'$, 均有 $|O(\tau_i) \cap O(\tau_j)| \geq k$,

即满足伴随群体定义的对象集合。为此, 采用聚类技术以实现高效检测。现有轨迹聚类方法主要包括基于划分的聚类 [180, 181]、基于密度的聚类 [182, 183] 以及基于深度学习的聚类 [102, 103, 140]。然而, 这些方法通常侧重于整体轨迹相似性建模, 难以刻画对象之间的显式协同行为连接关系; 同时, 部分基于密度的方法在大规模数据上具有较高的计算开销。因此, 上述针对轨迹聚类或表示学习提出的解决方案, 均无法直接应用于本文所研究的伴随群体发现问题。其根本原因在于, 聚类方法关注的是整体轨迹相似度或嵌入空间中的距离关系, 而处于同一聚类中的移动对象并不一定在具体时间段内真实地满足时空共现约束。换言之, 轨迹在全局层面上的相似性并不能保证其在局部时间区间内存在持续的联合移动行为。因此, 伴随群体发现问题仍需基于严格的时空约束建模与结构化搜索策略进行专门设计, 而不能简单依赖现有的轨迹表示学习或聚类方法。

核心思想是将协同行为关系建模为网络(图)结构, 其中节点表示移动对象, 边表示近似协同行为对。一个伴随群体对应于图中由至少 m 个节点构成的高度结构化子图, 且任意两节点之间均满足协同行为约束。受同质性假设的启发——即共享大量协同行为邻居的对象更可能属于同一群体——采用基于共享邻居结构的社区感知聚类方法进行检测。SCAN 算法 [179] 是一种典型的社区感知聚类方法, 其基于顶点结构相似性与连通性进行社区划分, 时间复杂度为 $O(|P|)$, 其中 $|P|$ 为协同行为对的数量(即图中的边数)。因此, SCAN 能够高效地应用于伴随群体检测任务。

定理 1.3 CS-ACMC 算法的时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|)$, 其中 $|\mathcal{T}|$ 表示轨迹数量, $|\tau|$ 表示单条轨迹的长度。

证明: 在近似协同行为对搜索阶段, 需要对每一对轨迹计算其公共网格编号数。若每条轨迹的网格编号序列长度为 $|\tau|$, 则通过线性扫描或哈希统计可在 $O(|\tau|)$ 时间内完成一对轨迹的公共网格编号计算。因此, 该阶段的时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|)$ 。在社区感知聚类阶段, SCAN 算法的时间复杂度为 $O(|P|)$, 其中 $|P|$ 为近似协同行为对数量, 且 $|P| \leq |\mathcal{T}|^2$ 。因此, 整体时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau| + |P|) = O(|\mathcal{T}|^2 \times |\tau|)$ 。综上, CS-ACMC 算法的总体时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|)$ 。 ■

1.5 实验评估

在本节中, 首先介绍实验设定, 包括所使用的数据集与运行环境; 随后给出实验结果与分析。实验主要关注所提出搜索算法在运行时间方面的表现, 即高效性。通过设置不同参数, 如轨迹长度、位置点密度、协同行为持续时间阈值等, 对比不

同算法的运行时间并进行分析。

1.5.1 实验设置

1.5.1.1 数据准备

本文实验基于两个真实世界的出租车轨迹数据集：北京出租车轨迹数据集 [184, 185]^①以及波尔图出租车轨迹数据集^②。

1.5.1.1.1 北京出租车轨迹数据集 该数据集记录了 2008 年 2 月 2 日至 2008 年 2 月 8 日期间，北京市 10357 辆出租车的 GPS 轨迹数据。该数据集包含了约 1500 万条轨迹点，总距离达到 900 万公里，平均采样间隔约为 177 秒，距离约为 623 米。每个文件以出租车 ID 命名，详细记录了时间、经度和纬度信息，为城市交通分析、出租车轨迹预测、路径规划以及地理信息系统研究提供了丰富的数据支持。

1.5.1.1.2 波尔图出租车轨迹数据集 本研究采用的波尔图出租车轨迹数据集来源于葡萄牙波尔图市的出租车调度系统。时间跨度为 19 个月，包含超过 170 万条出租车轨迹。所有车辆均通过安装在车载终端中的移动数据设备与调度中心通信，因此能够连续采集高精度 GPS 轨迹数据。该数据集具有时间跨度长、采样频率稳定、轨迹覆盖范围广等特点，能够真实反映城市尺度下出租车群体的动态出行行为，为协同行为模式挖掘与群体结构分析提供了可靠的数据基础。

1.5.1.1.3 数据预处理 为统一实验设定，所有时间戳均被映射到 24 小时范围内。对于波尔图数据集，每条轨迹的出发时间被随机分配至 24 小时区间内，以避免时间分布偏置。所有轨迹数据在实验前均被预处理并转换为轨迹网格编号序列。生成网格编号序列及伴随群体发现所使用的默认参数设置如表 1-2 所示。同时，对轨迹的经纬度范围以及轨迹长度进行了筛选与限制，以保证实验规模可控且具有代表性，具体参数同样列于表 1-2 中。

1.5.1.2 比较算法

表1-3列举了实验研究中的比较算法。本文对以下两种算法进行性能比较：ES-ECMC 算法，以及 CS-ACMC 算法。此外，在候选对象筛选阶段引入 R 树索引结构 [157]，以对空间上显然不满足距离约束的对象对进行早期剪枝，从而减少无效距离计算并提升整体运行效率。

① <https://www.microsoft.com/en-us/research/publication/t-drive-trajectory-data-sample/>

② <https://www.kaggle.com/c/pkdd-15-predict-taxi-service-trajectory-i/data>

表 1-2 参数设定

	北京数据集	波尔图数据集
经度范围	[116.250, 116.550]	[-8.735, -8.156]
维度范围	[39.830, 40.030]	[40.953, 41.307]
轨迹长度范围	[20, 100]	[20, 100]
ϵ_s	200 米	200 米
ϵ_t	200 秒	200 秒
$ \mathcal{T} $	2K–10K / 默认 6K	20K–100K / 默认 20K
k	2–6 / 默认 4	2–6 / 默认 4
m	2–6 / 默认 4	2–6 / 默认 4
μ	0.42–0.50 / 默认 0.50	0.42–0.50 / 默认 0.50

表 1-3 比较算法

算法标识	算法描述
ES-ECMC	精确搜索算法
CS-ACMC	基于近似协同行为计算的社区感知搜索算法

1.5.1.3 评估指标

为了评估 CS-ACMC 算法的有效性, 采用 ES-ECMC 算法所发现的精确协同行为对作为基准, 并使用协同行为对的平均命中率作为主要质量评估指标。具体而言, 对于 ES-ECMC 算法发现的每一个精确伴随群体 g , 若其中任意一个协同行为对 $\langle o_i, o_j \rangle$ (其中 $o_i \in g, o_j \in g$) 同时存在于 CS-ACMC 算法所发现的任意一个伴随群体中, 则认为该协同行为对被命中, 命中计数加一; 否则认为未被命中。最终统计所有精确协同行为对的命中比例, 作为整体命中率。该指标能够有效反映近似算法在保持协同行为结构方面的结果质量。在效率评估方面, 采用平均 CPU 运行时间作为主要性能指标。需要说明的是, 在默认参数设置下, ES-ECMC 算法在北京数据集上采用单线程运行时至少需要 1 天时间, 因此实验中为 ES-ECMC 启用了 40 个线程以保证实验可行性; 相比之下, CS-ACMC 算法仅使用单线程运行。

1.5.1.4 实验环境

所有算法均采用 Python 实现, 并运行于 Ubuntu 操作系统平台。实验硬件环境为: 2 颗 Intel(R) Xeon(R) Silver 4214R CPU (主频 2.40GHz) 以及 128GB 内存。除非特别说明, 所有实验结果均为在 20 组不同测试轨迹输入下重复实验所得的平均值, 以减少偶然因素对结果的影响。

1.5.2 实验结果与分析

1.5.2.1 轨迹数量的影响

首先，在默认参数设置下，研究轨迹数量变化对算法性能的影响。具体而言，在波尔图数据集中，轨迹数量从 20,000 增加至 100,000；在北京数据集中，轨迹数量从 2,000 增加至 10,000。之所以采用该设置，是因为北京数据集的轨迹空间分布更加密集、采样间隔更小，因此任意两条轨迹更容易满足距离约束并形成协同行为对，从而带来更高的计算压力。从命中率结果来看，波尔图数据集上的命中率随轨迹数量增加呈现明显上升趋势（见图 1-3(c)）。当轨迹数量由 20K 增加至 100K 时，命中率由约 0.70 提升至接近 0.88。这一现象说明，在轨迹规模较小时，近似方法可能因协同行为对数量较少而遗漏部分结构；随着轨迹数量增加，对象之间的连接关系更加充分，社区结构更加清晰，基于共享邻居的聚类策略能够更准确地恢复真实伴随群体结构。相比之下，北京数据集上的命中率始终稳定在 0.91–0.93 之间（见图 1-3(a)），整体波动较小。这是因为北京数据集本身轨迹密度较高，在较小规模下已能形成相对稳定的协同行为图结构，因此随着规模增加，近似算法的结果质量提升空间有限，但整体保持较高水平。




图 1-3 轨迹数量的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间




图 1-4 协同行为持续时间阈值的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间

在算法运行效率方面，两种算法的运行时间均随轨迹数量增加而增长，但增长趋势存在显著差异。ES-ECMC 的运行时间随规模增加呈现近似二次增长趋势；而 CS-ACMC 的增长速度明显更缓（见图 1-3(b) 和图 1-3(d)）。即便 ES-ECMC 在实验中采用了 40 线程并行计算，当轨迹数量达到 10,000（北京）和 100,000（波尔图数据集）时，其运行时间仍分别超过 8,000 秒和 20,000 秒；相比之下，CS-ACMC 在单线程条件下的运行时间始终控制在千秒以内。值得注意的是，波尔图数据集中捕获的协同行为对数量明显多于北京数据集，导致图结构更加稠密，从而增加了精确算法的计算负担。这也进一步放大了两种方法在大规模场景下的性能差距。综上所述，随着轨迹数量的增加，CS-ACMC 在保证较高命中率（尤其在大规模数据上不断提升）的同时，始终保持至少一个数量级的时间优势。这表明该方法在大规模轨迹数据分析场景下具有良好的可扩展性和实际应用价值。

1.5.2.2 协同行为持续时间阈值的影响

图 1-4 展示了当协同行为持续时间阈值 k 从 2 增加到 6 时两种算法的性能变化趋势。从命中率角度来看，北京数据集上的命中率随 k 增大呈现缓慢上升趋势

(见图 1-4(a))。当 $k = 2$ 时命中率约为 0.89，随后逐步提升并稳定在 0.91 以上。这表明在北京这种高密度轨迹环境下，提高持续时间阈值能够有效过滤掉短暂、偶然的协同行为，使近似方法更聚焦于结构稳定的协同行为对，从而提升结果质量。相比之下，波尔图数据集上的命中率随着 k 的增大整体呈下降趋势（见图 1-4(c)），从约 0.75 下降至 0.69 左右。这是因为波尔图数据集采样频率更高、时间跨度更长，较大的 k 会显著减少满足条件的协同行为对数量，使得图结构变得稀疏，进而影响基于共享邻居的社区识别效果。因此，近似方法在较大 k 下更容易遗漏部分真实协同行为结构。

在运行时间方面，如图 1-4(b) 和图 1-4(d)，两种算法均未随着 k 的增大而出现明显下降趋势。尽管理论上更大的 k 会减少协同行为对及伴随群体数量，从而降低后续聚类成本，但实验结果表明，总体运行时间基本保持稳定。其主要原因在于，算法的核心计算开销集中在协同行为对的枚举或近似计算阶段，而该阶段需要对所有轨迹对进行比较，其复杂度与 k 无关；从协同行为对中生成分随群体的代价相对较低，因此 k 的变化对总时间影响有限。同时可以观察到，在所有 k 取值下，CS-ACMC 的运行时间始终显著低于 ES-ECMC。即使在较小 k 的情况下，CS-ACMC 仍保持明显的效率优势，进一步验证了近似计算策略在降低计算成本方面的有效性。

1.5.2.3 群体规模阈值的影响

图 1-5 展示了当群体规模阈值 m 从 2 变化到 6 时两种算法性能的变化趋势。直觉上，随着 m 的增大，满足条件的伴随群体数量逐渐减少，因为只有结构更加紧密、连接更加稳定的对象集合才能满足更严格的规模约束。这一变化对结果质量与运行时间均产生一定影响。如图 1-5(a)，北京数据集上的命中率随着 m 的增加呈显著上升趋势。当 $m = 2$ 时命中率约为 0.71，而当 $m = 5$ 或 6 时可提升至 0.93 左右。这说明在高密度轨迹环境下，小规模群体中包含较多边界性或弱连接结构，近似方法可能存在一定偏差；而当 m 增大后，仅保留结构更加紧密的核心群体，使得近似方法与精确方法在识别结果上更加一致，从而显著提升命中率。相比之下，波尔图数据集上的命中率随着 m 的增加呈下降趋势，从约 0.88 下降至 0.59 左右。这主要是由于波尔图数据集数据的空间分布更为分散、轨迹时间跨度更长。当 m 较大时，满足条件的群体数量显著减少，图结构趋于稀疏，近似协同行为对可能无法完整保留所有真实连接关系，导致部分精确群体未被成功恢复，从而降低命中率。

在效率方面（见图 1-5(b) 和图 1-5(d)），群体规模阈值 m 的变化对总体运行时间影响较小。两种算法的运行时间曲线基本保持平稳，仅在个别取值处存在轻微

波动。这进一步验证了前文分析：算法的主要时间开销集中在协同行为对的构建或近似计算阶段，而最终伴随群体的筛选与过滤成本相对较低，因此 m 的变化不会显著改变总体时间复杂度。同时可以观察到，在所有 m 取值下，CS-ACMC 的运行时间始终远低于 ES-ECMC。即使在波尔图数据集中，当 $m = 6$ 时 ES-ECMC 的运行时间超过 8,000 秒，而 CS-ACMC 仍保持在数百秒以内，体现出明显的规模优势。综上所述，在不同 m 参数设置下，CS-ACMC 在保持较高命中率（尤其在高密度数据集上）的同时，显著降低了运行时间，表现出良好的稳定性与参数鲁棒性。这表明该方法能够适应不同规模约束条件，在多种实际应用场景中具有较强的实用价值。




图 1-5 群体规模阈值的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间

1.5.2.4 聚类参数的影响

图 1-6 展示了当结构相似度阈值 μ 从 0.42 增加到 0.50 时算法在两个数据集上的命中率与运行时间变化情况。结构相似度阈值用于控制对象之间是否建立连接： μ 越小，两个对象越容易满足相似性条件，从而在协同行为图中形成更多边； μ 越大，则连接关系更加严格，图结构趋于稀疏。




图 1-6 SCAN 聚类结构相似度参数的影响。(a) 北京数据集上的命中率 (b) 北京数据集上的运行时间 (c) 波尔图数据集上的命中率 (d) 波尔图数据集上的运行时间

从命中率变化趋势来看，在波尔图数据集中（见图 1-6(c)），随着 μ 的增大，命中率呈现明显下降趋势。当 $\mu = 0.42$ 时取得最佳效果，而当 $\mu = 0.50$ 时命中率下降至约 0.70。这表明在空间分布较为分散的数据环境下，适当放宽结构相似度约束有助于保留潜在的真实连接关系，而过高的阈值会导致部分真实协同关系被过滤，进而影响整体命中率。相比之下，北京数据集上的命中率始终稳定在 0.91 以上，且随 μ 的变化波动较小（见图 1-6(a)）。这一现象主要归因于北京数据集更高的轨迹采样密度和更强的空间聚集性。在高密度环境中，即使提高相似度阈值，真实协同行为之间仍能保持较高的结构一致性，因此算法结果对 μ 的敏感度较低，表现出更强的稳定性。

在效率方面（见图 1-6(b) 和图 1-6(d)），两种算法的运行时间均未随 μ 的变化出现显著波动，说明结构相似度阈值主要影响图的连接密度，而对整体计算流程的复杂度影响有限。然而，即便 ES-ECMC 采用多线程实现，其运行时间仍显著高于 CS-ACMC，在两个数据集上均至少相差一个数量级。这表明本文提出的近似协同行为构建策略在降低候选连接数量的同时，有效控制了计算开销。

1.6 本章小结

针对传统协同行为模式定义过于严格、难以适应真实轨迹数据中噪声与不规则性的不足，提出了一种放宽的协同行为模式定义，在保证语义合理性的同时，提高了模型对实际数据的适应能力。

从数据处理模式的角度来看，现有方法可大致分为静态处理与流式处理两类。一些方法（如 [122, 130, 131]）能够处理轨迹数据流，支持持续更新与在线检测；而另一些方法则主要面向离线或静态轨迹数据（如 [118, 119, 125]）。与本文最为相关的工作之一是 Chen 等人 [132] 提出的实时联合移动模式挖掘方法。该方法定义了一种更为通用的联合移动模式，并通过 L -连续性与 G -连通性刻画轨迹之间的时间连续性与结构连通性。然而，由于问题定义存在本质差异，该方法无法直接应用于本文场景：一方面，本文不要求时间上的严格连续性或连通性；另一方面，也不要求对象在每个时间点均属于同一聚类结构；此外，当一个对象能够参与多个群体时，本文采用“成员规模最大优先”的归属策略，以保证结果的不确定性与可解释性。

围绕上述问题，分别设计了精确算法与近似算法。精确算法通过完整枚举与严格验证协同行为对，能够获得理论上的最优结果，但在大规模数据场景下面临较高的时间复杂度。为此，进一步提出了基于结构剪枝与候选压缩策略的近似算法，通过构建紧凑的协同行为图结构，有效减少冗余计算与无效候选，从而在保证

较高命中率的前提下显著降低运行开销。两种算法在设计思路上相互补充：前者保证结果精确性，后者强调规模可扩展性，共同构成了完整的解决方案体系。

在实验评估方面，基于北京与波尔图数据集两个真实世界轨迹数据集，从轨迹数量、协同行为持续时间阈值 k 、群体规模阈值 m 以及结构相似度阈值 μ 等多个维度进行了系统分析。实验结果表明：（1）在不同数据规模下，CS-ACMC 均表现出良好的可扩展性，其运行时间相比 ES-ECMC 至少降低一个数量级；（2）在高密度数据集上，近似算法能够保持稳定且较高的命中率，体现出较强的鲁棒性；（3）参数变化对算法运行时间影响有限，说明主要计算开销集中在协同行为对构建阶段；（4）在不同数据分布特性下，结构相似度与群体规模参数对命中率的影响具有一定差异，进一步验证了方法在多场景下的适应能力。

从应用角度来看，本章研究成果对于交通管理与城市计算具有重要意义。通过对潜在协同行为群体的提前识别，可以辅助分析车队行驶、异常聚集、隐性组织化出行等行为模式，为拥堵预测、路径规划优化以及公共安全监测提供数据支持。同时，所提出的近似建模与剪枝策略也可推广至其他大规模时空模式挖掘任务，具有较强的通用性。

第二章 总结与展望

本章首先对全文进行总结，并分别列出来每个研究内容的贡献创新，然后介绍未来进一步的研究工作。

2.1 全文总结

随着 GPS 设备与智能移动终端的广泛普及，移动对象数据呈现出爆炸式增长，这为城市计算与时空数据挖掘提供了丰富的数据基础，也带来了新的研究挑战。特别是在路径规划、接触搜索、联合移动模式挖掘以及轨迹相似性分析等任务中，如何在大规模、动态且存在观测不确定性的环境下进行高效计算，成为学术界和工业界亟需解决的问题。传统方法往往依赖离散轨迹点或静态路径集合，难以满足实时性、可扩展性及准确性要求，尤其在连续到达的行程请求流或大规模移动对象场景下，其性能和适用性存在明显局限。为应对上述挑战，本文系统研究了面向城市计算的高效算法设计，提出了一系列针对不同场景与任务的算法框架。具体而言，本文涵盖四类核心研究工作：(1) 持续最优路径规划：针对动态路网中持续到达的行程请求流，提出了全局协同优化的路径规划方法，通过将时间窗口内的请求作为整体进行联合优化，实现整体通行效率的提升，有效缓解交通拥堵。(2) 联合移动模式挖掘：面向大规模移动对象轨迹数据，设计了高效的群体模式检测算法，用于高效发现一种宽松的联合移动模式，支持交通管理、拼车推荐及异常行为识别等应用。(3) 接触搜索与疾病传播分析：针对大规模连续轨迹数据，提出可扩展且低延迟的接触搜索方法，通过运动范围建模有效识别潜在接触事件，为公共卫生监测、疫情防控及风险评估提供数据支撑。(4) 轨迹相似连接：提出基于运动范围的交集相似性连接框架，突破传统离散点方法的局限，在稀疏采样或不确定条件下仍能稳健刻画对象间潜在交互关系，适用于交通监控、野生动物迁徙分析及接触追踪等场景。

2.1.1 面向大规模行程请求流的持续最优路线组合规划

首先，本文在“持续最优路线组合规划”章节研究了面向大规模行程请求流的全局协同路径规划问题。该问题的复杂性在于：行程请求以数据流形式持续到达，早期规划结果会影响未来交通状态，不同行程路径通过共享路段形成复杂耦合关系，从而导致组合搜索空间呈指数级增长。传统单次最优路径规划方法无法应对这种持续性、动态性和全局耦合性的挑战，容易在局部最优决策叠加下形成

新的拥堵热点。

为此，本文设计了一种高效的自感知批处理解决方案，用于持续优化行程请求流中的路线组合。解决方案包含两个核心步骤：初始路径搜索与批量优化处理。初始路径搜索步骤为每批新到达的行程请求生成高质量的初始路径组合，以避免潜在交通拥堵；批量优化处理步骤则在初始组合基础上进一步优化所有路径，以最小化总通行时间并提升整体路网效率。

重点研究的内容包括：- 提出了持续最优路线组合问题的形式化模型，明确了其持续性、动态性和全局耦合性的特征；- 设计了自感知批处理算法，实现对新到达请求的在线处理和增量优化；- 构造了基于交通流感知的路径组合存储与剪枝策略，有效缩小搜索空间并提升计算效率。

研究成果和贡献总结如下：- 提出了一种新颖的持续最优路线组合问题模型，适用于城市交通流管理、实时路径规划及拥堵预防等多种应用场景；- 设计了高效的自感知批处理算法及剪枝机制，实现对大规模行程请求流的实时优化，兼顾准确性与计算效率；- 基于真实路网数据开展大量实验，验证了所提方法在总通行时间优化和实时处理能力上的显著优势，相较于基线方法展现出更高的性能和可扩展性。

2.1.2 基于轨迹数据的群体联合移动模式挖掘

其次，本文在“伴随群体发现”章节研究了面向大规模移动对象轨迹的联合移动模式挖掘问题。该问题的复杂性在于：轨迹数据规模庞大，移动对象随时间持续变化，联合移动模式需要在空间邻近性、时间持续性及群体规模约束下进行精确判定；同时，传统模式定义在时间上过于严格，导致候选生成与验证成本极高，尤其在实时或近实时应用场景中难以满足计算效率要求。此外，群体成员可能暂时离开群体并重新加入，历史数据与新到达轨迹间存在强动态依赖，使得模式挖掘具有高度动态性与组合耦合性。

本文设计了一种针对伴随群体的高效挖掘框架。解决方案包含两类核心算法：精确搜索算法（ES-ECMC）和社区感知的近似搜索算法（CS-ACMC）。ES-ECMC 算法基于严格的时空约束判定机制，对候选对象对及群体进行精确验证，保证结果完备性与准确性，适用于离线或中小规模数据场景；CS-ACMC 算法通过近似计算与结构化聚类方法压缩搜索空间，实现高效增量挖掘，满足实时或近实时应用需求。整体解决方案的步骤为：首先在近似联合移动对搜索阶段，通过网格划分将轨迹离散化，并快速估计对象间联合移动程度生成候选对；随后在社区感知群体发现阶段，将候选对构建为图结构并利用社区检测算法进行聚类，从而高效识别伴随群体。

重点研究的内容包括：- 提出了伴随群体这一新的联合移动模式定义，相较于传统模式更加宽松且具实用性，能够容忍对象在时间维度上的暂时缺席，同时保证群体规模与时间持续性约束；- 设计了精确搜索算法（ES-ECMC），在严格判定机制下实现伴随群体的完备发现；- 构造了社区感知的近似搜索算法（CS-ACMC），通过网格离散化、候选压缩及社区聚类方法在大规模数据环境下实现高效挖掘；- 提出了增量处理与滑动窗口机制，使算法能够在持续数据流中高效维护群体模式，实现实时或近实时更新。

研究成果和贡献总结如下：- 首次提出伴随群体模式定义，兼顾空间邻近性、时间持续性与群体规模约束，并适应动态轨迹数据环境，具备广泛应用价值，包括交通监测、疫情防控及公共安全预警等场景；- 系统设计并实现了精确与近似两类算法（ES-ECMC 与 CS-ACMC），有效解决了准确性与效率之间的权衡问题；- 基于真实世界轨迹数据进行了全面实验评估，验证了所提方法在用户可交互时间内高效发现伴随群体的能力，同时展示了在大规模数据环境下的可扩展性与实用性；- 提供了算法开源实现，为后续研究提供复现与扩展基础。

总体而言，本文在理论与实践层面系统研究了伴随群体发现问题，提出了高效、可扩展且具有应用价值的解决方案，为大规模动态轨迹数据环境下的群体行为挖掘提供了新的研究方法与技术工具。

2.1.3 大规模移动对象上的持续密切接触发现

首先，本文在“持续密切接触搜索”章节研究了面向大规模动态移动对象的实时密切接触检测问题。该问题的复杂性在于：轨迹数据以持续流的形式到达，移动对象数量巨大且不断变化，同时需要在空间邻近性与时间持续性约束下实时识别潜在密切接触对象。此外，密切接触具有递归扩展特性，即新发现的接触对象将继续参与后续检测，导致传播链持续增长，增加了算法的计算复杂度与状态维护难度。在突发公共卫生事件或大型人群聚集场景下，若无法高效处理轨迹流，将难以及时识别关键接触节点，从而影响风险控制决策。

本文设计了一种针对持续密切接触搜索（Continuous Exposure Search, CES）问题的高效解决方案。解决方案包含两类核心算法：精确实时搜索算法（Exact Group Processing, EGP）和近似实时搜索算法（Approximate Group Processing, AGP）。EGP 算法通过严格的空间与时间约束判定，对候选对象进行精确验证，保证检测结果的完备性与准确性；AGP 算法在保证不漏检的前提下，通过首尾优先检查、跳跃检测及近似机制显著降低计算量，实现高效实时处理。整体解决方案的步骤为：首先对轨迹对象进行分组过滤，减少候选对象数量；随后基于距离上下界的预检查策略避免不必要的精确距离计算；最后在滑动时间窗口内维护对象间接触状态，实

现持续更新与递归扩展。

重点研究的内容包括：- 提出了持续密切接触搜索（CES）问题的形式化定义，刻画了在大规模动态环境中空间邻近、时间持续与递归传播链的联合约束特性；- 设计了精确实时搜索算法（EGP），通过分组过滤、预检查及状态维护，实现大规模轨迹数据的准确持续检测；- 构造了近似实时搜索算法（AGP），通过可控近似机制与跳跃检测，在保证不漏检的前提下大幅提升处理效率；- 提出滑动窗口增量更新策略，使算法能够在持续轨迹流中高效维护密切接触集合，实现实时响应与可扩展性。

研究成果和贡献总结如下：- 形式化定义了持续密切接触搜索问题，为流行病传播监测、公共卫生预警及风险追踪提供统一的数据处理框架，明确了递归扩展与实时更新特性；- 系统设计并实现了精确与近似两类实时处理算法（EGP 与 AGP），结合分组过滤、预检查及跳跃检测等优化策略，有效解决了准确性与效率之间的权衡难题；- 在两个真实世界轨迹数据集上进行了全面实验评估，结果表明所提出方法在保证检测精度的同时，实现了大规模动态场景下的高效实时密切接触检测，展现出良好的可扩展性与稳定性。

总体而言，本文系统研究了持续密切接触搜索问题，提出了高效、可扩展且具有应用价值的解决方案，为大规模流式轨迹数据环境下的实时疫情监控与风险管理提供了新的技术方法与实践参考。

2.1.4 面向时空运动范围的轨迹相似度连接

本文研究了移动对象相似性连接问题中的一个关键挑战——在稀疏采样条件下如何准确刻画对象间潜在交互关系。传统基于离散采样点的相似性度量方法在对象轨迹采样频率不足或存在观测缺失时容易低估真实相似性，导致潜在对象对被误剪枝。为解决这一问题，本文提出了交集相似性连接（Intersection Similarity Join, IS-Join）问题，通过引入“运动范围”概念，将对象在相邻观测样本之间可能到达的空间区域建模为运动范围，并基于这些区域的交集程度进行相似性度量，从而在稀疏采样或数据噪声条件下更稳健地刻画潜在交互。

IS-Join 问题在多个实际场景中具有重要应用价值。例如，在城市交通监测中，车辆轨迹的运动范围可映射为道路子路段或交叉口集合，通过交集相似性识别潜在交通关联，有助于拥堵预测与异常路段识别；在野生动物迁徙分析中，运动范围结合栖息地与迁徙通道信息，可识别共享走廊或高频活动区域，实现低采样频率下的关键交互检测；在公共卫生领域，个体潜在接触事件可通过运动范围交集推断，从而支持疾病传播建模与风险评估。不同应用虽对象类型与特征不同，但核心需求均为在观测不确定条件下识别潜在运动交集关系，IS-Join 提供了统一且可

扩展的解决框架。

在建模与计算上，IS-Join 的关键创新包括：首先，明确将相似性度量从离散点级距离扩展到连续时间下的区域交集，允许在理论上处理未观测时间段的潜在交互；其次，将连续时间区间内的交集相似性定义为时间平均函数，既保留连续性信息，又便于离散化近似计算。该建模显著提升了稀疏采样条件下潜在对象对识别能力，同时引入连续时间处理与大规模候选对计算的两大挑战：一是连续时间计算的复杂性，需设计可计算的离散化或可控近似方法；二是高效连接的挑战，现有点或静态区域相似性算法无法直接支持连续时间运动范围的交集计算，否则候选对象对数量会急剧膨胀。

为应对上述挑战，本文提出了基于时间区间运动范围的高效求解框架。核心思想是通过混合 Ball-tree (HBall-tree) 索引对对象运动范围进行层次化组织，并结合重划分策略与多级剪枝技术，有效过滤候选对象对，从而在保证正确性与完整性的前提下显著降低计算开销。该框架适用于稀疏采样轨迹数据，能够高效识别满足相似性阈值的对象对，实现连续时间区间下的交集相似性计算。

本文的主要贡献可概括为三点：1. **问题建模创新**：提出交集相似性连接 (IS-Join) 问题，将相似性度量从离散点扩展到连续时间下的运动范围交集，显著增强稀疏采样轨迹潜在交互建模能力。2. **高效求解框架设计**：构建 HBall-tree 层次索引结构，并结合重划分与多级剪枝策略，实现大规模连续时间区间下的高效连接计算。3. **系统化实验验证**：在真实世界数据集上进行评估，结果表明方法在保证准确性的前提下，相较于现有基线方法平均运行时间降低约 3 倍，验证了算法的可扩展性与实用价值。

总之，本文针对稀疏采样轨迹数据中潜在运动交集关系的识别提出了统一建模与高效计算框架，为交通分析、生态监测及公共卫生等多种实际场景提供了可行且高效的技术方案。

2.2 展望

本文针对面向大规模行程请求流的持续最优路线组合规划需求，基于轨迹数据的群体联合移动模式挖掘需求，面向大规模移动对象的持续密切接触查询需求，以及面向时空运动范围的轨迹相似度连接需求展开了深入研究，发表了一系列研究成果，但仍存在一些值得进一步研究和探索的空间。随着移动对象数据规模和实时更新频率的持续增长，单机处理在计算能力与内存资源上面临显著瓶颈。未来可能的进一步研究方向可以向分布式环境、深度学习优化、时空大模型拓展，潜在研究方向包括：

- **分布式时空-文本连续查询。**针对大规模移动对象或位置标注数据，当数据量超出单机处理能力时，可在分布式框架（如 Hadoop、Spark）中研究并行化的索引机制和查询算法。研究重点可包括：分布式时空-文本索引结构设计，以支持跨节点高效定位潜在交互对象；面向海量时空-文本数据的并行查询架构，优化任务调度与负载均衡；以及分布式数据迁移与副本管理策略，以保证连续查询过程中的数据一致性与高可用性。在分布式环境下，将交集相似性连接（IS-Join）或连续密切接触搜索（CES）等计算任务进行分片处理，同时保持跨节点候选对象的完整性与准确性，是提高系统可扩展性与实时性的重要方向。相关研究可包括分布式滑动窗口维护、跨节点运动范围交集计算以及并行剪枝策略设计。分布式处理环境中，节点故障、网络延迟及数据倾斜可能导致查询性能下降。未来可探索自适应任务调度、容错恢复机制以及数据划分优化方法，以保障大规模连续时空查询的稳定性与效率。
- **基于深度学习的方法优化。**随着移动对象数据的持续增长与复杂化，传统基于规则或索引的算法在处理大规模、动态、多源数据时面临性能和可扩展性瓶颈。深度学习技术因其强大的表示学习和模式捕捉能力，为未来时空数据分析与连续查询提供了新的研究契机。具体而言，潜在的研究方向可包括以下几个方面：（1）在大规模行程请求流场景下，如何为海量移动对象实时生成最优路线组合是关键问题。深度强化学习可用于建模连续决策过程，将路线选择、时间窗口约束和交通动态因素作为状态与奖励函数，实现高效、可扩展的路径优化。通过结合历史轨迹数据与实时交通信息，模型可学习群体行程模式，从而在动态环境中提供持续优化的路线方案。（2）群体行为分析和联合移动模式识别在城市规划、公共交通调度及疫情传播监控中具有重要意义。深度学习方法，如图神经网络（GNN）或时空卷积网络（STCN），可以将移动对象及其轨迹视为时空图结构或序列数据，从而自动捕捉潜在的群体协同行为、同步移动模式及关键影响节点，实现对复杂群体行为的高效挖掘。（3）持续密切接触（Continuous Exposure）检测涉及大规模对象在动态环境下的空间邻近与时间连续性判定。深度学习模型可通过学习对象轨迹的潜在运动分布和邻近概率，实现对未观测时间段潜在接触的预测，从而在海量数据流环境下支持实时、鲁棒的密切接触检测。结合序列建模（如 LSTM、Transformer）与空间嵌入方法，可以有效提升接触预测的精度与响应速度。（4）在稀疏采样轨迹或不完整数据条件下，基于传统规则的运动范围交集计算容易受限。深度表示学习可通过将轨迹映射到低维时空潜在空间，捕捉连续时间区间内的潜在重叠关系，从而高

效完成交集相似性连接。此外，生成式模型（如变分自编码器或时空 GAN）可以辅助补全未观测轨迹，进一步增强相似性连接的准确性与鲁棒性。

- **时空大模型设计。**未来可以构建一个统一的时空大模型框架，将轨迹数据分析、群体联合移动模式挖掘、持续密切接触查询以及轨迹相似度连接等任务整合在同一平台中。该框架可通过深度学习方法实现统一时空表示，将多源轨迹、行为和环境信息映射到低维潜在空间，从而支持个体轨迹预测、群体模式识别、实时接触检测和交集相似性计算。针对大规模和高频数据，可在分布式计算环境下进行流式处理与增量模型更新，实现高效并行计算与实时响应。同时，框架可提供统一接口与查询语义，便于不同应用场景快速接入，包括智能交通、公共卫生监控和生态保护等。结合可解释性和隐私保护技术，系统既能输出可理解的决策依据，又保障个体数据安全。整体来看，该统一时空大模型有望通过深度学习和大数据优化，实现跨任务、跨数据源的高效、实时和可扩展时空智能分析。

致 谢

本论文的完成，凝聚了诸多师长、亲友和同窗的关心与帮助。值此论文付梓之际，谨向所有给予我支持与帮助的人致以最诚挚的感谢。

本研究及学位论文是在我的导师商烁教授的亲切关怀和悉心指导下完成的。商老师严谨求实的治学态度、敏锐深刻的学术洞察力以及精益求精的科研精神，始终激励着我不断进步。在论文选题、研究思路构建、关键技术突破以及论文整体结构把握等方面，商老师都给予了我耐心细致的指导。每一次讨论都让我受益匪浅，使我在学术视野与研究能力上不断提升。老师不仅在科研上给予我悉心培养，也在思想和生活上给予我关怀与支持，使我在攻读博士学位的过程中始终保持坚定与从容。在此谨向商烁教授致以最诚挚的谢意和崇高的敬意。

衷心感谢我的副导师陈力思教授。陈老师在科研方法、论文写作以及学术表达方面给予了我重要指导。在论文撰写与修改过程中，陈老师多次提出宝贵意见，从整体框架到细节表述均给予认真审阅与精心修改，使论文更加严谨和完善。每当科研工作遇到困难时，陈老师都耐心分析问题、指引方向，使我能够理清思路、稳步推进研究工作。在此谨向陈力思教授表示衷心的感谢与敬意。

感谢学院与实验室为我提供良好的科研环境与学术氛围。浓厚的学术交流氛围和开放包容的研究环境，使我能够专注于学术探索，不断拓展研究视野。感谢实验室的各位老师们在学术讨论中的启发与帮助，感谢师兄师姐、师弟师妹以及同窗好友在学习与生活中的支持与陪伴。与大家并肩奋斗的时光，是我博士生涯中最宝贵的记忆之一。

同时，感谢论文中所引用文献的作者们，他们严谨而卓越的研究成果为本论文奠定了重要的理论基础，使我得以在前人工作的基础上不断探索与创新。

最后，我要特别感谢我的父母和家人。无论在顺境还是逆境，你们始终给予我理解、包容与坚定的支持，是我坚持学术道路最坚实的后盾。你们无私的付出与默默的守护，使我能够心无旁骛地完成学业。未来我将以更加努力的工作与生活来回报你们的关爱与期望。

谨以此文，向所有关心、帮助和支持过我的师长、亲友和同学们致以最诚挚的感谢！

参考文献

- [1] Li K, Chen L, Shang S, et al. Traffic congestion alleviation over dynamic road networks: Continuous optimal route combination for trip query streams[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3656–3662.
- [2] Li K, Chen L, Shang S. Towards alleviating traffic congestion: Optimal route planning for massive-scale trips[C]. IJCAI, ijcai.org, 2020: 3400–3406.
- [3] Chen L, Shang S, Jensen C S, et al. Effective and efficient reuse of past travel behavior for route recommendation[C]. KDD, ACM, 2019: 488–498.
- [4] Chen L, Shang S, Guo T. Real-time route search by locations[C]. AAAI, AAAI Press, 2020: 574–581.
- [5] Chen L, Shang S, Yao B, et al. Pay your trip for traffic congestion: Dynamic pricing in traffic-aware road networks[C]. AAAI, AAAI Press, 2020: 582–589.
- [6] Shang S, Ding R, Yuan B, et al. User oriented trajectory search for trip recommendation[C]. 15th International Conference on Extending Database Technology, EDBT '12, Berlin, Germany, March 27-30, 2012, Proceedings, ACM, 2012: 156–167.
- [7] Liu K, Li Y, Ding Z, et al. Benchmarking big data for trip recommendation[C]. ICCCN, IEEE, 2014: 1–6.
- [8] Shang S, Guo D, Liu J, et al. Prediction-based unobstructed route planning[J]. Neurocomputing, 2016, 213: 147–154.
- [9] Han P, Wang J, Yao D, et al. A graph-based approach for trajectory similarity computation in spatial networks[C]. KDD, ACM, 2021: 556–564.
- [10] Yang C, Chen L, Wang H, et al. Towards efficient selection of activity trajectories based on diversity and coverage[C]. AAAI, AAAI Press, 2021: 689–696.
- [11] Chen L, Shang S, Feng S, et al. Parallel subtrajectory alignment over massive-scale trajectory data[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3613–3619.
- [12] Shang S, Ding R, Zheng K, et al. Personalized trajectory matching in spatial networks[J]. VLDB J., 2014, 23(3): 449–468.
- [13] Shang S, Zheng K, Jensen C S, et al. Discovery of path nearby clusters in spatial networks[J]. TKDE, 2015, 27(6): 1505–1518.
- [14] Shang S, Chen L, Jensen C S, et al. Searching trajectories by regions of interest[J]. TKDE, 2017, 29(7): 1549–1562.

- [15] Shang S, Chen L, Wei Z, et al. Trajectory similarity join in spatial networks[J]. *Proc. VLDB Endow.*, 2017, 10(11): 1178–1189.
- [16] Shang S, Chen L, Wei Z, et al. Parallel trajectory similarity joins in spatial networks[J]. *VLDB J.*, 2018, 27(3): 395–420.
- [17] Chen L, Shang S, Jensen C S, et al. Parallel semantic trajectory similarity join[C]. *ICDE, IEEE*, 2020: 997–1008.
- [18] Zhao Y, Shang S, Wang Y, et al. REST: A reference-based framework for spatio-temporal trajectory compression[C]. Guo Y, Farooq F, (Eds.) *SIGMOD, ACM*, 2018: 2797–2806.
- [19] Liu J, Zhao K, Sommer P, et al. A novel framework for online amnesic trajectory compression in resource-constrained environments[J]. *IEEE Trans. Knowl. Data Eng.*, 2016, 28(11): 2827–2841.
- [20] Liu J, Zhao K, Sommer P, et al. Bounded quadrant system: Error-bounded trajectory compression on the go[C]. Gehrke J, Lehner W, Shim K, et al., (Eds.) *ICDE, IEEE Computer Society*, 2015: 987–998.
- [21] Shang S, Yuan B, Deng K, et al. PNN query processing on compressed trajectories[J]. *GeoInformatica*, 2012, 16(3): 467–496.
- [22] Chen L, Shang S, Yang C, et al. Spatial keyword search: a survey[J]. *GeoInformatica*, 2020, 24(1): 85–106.
- [23] Wilkie D, Baykal C, Lin M C. Participatory route planning[C]. *SIGSPATIAL/GIS, ACM*, 2014: 213–222.
- [24] Ding B, Yu J X, Qin L. Finding time-dependent shortest paths over large graphs[C]. *EDBT, ACM*, vol. 261 of *ACM International Conference Proceeding Series*, 2008: 205–216.
- [25] Kanoulas E, Du Y, Xia T, et al. Finding fastest paths on A road network with speed patterns[C]. *ICDE, IEEE Computer Society*, 2006: 10.
- [26] Wang Y, Li G, Tang N. Querying shortest paths on time dependent road networks[J]. *Proc. VLDB Endow.*, 2019, 12(11): 1249–1261.
- [27] Xu J, Guo L, Ding Z, et al. Traffic aware route planning in dynamic road networks[C]. *DASFAA (1), Springer*, vol. 7238 of *Lecture Notes in Computer Science*, 2012: 576–591.
- [28] Shang S, Liu J, Zheng K, et al. Planning unobstructed paths in traffic-aware spatial networks[J]. *GeoInformatica*, 2015, 19(4): 723–746.
- [29] Wilkie D, van den Berg J P, Lin M C, et al. Self-aware traffic route planning[C]. *Proceedings of the Twenty-Fifth AAAI Conference on Artificial Intelligence, AAAI 2011, San Francisco, California, USA, August 7-11, 2011, AAAI Press*.

-
- [30] Sistla A P, Wolfson O, Chamberlain S, et al. Modeling and querying moving objects[C]. ICDE, 1997: 422–432.
 - [31] Patel J M, Chen Y, Chakka V P. STRIPES: an efficient index for predicted trajectories[C]. SIGMOD, 2004: 637–646.
 - [32] Saltenis S, Jensen C S, Leutenegger S T, et al. Indexing the positions of continuously moving objects[C]. SIGMOD, 2000: 331–342.
 - [33] Ding Y, Zhou X, Wu G, et al. Mining spatio-temporal reachable regions with multiple sources over massive trajectory data[J]. IEEE Trans. Knowl. Data Eng., 2021, 33(7): 2930–2942.
 - [34] Bakalov P, Hadjieleftheriou M, Keogh E J, et al. Efficient trajectory joins using symbolic representations[C]. Chrysanthis P K, Samaras G, (Eds.) MDM, ACM, 2005: 86–93.
 - [35] Yi B, Faloutsos C. Fast time sequence indexing for arbitrary lp norms[C]. VLDB, Morgan Kaufmann, 2000: 385–394.
 - [36] Dijkstra E W. A note on two problems in connexion with graphs[J]. Numerische Mathematik, 1959, 1: 269–271.
 - [37] Likhachev M, Ferguson D I, Gordon G J, et al. Anytime dynamic a*: An anytime, replanning algorithm[C]. ICAPS, AAAI, 2005: 262–271.
 - [38] Cai X, Kloks T, Wong C K. Time-varying shortest path problems with constraints[J]. Networks, 1997, 29(3): 141–150.
 - [39] Narváez P, Siu K, Tzeng H. New dynamic SPT algorithm based on a ball-and-string model[J]. IEEE/ACM Trans. Netw., 2001, 9(6): 706–718.
 - [40] Malviya N, Madden S, Bhattacharya A. A continuous query system for dynamic route planning[C]. ICDE, IEEE Computer Society, 2011: 792–803.
 - [41] Yang B, Guo C, Ma Y, et al. Toward personalized, context-aware routing[J]. VLDB J., 2015, 24(2): 297–318.
 - [42] Guo C, Yang B, Hu J, et al. Context-aware, preference-based vehicle routing[J]. VLDB J., 2020, 29(5): 1149–1170.
 - [43] Letchner J, Krumm J, Horvitz E. Trip router with individualized preferences (TRIP): incorporating personalization into route planning[C]. AAAI, AAAI Press, 2006: 1795–1800.
 - [44] Balteanu A, Jossé G, Schubert M. Mining driving preferences in multi-cost networks[C]. SSTD, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 74–91.
 - [45] Lim S, Balakrishnan H, Gifford D, et al. Stochastic motion planning and applications to traffic[J]. Int. J. Robotics Res., 2011, 30(6): 699–712.
 - [46] Yang B, Guo C, Jensen C S, et al. Stochastic skyline route planning under time-varying uncertainty[C]. ICDE, IEEE Computer Society, 2014: 136–147.

- [47] Pedersen S A, Yang B, Jensen C S. Anytime stochastic routing with hybrid learning[J]. *Proc. VLDB Endow.*, 2020, 13(9): 1555–1567.
- [48] Hua M, Pei J. Probabilistic path queries in road networks: traffic uncertainty aware path selection[C]. *EDBT*, ACM, vol. 426 of ACM International Conference Proceeding Series, 2010: 347–358.
- [49] Ge Y, Xiong H, Tuzhilin A, et al. An energy-efficient mobile recommender system[C]. *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Washington, DC, USA, July 25-28, 2010, ACM, 2010: 899–908.
- [50] Huang J, Huangfu X, Sun H, et al. Backward path growth for efficient mobile sequential recommendation[J]. *IEEE Trans. Knowl. Data Eng.*, 2015, 27(1): 46–60.
- [51] Ye Z, Xiao K, Deng Y. A unified theory of the mobile sequential recommendation problem[C]. *IEEE International Conference on Data Mining, ICDM 2018*, Singapore, November 17-20, 2018, IEEE Computer Society, 2018: 1380–1385.
- [52] Ye Z, Xiao K, Ge Y, et al. Applying simulated annealing and parallel computing to the mobile sequential recommendation[J]. *IEEE Trans. Knowl. Data Eng.*, 2019, 31(2): 243–256.
- [53] Ye Z, Zhang L, Xiao K, et al. Multi-user mobile sequential recommendation: An efficient parallel computing paradigm[C]. *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD 2018*, London, UK, August 19-23, 2018, ACM, 2018: 2624–2633.
- [54] Chen Z, Shen H T, Zhou X, et al. Searching trajectories by locations: an efficiency study[C]. *SIGMOD Conference*, ACM, 2010: 255–266.
- [55] Zheng K, Shang S, Yuan N J, et al. Towards efficient search for activity trajectories[C]. Jensen C S, Jermaine C M, Zhou X, (Eds.) *29th IEEE International Conference on Data Engineering, ICDE 2013*, Brisbane, Australia, April 8-12, 2013, IEEE Computer Society, 2013: 230–241.
- [56] Shang S, Lu H, Pedersen T B, et al. Finding traffic-aware fastest paths in spatial networks[C]. *SSTD*, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 128–145.
- [57] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[C]. *ICDE*, IEEE Computer Society, 2017: 59–60.
- [58] Li R, Qin L, Yu J X, et al. Optimal multi-meeting-point route search[J]. *IEEE Trans. Knowl. Data Eng.*, 2016, 28(3): 770–784.
- [59] Reza R M, Ali M E, Cheema M A. The optimal route and stops for a group of users in a road network[C]. *Proceedings of the 25th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, GIS 2017*, Redondo Beach, CA, USA, November 7-10, 2017, ACM, 2017: 4:1–4:10.

- [60] Hashem T, Hashem T, Ali M E, et al. Group trip planning queries in spatial databases[C]. *Advances in Spatial and Temporal Databases - 13th International Symposium, SSTD 2013, Munich, Germany, August 21-23, 2013. Proceedings*, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 259–276.
- [61] Hashem T, Barua S, Ali M E, et al. Efficient computation of trips with friends and families[C]. *Proceedings of the 24th ACM International Conference on Information and Knowledge Management, CIKM 2015, Melbourne, VIC, Australia, October 19 - 23, 2015*, ACM, 2015: 931–940.
- [62] Lim S, Rus D. Stochastic distributed multi-agent planning and applications to traffic[C]. *ICRA*, IEEE, 2012: 2873–2879.
- [63] Zeng Y, Tong Y, Song Y, et al. The simpler the better: An indexing approach for shared-route planning queries[J]. *Proc. VLDB Endow.*, 2020, 13(13): 3517–3530.
- [64] Zheng L, Chen L, Ye J. Order dispatch in price-aware ridesharing[J]. *Proc. VLDB Endow.*, 2018, 11(8): 853–865.
- [65] Li F, Cheng D, Hadjieleftheriou M, et al. On trip planning queries in spatial databases[C]. *SSTD*, Springer, vol. 3633 of Lecture Notes in Computer Science, 2005: 273–290.
- [66] Sharifzadeh M, Kolahdouzan M R, Shahabi C. The optimal sequenced route query[J]. *VLDB J.*, 2008, 17(4): 765–787.
- [67] Cao X, Chen L, Cong G, et al. Keyword-aware optimal route search[J]. *Proc. VLDB Endow.*, 2012, 5(11): 1136–1147.
- [68] Yao B, Tang M, Li F. Multi-approximate-keyword routing in GIS data[C]. *GIS*, ACM, 2011: 201–210.
- [69] Zheng B, Su H, Hua W, et al. Efficient clue-based route search on road networks[J]. *IEEE Trans. Knowl. Data Eng.*, 2017, 29(9): 1846–1859.
- [70] Wen Y T, Yeo J, Peng W, et al. Efficient keyword-aware representative travel route recommendation[J]. *IEEE Trans. Knowl. Data Eng.*, 2017, 29(8): 1639–1652.
- [71] Li W, Cao J, Guan J, et al. Efficient retrieval of bounded-cost informative routes[C]. *ICDE*, IEEE Computer Society, 2018: 1811–1812.
- [72] Jossé G, Schmid K A, Schubert M. Probabilistic resource route queries with reappearance[C]. *Proceedings of the 18th International Conference on Extending Database Technology, EDBT 2015, Brussels, Belgium, March 23-27, 2015*, OpenProceedings.org, 2015: 445–456.
- [73] Christofides N. Worst-case analysis of a new heuristic for the traveling salesman problem[J]. 1976.

- [74] Zhang C, Liang H, Wang K, et al. Personalized trip recommendation with POI availability and uncertain traveling time[C]. Proceedings of the 24th ACM International Conference on Information and Knowledge Management, CIKM 2015, Melbourne, VIC, Australia, October 19 - 23, 2015, ACM, 2015: 911–920.
- [75] Yawalkar P, Ranu S. Route recommendations on road networks for arbitrary user preference functions[C]. ICDE, IEEE, 2019: 602–613.
- [76] Ma X, Shekhar S, Xiong H, et al. Exploiting a page-level upper bound for multi-type nearest neighbor queries[C]. GIS, ACM, 2006: 179–186.
- [77] Chen H, Ku W, Sun M, et al. The multi-rule partial sequenced route query[C]. GIS, ACM, 2008: 10.
- [78] Chen H, Ku W, Sun M, et al. The partial sequenced route query with traveling rules in road networks[J]. GeoInformatica, 2011, 15(3): 541–569.
- [79] Li J, Yang Y D, Mamoulis N. Optimal route queries with arbitrary order constraints[J]. IEEE Trans. Knowl. Data Eng., 2013, 25(5): 1097–1110.
- [80] Sharifzadeh M, Shahabi C. Processing optimal sequenced route queries using voronoi diagrams[J]. GeoInformatica, 2008, 12(4): 411–433.
- [81] Zeng Y, Chen X, Cao X, et al. Optimal route search with the coverage of users' preferences[C]. IJCAI, AAAI Press, 2015: 2118–2124.
- [82] Li Y, Yang W, Dan W, et al. Keyword-aware dominant route search for various user preferences[C]. Database Systems for Advanced Applications - 20th International Conference, DAS-FAA 2015, Hanoi, Vietnam, April 20-23, 2015, Proceedings, Part II, Springer, vol. 9050 of Lecture Notes in Computer Science, 2015: 207–222.
- [83] Kanza Y, Safra E, Sagiv Y, et al. Heuristic algorithms for route-search queries over geographical data[C]. GIS, ACM, 2008: 11.
- [84] Lu E H, Lin C, Tseng V S. Trip-mine: An efficient trip planning approach with travel time constraints[C]. Mobile Data Management (1), IEEE Computer Society, 2011: 152–161.
- [85] Kanza Y, Levin R, Safra E, et al. An interactive approach to route search[C]. GIS, ACM, 2009: 408–411.
- [86] Levin R, Kanza Y, Safra E, et al. Interactive route search in the presence of order constraints[J]. Proc. VLDB Endow., 2010, 3(1): 117–128.
- [87] Roy S B, Das G, Amer-Yahia S, et al. Interactive itinerary planning[C]. ICDE, IEEE Computer Society, 2011: 15–26.

-
- [88] Fan L, Bonomi L, Shahabi C, et al. Multi-user itinerary planning for optimal group preference[C]. *Advances in Spatial and Temporal Databases - 15th International Symposium, SSTD 2017, Arlington, VA, USA, August 21-23, 2017, Proceedings*, Springer, vol. 10411 of *Lecture Notes in Computer Science*, 2017: 3–23.
- [89] Fan L, Bonomi L, Shahabi C, et al. Optimal group route query: Finding itinerary for group of users in spatial databases[J]. *GeoInformatica*, 2018, 22(4): 845–867.
- [90] Levin R, Kanza Y. TARS: traffic-aware route search[J]. *GeoInformatica*, 2014, 18(3): 461–500.
- [91] Salgado C, Cheema M A, Taniar D. An efficient approximation algorithm for multi-criteria indoor route planning queries[C]. *SIGSPATIAL/GIS*, ACM, 2018: 448–451.
- [92] Feng Z, Liu T, Li H, et al. Indoor top-k keyword-aware routing query[C]. *ICDE*, IEEE, 2020: 1213–1224.
- [93] Agrawal R, Faloutsos C, Swami A N. Efficient similarity search in sequence databases[C]. *FODO*, Springer, vol. 730 of *Lecture Notes in Computer Science*, 1993: 69–84.
- [94] Yi B, Jagadish H V, Faloutsos C. Efficient retrieval of similar time sequences under time warping[C]. *Proceedings of the Fourteenth International Conference on Data Engineering*, Orlando, Florida, USA, February 23-27, 1998, IEEE Computer Society, 1998: 201–208.
- [95] Vlachos M, Gunopulos D, Kollios G. Discovering similar multidimensional trajectories[C]. *Proceedings of the 18th International Conference on Data Engineering*, San Jose, CA, USA, February 26 - March 1, 2002, IEEE Computer Society, 2002: 673–684.
- [96] Chen L, Ng R T. On the marriage of lp-norms and edit distance[C]. (e)*Proceedings of the Thirtieth International Conference on Very Large Data Bases, VLDB 2004*, Toronto, Canada, August 31 - September 3 2004, Morgan Kaufmann, 2004: 792–803.
- [97] Chen L, Özsu M T, Oria V. Robust and fast similarity search for moving object trajectories[C]. *Proceedings of the ACM SIGMOD International Conference on Management of Data*, Baltimore, Maryland, USA, June 14-16, 2005, ACM, 2005: 491–502.
- [98] Ranu S, P D, Telang A D, et al. Indexing and matching trajectories under inconsistent sampling rates[C]. *ICDE*, IEEE Computer Society, 2015: 999–1010.
- [99] Su H, Zheng K, Wang H, et al. Calibrating trajectory data for similarity-based analysis[C]. *SIGMOD*, ACM, 2013: 833–844.
- [100] Perng C, Wang H, Zhang S R, et al. Landmarks: a new model for similarity-based pattern querying in time series databases[C]. *Proceedings of the 16th International Conference on Data Engineering*, San Diego, California, USA, February 28 - March 3, 2000, IEEE Computer Society, 2000: 33–42.

- [101] Chen Y, Nascimento M A, Ooi B C, et al. Spade: On shape-based pattern detection in streaming time series[C]. Chirkova R, Dogac A, Özsu M T, et al., (Eds.) Proceedings of the 23rd International Conference on Data Engineering, ICDE 2007, The Marmara Hotel, Istanbul, Turkey, April 15-20, 2007, IEEE Computer Society, 2007: 786–795.
- [102] Li X, Zhao K, Cong G, et al. Deep representation learning for trajectory similarity computation[C]. ICDE, IEEE Computer Society, 2018: 617–628.
- [103] Yao D, Cong G, Zhang C, et al. Computing trajectory similarity in linear time: A generic seed-guided neural metric learning approach[C]. ICDE, IEEE, 2019: 1358–1369.
- [104] Chen Y, Patel J M. Design and evaluation of trajectory join algorithms[C]. 17th ACM SIGSPATIAL International Symposium on Advances in Geographic Information Systems, Washington, USA: ACM, 2009: 266–275.
- [105] Tampakis P, Doukeridis C, Pelekis N, et al. Distributed subtrajectory join on massive datasets[J]. ACM Trans. Spatial Algorithms Syst., 2020, 6(2): 8:1–8:29.
- [106] Li H, Li G, Liu J, et al. Ratel: Interactive analytics for large scale trajectories[C]. Proceedings of the 2019 International Conference on Management of Data, 2019: 1949–1952.
- [107] Shang Z, Li G, Bao Z. Dita: Distributed in-memory trajectory analytics[J]. Proceedings of the 2018 International Conference on Management of Data, 2018: 725–740.
- [108] Yuan H, Li G. Distributed in-memory trajectory similarity search and join on road network[J]. ICDE, 2019: 1262-1273.
- [109] Li K, Chen L, Shang S, et al. Towards controlling the transmission of diseases: Continuous exposure discovery over massive-scale moving objects[C]. IJCAI, 2022: 3891–3897.
- [110] Shang S, Chen L, Wei Z, et al. Trajectory similarity join in spatial networks[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1178-1189.
- [111] Chen L, Shang S, Jensen C S, et al. Parallel semantic trajectory similarity join[J]. ICDE, 2020: 997-1008.
- [112] Pan Z, Chao P, Fang J, et al. Trasp: A general framework for online trajectory similarity processing[C]. WISE, Springer, 2020: 384–397.
- [113] Atev S, Miller G, Papanikolopoulos N. Clustering of vehicle trajectories[J]. IEEE Transactions on Intelligent Transportation Systems, 2010, 11: 647-657.
- [114] Yi B K, Jagadish H V, Faloutsos C. Efficient retrieval of similar time sequences under time warping[C]. ICDE, IEEE, 1998: 201–208.
- [115] Vlachos M, Kollios G, Gunopulos D. Discovering similar multidimensional trajectories[C]. ICDE, IEEE, 2002: 673–684.

-
- [116] Fang Z, Gong S, Chen L, et al. Ghost: A general framework for high-performance online similarity queries over distributed trajectory streams[C]. Proceedings of the ACM on Management of Data, vol. 1, 2023: 1 - 25.
 - [117] Ding Z, Li K, Chen L, et al. Parallel online similarity join over trajectory streams[C]. Proceedings of the ACM on Web Conference 2025, 2025: 3426–3437.
 - [118] Jeung H, Yiu M L, Zhou X, et al. Discovery of convoys in trajectory databases[J]. Proc. VLDB Endow., 2008, 1(1): 1068–1080.
 - [119] Li Z, Ding B, Han J, et al. Swarm: Mining relaxed temporal moving object clusters[J]. Proc. VLDB Endow., 2010, 3(1): 723–734.
 - [120] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. 17th ACM SIGSPATIAL International Symposium on Advances in Geographic Information Systems, ACM-GIS 2009, ACM, 2009: 286–295.
 - [121] Tang L, Zheng Y, Yuan J, et al. On discovery of traveling companions from streaming trajectories[C]. IEEE 28th International Conference on Data Engineering (ICDE 2012), IEEE Computer Society, 2012: 186–197.
 - [122] Zheng K, Zheng Y, Yuan N J, et al. On discovery of gathering patterns from trajectories[C]. ICDE, IEEE Computer Society, 2013: 242–253.
 - [123] Wang Y, Lim E, Hwang S. Efficient mining of group patterns from user movement data[J]. Data Knowl. Eng., 2006, 57(3): 240–282.
 - [124] Li Y, Bailey J, Kulik L. Efficient mining of platoon patterns in trajectory databases[J]. Data Knowl. Eng., 2015, 100: 167–187.
 - [125] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. GIS, ACM, 2009: 286–295.
 - [126] Tanaka P S, Vieira M R, Kaster D S. An improved base algorithm for online discovery of flock patterns in trajectories[J]. J. Inf. Data Manag., 2016, 7(1): 52–67.
 - [127] Fan Q, Zhang D, Wu H, et al. A general and parallel platform for mining co-movement patterns over large-scale trajectories[J]. Proc. VLDB Endow., 2016, 10(4): 313–324.
 - [128] Naserian E, Wang X, Xu X, et al. Discovery of loose travelling companion patterns from human trajectories[C]. HPCC, IEEE Computer Society, 2016: 1238–1245.
 - [129] Shein T T, Puntheeranurak S, Imamura M. Discovery of loose group companion from trajectory data streams[J]. IEEE Access, 2020, 8: 85856–85868.
 - [130] Zheng K, Zheng Y, Yuan N J, et al. Online discovery of gathering patterns over trajectories[J]. TKDE, 2014, 26(8): 1974–1988.

- [131] Fang Z, Gao Y, Pan L, et al. Coming: A real-time co-movement mining system for streaming trajectories[C]. Maier D, Pottinger R, Doan A, et al., (Eds.) SIGMOD, ACM, 2020: 2777–2780.
- [132] Chen L, Gao Y, Fang Z, et al. Real-time distributed co-movement pattern detection on streaming trajectories[J]. Proc. VLDB Endow., 2019, 12(10): 1208–1220.
- [133] Liu Y, Zhao K, Cong G, et al. Online anomalous trajectory detection with deep generative sequence modeling[C]. ICDE, IEEE, 2020: 949–960.
- [134] Zhao Y, Chen Q, Cao W, et al. Deep learning for risk detection and trajectory tracking at construction sites[J]. IEEE Access, 2019, 7: 30905–30912.
- [135] Eusuf S S, Islam K A, Ali M E, et al. A web-based system for efficient contact tracing query in a large spatio-temporal database[C]. SIGSPATIAL '20: 28th International Conference on Advances in Geographic Information Systems, ACM, 2020: 473–476.
- [136] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying "infected" moving objects[J]. Proc. VLDB Endow., 2020, 13(12): 2825–2828.
- [137] He H, Li R, Wang R, et al. Efficient suspected infected crowds detection based on spatio-temporal trajectories[J]. CoRR, 2020, abs/2004.06653. 2004.06653.
- [138] Chao P, He D, Li L, et al. Efficient trajectory contact query processing[C]. DASFAA, 2021: 658–666.
- [139] Alarabi L, Basalamah S M, Hendawi A M, et al. Traceall: A real-time processing for contact tracing using indoor trajectories[J]. Inf., 2021, 12(5): 202.
- [140] Zhang Y, Liu A, Liu G, et al. Deep representation learning of activity trajectory similarity computation[C]. ICWS, IEEE, 2019: 312–319.
- [141] Yao D, Zhang C, Zhu Z, et al. Trajectory clustering via deep representation learning[C]. IJCNN, IEEE, 2017: 3880–3887.
- [142] Boyle J, Nawaz T, Ferryman J M. Deep trajectory representation-based clustering for motion pattern extraction in videos[C]. AVSS, IEEE Computer Society, 2017: 1–6.
- [143] Fang Z, Du Y, Chen L, et al. E²dtc: An end to end deep trajectory clustering framework via self-training[C]. ICDE, IEEE, 2021: 696–707.
- [144] Li M, Chen L, Cong G, et al. Efficient processing of location-aware group preference queries[C]. CIKM, ACM, 2016: 559–568.
- [145] Shang S, Guo D, Liu J, et al. Finding regions of interest using location based social media[J]. Neurocomputing, 2016, 173: 118–123.
- [146] Chen L, Shang S. Approximate spatio-temporal top-k publish/subscribe[J]. World Wide Web, 2019, 22(5): 2153–2175.

-
- [147] Xu Y, Chen L, Yao B, et al. Location-based top-k term querying over sliding window[C]. WISE (1), Springer, vol. 10569 of Lecture Notes in Computer Science, 2017: 299–314.
- [148] Chen L, Shang S, Jensen C S, et al. Top-k term publish/subscribe for geo-textual data streams[J]. VLDB J., 2020, 29(5): 1101–1128.
- [149] Zhao K, Chen L, Cong G. Topic exploration in spatio-temporal document collections[C]. SIGMOD, ACM, 2016: 985–998.
- [150] Chen L, Shang S. Region-based message exploration over spatio-temporal data streams[C]. AAAI, AAAI Press, 2019: 873–880.
- [151] Chen L, Shang S, Zheng K, et al. Cluster-based subscription matching for geo-textual data streams[C]. ICDE, IEEE, 2019: 890–901.
- [152] Li X, Cheng Y, Cong G, et al. Discovering pollution sources and propagation patterns in urban area[C]. KDD, ACM, 2017: 1863–1872.
- [153] Han J, Zheng K, Sun A, et al. Discovering neighborhood pattern queries by sample answers in knowledge base[C]. ICDE, IEEE Computer Society, 2016: 1014–1025.
- [154] Zheng Y, Zhang L, Xie X, et al. Mining interesting locations and travel sequences from GPS trajectories[C]. WWW, 2009: 791–800.
- [155] Li J, Ni C, He D, et al. Efficient knn query for moving objects on time-dependent road networks[J]. VLDB J., 2023, 32(3): 575–594.
- [156] Zheng Y, Xie X, Ma W. Geolife: A collaborative social networking service among user, location and trajectory[J]. IEEE Data Eng. Bull., 2010, 33(2): 32–39.
- [157] Guttman A. R-trees: A dynamic index structure for spatial searching[C]. SIGMOD, 1984: 47–57.
- [158] Brinkhoff T, Kriegel H, Seeger B. Efficient processing of spatial joins using r-trees[C]. SIGMOD, 1993: 237–246.
- [159] Bentley J L. Multidimensional binary search trees used for associative searching[J]. Commun. ACM, 1975, (9): 509–517.
- [160] Zhang M, Chen S, Jensen C S, et al. Effectively indexing uncertain moving objects for predictive queries[J]. Proc. VLDB Endow., 2009, 2(1): 1198–1209.
- [161] Ciaccia P, Patella M, Rabitti F, et al. Indexing metric spaces with m-tree[C]. SEBD, 1997: 67–86.
- [162] Ciaccia P, Patella M, Zezula P. M-tree: An efficient access method for similarity search in metric spaces[C]. VLDB, 1997: 426–435.
- [163] Liu T, Moore A W, Gray A G. New algorithms for efficient high-dimensional nonparametric classification[J]. J. Mach. Learn. Res., 2006, 7: 1135–1158.

- [164] Omohundro S M. Five balltree construction algorithms[M]. International Computer Science Institute Berkeley, 1989.
- [165] Dolatshah M, Hadian A, Minaei-Bidgoli B. Ball*-tree: Efficient spatial indexing for constrained nearest-neighbor search in metric spaces[J]. CoRR, 2015.
- [166] Zhang X, Ray S, Shoeleh F, et al. Efficient contact similarity query over uncertain trajectories[C]. EDBT, 2021: 403–408.
- [167] Dumitrescu I, Boland N. Improved preprocessing, labeling and scaling algorithms for the weight-constrained shortest path problem[J]. Networks, 2003, 42(3): 135–153.
- [168] Shang S, Lu H, Pedersen T B, et al. Modeling of traffic-aware travel time in spatial networks[C]. MDM (1), IEEE Computer Society, 2013: 247–250.
- [169] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[J]. TKDE, 2016, 28(5): 1132–1146.
- [170] Guo C, Yang B, Hu J, et al. Learning to route with sparse trajectory sets[C]. 34th IEEE International Conference on Data Engineering, ICDE 2018, Paris, France, April 16-19, 2018, IEEE Computer Society, 2018: 1073–1084.
- [171] Liebig T, Piatkowski N, Bockermann C, et al. Dynamic route planning with real-time traffic predictions[J]. Inf. Syst., 2017, 64: 258–265.
- [172] Dafermos, C S. The traffic assignment problem for multiclass-user transportation networks[J]. Transportation Science, 1972, 6(1): 73-87.
- [173] Lim S, Rus D. Stochastic distributed multi-agent planning and applications to traffic[J]. ICRA, 2012: 2873-2879.
- [174] Babak J, Abbas B, (Avi) C A. Path-based capacity-restrained dynamic traffic assignment algorithm[J]. Transportmetrica B: Transport Dynamics, 2018: 1-24.
- [175] Dijkstra E W. A note on two problems in connexion with graphs[J]. Numerische Mathematik, 1959, 1: 269-271.
- [176] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying "infected" moving objects[J]. Proc. VLDB Endow., 2020, 13(12): 2825–2828.
- [177] Chen Z, Li K, Zhou S, et al. Towards robust trajectory similarity computation: Representation-based spatio-temporal similarity quantification[J]. World Wide Web, 2022: 1–24.
- [178] Zheng B, Xu J, Lee W C, et al. Grid-partition index: a hybrid method for nearest-neighbor queries in wireless location-based services[J]. The VLDB Journal, 2006, 15(1): 21–39.
- [179] Xu X, Yuruk N, Feng Z, et al. SCAN: a structural clustering algorithm for networks[C]. SIGKDD, ACM, 2007: 824–833.

-
- [180] Pelekis N, Kopanakis I, Kotsifakos E E, et al. Clustering trajectories of moving objects in an uncertain world[C]. ICDM, IEEE Computer Society, 2009: 417–427.
- [181] Lee J, Han J, Whang K. Trajectory clustering: a partition-and-group framework[C]. SIGKDD, ACM, 2007: 593–604.
- [182] Li Z, Lee J, Li X, et al. Incremental clustering for trajectories[C]. DASFAA, Springer, vol. 5982 of Lecture Notes in Computer Science, 2010: 32–46.
- [183] Li H, Liu J, Wu K, et al. Spatio-temporal vessel trajectory clustering based on data mapping and density[J]. IEEE Access, 2018, 6: 58939–58954.
- [184] Yuan J, Zheng Y, Xie X, et al. Driving with knowledge from the physical world[C]. Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, ACM, 2011: 316–324.
- [185] Yuan J, Zheng Y, Zhang C, et al. T-drive: driving directions based on taxi trajectories[C]. ACM-GIS, ACM, 2010: 99–108.
- [186] Shang S, Chen L, Zheng K, et al. Parallel trajectory-to-location join[J]. TKDE, 2019, 31(6): 1194–1207.
- [187] Xiong L, Shahabi C, Da Y, et al. REACT: real-time contact tracing and risk monitoring using privacy-enhanced mobile tracking[J]. ACM SIGSPATIAL Special, 2020, 12(2): 3–14.
- [188] Faloutsos C, Ranganathan M, Manolopoulos Y. Fast subsequence matching in time-series databases[C]. Proceedings of the 1994 ACM SIGMOD International Conference on Management of Data, ACM Press, 1994: 419–429.
- [189] Assent I, Wichterich M, Krieger R, et al. Anticipatory DTW for efficient similarity search in time series databases[J]. Proc. VLDB Endow., 2009, 2(1): 826–837.
- [190] Rong C, Lin C, Silva Y N, et al. Fast and scalable distributed set similarity joins for big data analytics[C]. 33rd IEEE International Conference on Data Engineering, ICDE 2017, IEEE Computer Society, 2017: 1059–1070.
- [191] Xie D, Li F, Phillips J M. Distributed trajectory similarity search[J]. Proc. VLDB Endow., 2017, 10(11): 1478–1489.
- [192] Ojagh S, Saeedi S, Liang S H L. A person-to-person and person-to-place COVID-19 contact tracing system based on OGC indoorgml[J]. ISPRS Int. J. Geo Inf., 2021, 10(1): 2.
- [193] Taha A A, Hanbury A. An efficient algorithm for calculating the exact hausdorff distance[J]. IEEE Trans. Pattern Anal. Mach. Intell., 2015, 37(11): 2153–2163.
- [194] Kong X, Chen Q, Hou M, et al. Mobility trajectory generation: a survey[J]. Artif. Intell. Rev., 2023, 56(Supplement 3): 3057–3098.

- [195] Zhang R, Lin D, Ramamohanarao K, et al. Continuous intersection joins over moving objects[C]. ICDE, 2008: 863–872.
- [196] Zhang R, Qi J, Lin D, et al. A highly optimized algorithm for continuous intersection join queries over moving objects[J]. VLDB J., 2012, 21(4): 561–586.
- [197] Vishnu C, Abhinav V, Roy D, et al. Improving multi-agent trajectory prediction using traffic states on interactive driving scenarios[J]. IEEE Robotics Autom. Lett., 2023, 8(5): 2708–2715.
- [198] Forrest S, Recio M, Seddon P. Moving wildlife tracking forward under forested conditions with the swift gps algorithm[J]. Animal Biotelemetry, 2022, 10(1): 19.
- [199] Pfoser D, Jensen C S. Capturing the uncertainty of moving-object representations[C]. SSD, 1999: 111–132.
- [200] Trajcevski G, Choudhary A, Wolfson O, et al. Uncertain range queries for necklaces[C]. MDM, 2010: 199–208.
- [201] Moore A W. The anchors hierarchy: Using the triangle inequality to survive high dimensional data[C]. UAI, 2000: 397–405.
- [202] Samet H. The quadtree and related hierarchical data structures[J]. ACM Comput. Surv., 1984, 16(2): 187–260.
- [203] Zheng Y, Li Q, Chen Y, et al. Understanding mobility based on GPS data[C]. UbiComp, 2008: 312–321.
- [204] Moreira-Matias L, Gama J, Ferreira M, et al. Predicting taxi-passenger demand using streaming data[J]. IEEE Trans. Intell. Transp. Syst., 2013, 14(3): 1393–1402.