

目 录

第一章 前截断章节	1
1.1 当前版本编译时间	1
第二章 面向大规模行程请求流的持续最优路线组合规划	2
2.1 引言	3
2.1.1 研究背景及应用场景	3
2.1.2 研究内容与挑战	5
2.1.3 研究成果与贡献	7
2.2 问题描述	7
2.2.1 路网及其构成	7
2.3 精确遍历算法	9
2.4 自感知的批处理算法	10
2.4.1 初始路线搜索	10
2.4.2 批优化处理	12
2.4.3 持续最优路线组合问题的总体解决方案	14
2.5 实验研究	16
2.5.1 实验设定	16
2.5.2 实验结果	18
2.6 本章小结	23
第三章 后截断章节	25
致 谢	26
参考文献	28

图目录

图 2-1	行程请求和路线	4
图 2-2	行程请求数目 $ Q $ 对算法运行时间和全局通行时间的影响	18
图 2-3	行程请求到达速率的影响	20
图 2-4	参数 α & β 的影响	21
图 2-5	批优化时间间隔 T 的影响	22
图 2-6	参数 ϵ 和预检查策略的影响 (a) CPU 运行时间; (b) 通行时间; (a) 预 先检查策略的影响评估	23

表目录

表 2-1 主要符号解释.....	8
表 2-2 参数设定.....	17

主要符号表

第一章 前截断章节

1.1 当前版本编译时间

二零二六年二月九日 22:47

第二章 面向大规模行程请求流的持续最优路线组合规划

本章研究如何设计面向大规模行程请求下的全局持续最优路线规划，以缓解动态路网下的全局交通拥堵。在研究背景上，调研了现有工作在路径规划问题取得的研究进展。随后，通过分析现有工作的不足进而引出本章研究工作的研究内容和面临的研究挑战。在问题描述上，一一定义了动态路网及其构成、车辆通行时间函数、路线及其通行时间、行程请求流以及所研究的全局最优路径规划问题。本章提出了一个全新的持续最优路线组合问题。具体来说，在一个动态变化的路网中，持续最优路线组合问题旨在对一段时间窗口内密集到达的行程请求进行联合优化。具体而言，在持续到达的请求流中，我们按照给定的时间间隔划分请求批次，每次选取发布时间落在同一时间窗口内的一组请求作为当前待处理的请求集合。对于当前时间窗口内的所有行程请求，需要为每一个请求规划一条从其起点到终点的可行路线。每条路线必须满足对应请求的出发位置和目的位置约束，即路线的起点与请求的起点一致，路线的终点与请求的终点一致。在满足上述约束的前提下，优化目标是使该批所有规划路线的总通行时间最小。这里，总通行时间定义为每条路线在其对应请求发布时间下的预计通行时间之和。

综上，持续最优路线组合问题的核心在于：在动态交通环境中，将时间窗口内到达的行程请求作为一个整体进行协同规划，在保证个体可行性的同时，实现整体通行效率的最优。例如在实际应用场景中，大量的用户很有可能会在极短的时间间隔内密集地发布行程请求，特别是在通勤时间等高峰时期，从而形成了持续的行程请求流。又比如，自动驾驶技术在人工智能、传感器融合与高精度地图等关键技术的推动下实现了快速发展，并逐步渗透到实际交通场景中。这种技术演进不仅改变了车辆的控制方式，也深刻影响了人类的驾驶行为与出行模式，使传统以人为主导的驾驶方式逐步向智能化、自动化方向演进。在自动驾驶场景下，大规模行程的批量规划天然存在。

在解决方案上，该问题的精确求解需要在指数级的路径组合空间中进行搜索，其时间复杂度随查询数量呈指数级增长，难以满足实时应用的需求。因此，如何在保证整体优化效果的前提下设计高效的近似算法，是解决持续最优路线组合问题的核心挑战。为解决该问题，本章提出了自感知的全局最优路径规划算法以及对应的修剪枝策略。最后，基于真实数据集开展了广泛的实验研究，实验结果验证了这些算法的准确性、高效性以及可扩展性。

2.1 引言

2.1.1 研究背景及应用场景

随着汽车产业、智能移动设备以及基于位置服务的快速发展，路径规划已经成为现代社会运行的重要基础功能之一，并深刻影响着人们的日常出行方式。随着地理定位服务的不断普及，各类路线规划应用（如谷歌地图^①，高德地图^②，百度地图^③）和拼车平台（如滴滴出行^④、曹操出行^⑤等）已成为日常生活中不可或缺的重要工具。随着网络购物的兴起，物流运输的高效运行同样需要路径规划算法。不同于仅返回一组实体结果（如兴趣点或位置点）的查询方式，路线搜索关注的是满足特定约束条件的完整路径：该路径通常以给定起点（例如用户当前位置）为出发点，在满足多种优化目标（如时间、距离或成本）的前提下，最终到达指定终点。无论是通勤导航、网约车调度，还是物流配送与智慧交通管理，高效且智能的路径规划算法都在其中发挥着核心作用。据新华社北京 2026 年 1 月 26 日电^⑥，公安部发布的最新统计数据显示，2025 年全国机动车保有量达 4.69 亿辆，其中汽车 3.66 亿辆；机动车驾驶人达 5.59 亿人，其中汽车驾驶人 5.25 亿人。如此庞大的车辆规模对城市路网的承载能力构成了前所未有的挑战，由此带来的交通拥堵、出行效率下降以及能源浪费等问题日益凸显。在此背景下，如何通过智能路径规划技术缓解交通压力、提升整体出行效率，成为学术界与工业界共同关注的重要课题。

由此，路径规划和行程推荐在很早以前就引起了学者们的广泛研究 [1–7]。上述早期路径规划的研究目标是基于当前的交通状态，为单个行程制定个人最优路线。其中，最优路径规划在不同设定下已被广泛研究 [8–12]。部分研究旨在在用户指定约束（例如出发时间）下，根据特定优化目标（例如最短距离、最小拥堵概率）生成一条路径 [13–16]。然而，这些研究提出的查询大多基于单次行程。此外，也有研究从全局角度出发，将问题建模为流量分配问题，在预定义路径集合上寻找最优流量分布 [17–19]。然而，这类方法本质上并非面向实时路径规划场景，其路径集合通常是静态给定的，难以适应动态变化的行程请求流。

近年来，自动驾驶技术在人工智能、传感器融合与高精度地图等关键技术的推动下实现了快速发展，并逐步渗透到实际交通场景中。这种技术演进不仅改变了车辆的控制方式，也深刻影响了人类的驾驶行为与出行模式，使传统以人为主

① <https://www.google.com/maps>

② <https://www.amap.com/>

③ <https://map.baidu.com/>

④ <https://www.didiglobal.com/>

⑤ <https://www.caocao.com.cn/>

⑥ https://paper.people.com.cn/rmrhwb/pc/content/202601/27/content_30135944.html

导的驾驶方式逐步向智能化、自动化方向演进。值得关注的是，在路径规划服务使用越来越频繁的情况下，大量的用户很有可能会在极短的时间间隔内密集地发布行程请求，特别是在通勤时间等高峰时期，从而形成了持续的行程请求流。在这种新的场景下，实现针对行程请求流的路径规划这一需求变得更加迫切。已经存在的相关研究旨在为行程请求中的单个行程依次制定个人最优路线 [20, 21]。尽管已有研究 [22] 提出了最小化全局出行时间的方法，但其解决方案无法用于解决持续最优化。在为行程请求流规划路线时，仅仅基于当前的交通状态以个人最优为最终目标规划个人最优的路线，可能会导致交通拥堵。更合理的路线规划应该考虑到之前已经规划的行程会对未来的交通状态产生影响，因为它们会增加路网中各路段的车流量。




图 2-1 行程请求和路线

以图2-1为例，共有 4 个行程请求。其中每个行程均包含一个起点和一个终点，分别以圆形和菱形标记。顶点 v_1 至 v_4 分别对应行程 1 至 4 的起点，而顶点 v_5 至 v_8 则分别对应行程 1 至 4 的终点。假设行程请求 1 至 3 的发布时刻十分相近，分别为 8:00:01、8:00:01 和 8:00:05，几乎为同时发布。基于各自发布时刻的实时交通状态，为这 3 个行程请求规划得到的最优路线分别为路线 1、路线 2 和路线 3，在图中以实线表示。根据预测，这三条路线将在时间区间 $[8:02:00, 8:05:00]$ 、 $[8:01:40, 8:04:40]$ 和 $[8:01:30, 8:04:30]$ 经过路段 $e(v_9, v_{10})$ 。可以观察到，在时间区间 $[8:02:00, 8:04:30]$ 内，三条路线将同时占用该路段。由于路径规划过程彼此独立，未考虑其他已规划行程的未来占用情况，因此这种时间上的重叠可能导致路段 $e(v_9, v_{10})$ 在未来产生交通拥堵，进而增加该路段上所有车辆的实际通行时间。随后，行程 4 于

8:00:20 发布。基于该时刻的实时交通状态，为其规划得到的最优路线为路线 4。然而，该规划过程同样未考虑先前规划路线 1 至路线 3 在未来时段对路段 $e(v_9, v_{10})$ 的潜在影响。因此，路线 4 将再次经过该路段，可能进一步加剧拥堵问题。综上所述，在面对一组密集发布的行程请求流时，如果仍然采用逐个独立规划的策略，容易在局部最优决策的叠加下产生全局拥堵。为缓解交通压力，有必要将这些行程请求视为一个整体进行协同规划。例如，在本例中，可以首先将行程 1 至 3 作为一个整体进行联合优化，在预测未来路段负载的基础上，将行程 3 的路线由路线 3 调整为路线 5，其中路线 5 以虚线表示，以降低对路段 $e(v_9, v_{10})$ 的集中占用。进一步地，对于随后到达的行程 4，同样将行程 1 至 4 作为一个整体进行优化，可将其路线由路线 4 调整为路线 6。尽管调整后的路线对单个请求而言可能不再是各自的最短路径，即在个体层面上是“次优”的，但由于有效分散了路段 $e(v_9, v_{10})$ 的交通负载，整体交通拥堵得到缓解，从而显著降低了行程 1 至 4 的总通行时间。通过采用路线组合 $\tau_1, \tau_2, \tau_5, \tau_6$ ，行程 1-4 的总体通行时间可能达到最小。我们将能够使整体目标函数最优的这种路线组合称为最优路线组合。

综上，当多个行程在相近时间内发布并分别进行独立规划时，可能在未来某一时间区间内集中占用同一路段，从而导致拥堵加剧。若后续行程仍然基于当前状态进行规划而不考虑已有规划结果的潜在影响，则会进一步恶化交通状况。因此，在面对持续到达的行程请求流时，有必要将新到达的请求与已规划路径进行协同考虑，从整体角度优化路线组合，而非仅追求单个请求的即时最优。基于上述背景，本章围绕持续行程请求流场景下的协同路径规划问题展开研究，旨在在动态路网环境中实现更具前瞻性的整体优化。

2.1.2 研究内容与挑战

为了解决上述缺陷，本章的研究目标为：开发适应城市动态变化的智能路径规划系统，以实现交通流量平衡，减少拥堵，提高效率。主要目标是开发一种高效的算法，为大规模交通通行提供最优路径规划，以减轻城市交通拥堵。次要目标包括提高路网利用效率，减少交通通行时间，以及提高交通系统的整体性能。基于此，本章创新性地提出并研究了一种持续的行程请求流的路线规划问题：在一个动态路网上给定一组行程请求流，行程请求流中的行程请求数是不断增加的，我们需要找到一个路线组合 Π 使得所有在 Π 中的路线的总的通行时间最小。其中，每一条路线是为每一个具体的行程请求对应规划的。在我们的设定中，每条边上的实时行驶时间与当前位于该边上的车辆数量成正比。该问题具有十分广泛的应用场景，包括但不限于城市交通流量管理，实时的路线规划以及持续的拥堵预防上。

与传统单次最优路径规划问题不同，持续最优路线组合问题具有显著的持续

性、动态性与全局耦合性等特征。首先，行程请求以数据流形式持续到达，系统需要在不断扩展的查询集合上进行在线优化，而非一次性处理静态输入；其次，早期规划结果会改变未来时刻各路段的车流分布，从而影响后续行程的路径选择，使得决策之间具有时间上的传递性；最后，不同行程路径通过共享路段产生资源竞争关系，使得各路径之间形成复杂的耦合结构，从而显著扩大了组合搜索空间。上述特性使得该问题不仅是一个路径搜索问题，更是一个具有强依赖性的动态组合优化问题。

具体而言，高效且有效地解决该问题面临以下关键挑战：

- **规模性**：在实际应用中，行程请求可能达到百万级甚至更高规模。系统需要在大规模请求集合与复杂路网结构下进行统一规划，同时考虑车辆数量变化对边权的动态影响，这对算法的时间复杂度与空间复杂度提出了严格要求。
- **实时性**：动态路网中的交通状态（如车流密度、拥堵程度）随时间持续变化。算法必须能够在极短时间内响应路网状态更新，并为新到达的行程请求生成可行路径，以满足实时交互需求。
- **准确性与效率的平衡**：单纯追求全局最优往往需要高昂的计算代价，而过度简化模型又可能导致严重的拥堵问题。因此，需要在整体通行时间优化效果与算法运行效率之间取得合理平衡。
- **连续查询流的处理**：行程请求以流式形式持续到达，系统需要在已有规划结果的基础上进行增量优化，而非每次从头计算。这要求算法具备良好的在线处理能力与历史信息复用机制。
- **动态路网的适应性**：路段通行时间随车辆数量动态变化，算法需具备对未来交通负载的预测与感知能力，从而在规划阶段主动规避潜在拥堵，而非被动响应。
- **效率与可扩展性**：面对持续增长的查询规模与复杂动态约束，算法应具有良好的可扩展性，能够随着数据规模扩大而保持稳定性能表现。

更为重要的是，从理论角度看，持续最优路线组合问题本质上需要在指数级规模的路径组合空间中进行搜索。随着行程请求数量的增加，可行路线组合数呈指数级增长，其精确求解的时间复杂度难以控制在可接受范围内，因而无法满足实际应用中的实时性需求。已有研究 [22] 尝试在全局层面最小化一组行程的总出行时间成本，但其假设输入为静态行程集合，并未考虑在当前时间之前已经规划的路径对未来交通状态的持续影响。因此，该方法难以直接扩展到持续到达的行程请求流场景。特别是在高频行程发布场景下，若忽略历史路径的累积影响，系统容易在局部最优决策的叠加下形成新的拥堵热点。因此，如何在保证整体优化

效果的前提下，设计具有可扩展性和实时性的高效近似算法，在动态路网环境中持续优化路径组合，是解决持续最优路线组合问题的核心挑战，也是本文研究的重点。

2.1.3 研究成果与贡献

该问题由于计算开销高而极具挑战性。精确算法的时间复杂度相对于查询数量呈指数级增长，因此无法在交互式时间内找到最优的路径组合。为实现高效率，我们提出了一种自感知批处理算法及其相应的剪枝技术。除当前时刻之前由我们规划路径所引起的与查询相关的交通流，以及与查询无关的交通流之外，我们还考虑了由初始路径规划所带来的潜在交通流。本文的主要贡献总结如下。

- 我们提出了一种新颖的持续最优路线组合问题，面向多种应用场景，包括交通流管理、实时路径规划和拥堵预防。
- 我们设计了一种自感知批处理算法以高效求解持续最优路线组合问题。该算法包含两个主要步骤：（1）*初始路径搜索*和（2）*批量优化处理*。具体而言，对于一批新到达的行程请求，我们首先执行初始路径搜索，为每个新到达的行程请求生成一组高质量的初始路径组合。该步骤有助于在初步阶段避免部分交通拥堵。我们使用路径组合来存储这些为最近发布的行程请求规划的初始路径。为了进一步减少所有行程请求的总出行时间并缓解交通拥堵，我们以批处理模式对最近发布的请求集合进行处理。随后，执行批量优化处理步骤，对初始路径组合中的路径进行进一步优化。
- 我们基于两个真实数据集进行了大量实验来评估所提方法的准确性和效率。实验结果表明，我们的方法优于基线方法，并且能够以实时方式处理行程查询流。

2.2 问题描述

在本章，定义了动态路网及其构成、车辆通行时间函数、路线及其通行时间、行程请求流以及所研究的全局最优路径规划问题。本章所使用的主要符号及其解释如表2-1所示。

2.2.1 路网及其构成

定义 2.1（动态路网） 一个动态路网 $G = (V, E)$ 是由顶点集 V 和边集 E 构成的，其中 $E \subseteq V \times V$ ，顶点代表路段的连接点，交叉点；连边则代表具体的路段。每条边 $e(v_i, v_j) \in E$ 连接着两个顶点 v_i 和 v_j ，这里 $v_i, v_j \in V$ 。为了便于描述，我们假定所有行程请求的起点和终点位置都已经被映射到离它们最近的顶点上。针

表 2-1 主要符号解释

符号	解释
t	某个时刻
V	路网上的顶点集合
v	路网上的一个顶点
E	路网上的边集合
e	路网上的边
C_e	边 e 的车容量限制
$f(e, t)$	在时刻 t 经过路段 e 的车流量
$T_m(e)$	车辆在边 e 的最短通行时间
$T(e, t)$	车辆在时刻 t 经过路段 e 的通行时间
$G = (V, E)$	动态路网及其构成
π	一条由有限的顶点序列构成的路线
Π	一个包含多条路线的路线集合
$ET(\pi, t_0)$	一条路线 π 的预计通行时间，即路线 π 中每个路段的预计通行时间之和
$q = (v_s, v_d, t_s)$	一个行程请求，其中 v_s 是起点位置， v_d 是终点位置， t_s 是出发时间
Q	包含多个行程请求的一组行程请求流
T	批处理时间间隔
$TT(\Pi)$	所有已规划路线的总的通行时间

对每个路段 e , 用 C_e 来代表该路段的车容量, 用 $T_m(e)$ 代表在路段 e 的最小通行时间 (例如, 当路段 e 上没有其他车辆时的通行时间)。在我们的设定中, 每一个路段的权重 (通行时间) 是动态变化的。一个路段的最小通行时间是 $T_m(e)$, 而实际的通行时间是和该路段上的动态车流量成比例的。

定义 2.2 (车辆通行时间函数) 车辆在时刻 t 经过路段 e 的通行时间和当前时刻路段 e 上的车流量 $f(e, t)$ 相关。参照已经存在的研究 [18, 19, 22], 基于当前时刻路段 e 上的车流量, 使用下式来计算路段 e 在时刻 t 的通行时间, 用 $T(e, t)$ 表示。

$$T(e, t) = T_m(e) \times (1 + \alpha \times (\frac{f(e, t)}{C_e})^\beta) \quad (2-1)$$

其中, C_e 代表路段 e 的车流量, α 和 β 是由路段的不同性质 (例如, 限速, 路宽) 等决定的可变参数。我们的解决方案是和这些参数独立的, 如何为这些参数设置合适的值并不在我们的研究范围内。由式2-1可以知道, 随着车辆数目的动态变化, 每条路段的通行时间也会随之发生改变。

定义 2.3 (路线及其通行时间) 我们用一个有限的顶点序列 $\langle v_0, v_1, \dots, v_{|\pi|-1} \rangle$ 来表示一条路线 π 。假定路线 π 出发时间为 t_0 , t_i 是其经过的顶点 v_i 的预计到达时间 (即, $t_i = t_{i-1} + T(e(v_{i-1}, v_i), t_{i-1})$)。结合式2-1, 我们用式2-2来计算一条路线 π 的预计通行时间, 即路线 π 中每个路段的预计通行时间之和, 我们用 $ET(\pi, t_0)$

来表示。

$$ET(\pi, t_0) = \sum_{i=0}^{|\pi|-2} T(e(v_i, v_{i+1}), t_i) \quad (2-2)$$

之后我们使用 $\pi.v_0$ 和 $\pi.v_{|\pi|-1}$ 来分别代表一条路线 π 对应的第一个顶点 (起点) 和最后一个顶点 (终点)。

定义 2.4 (行程请求流) 我们用 $q = (v_s, v_d, t_s)$ 来代表一个行程请求, 其中 v_s 是该行程的起点位置, v_d 是该行程的终点位置, 而 t_s 是该行程的出发时间。 $Q = \{q_1, q_2, \dots\}$ 由多个行程请求组成, 代表一组行程请求流 (即, $\forall q_i, q_j \in Q, i > j: q_i.t \geq q_j.t$)。需要注意的是, Q 是以流数据的形式到达的行程请求集合并且 Q 是动态更新的。

定义 2.5 (全局最优路径规划问题) 在一个动态路网 $G = (V, E)$ 上, 给定一组行程请求流 $Q = \{q_1, q_2, \dots\}$ 和时间间隔 T , 持续的最优路线组合问题旨在不断地处理最近到达的一批行程请求 $Q_n = \{q_k, q_{k+1}, \dots, q_{|Q|}\} (Q_n \subset Q \wedge q_{|Q|}.t - q_k.t = T)$, 找到一个最优的路线组合 $\Pi = \{\pi_1, \pi_2, \dots\}$ 使得: (1) $|Q| = |\Pi|$; (2) $(\forall \pi_i \in \Pi) (\pi_i.v_0 = q_i.s \wedge \pi_i.v_{|\pi_i|-1} = q_i.d)$; (3) 在 Π 中规划的所有路线的总的通行时间最小, 我们用 $TT(\Pi)$ 来表示所有路线的总的通行时间, 如公式2-3所示。

$$TT(\Pi) = \sum_{i=1}^{|\Pi|} ET(\pi_i, q_i.t) \quad (2-3)$$

2.3 精确遍历算法

针对持续最优路线组合问题, 一个简单直接的办法就是对每一个行程请求, 搜索起点和终点间可能存在的所有路线, 然后对所有的路线组合进行遍历评估, 比较各个路线组合所有路线总的通行时间, 最终筛选出具有最小通行时间的路线组合。具体来说, 对于每一个行程请求 $q_i \in Q$, 我们可以采取深度优先算法来查找从起点 s_i 到终点 d_i 可能存在的所有路线。其中, 我们可以应用一些剪枝策略来加速深度优先搜索。随后, 对于每一个路线组合我们计算它所有路线总的通行时间。最终, 我们返回具有最小通行时间的路线组合作为返回结果。精确算法比较简单直接, 便于理解。当行程请求数量较小时, 精确算法可以在有限时间内得到最优解。但是, 当行程请求数量很大时, 精确算法显然大量的计算时间, 不能运用到实际的应用场景中。

2.4 自感知的批处理算法

为了高效解决持续最优路线组合问题，我们提出了一个自感知的批处理算法，该算法主要包含两大组成部分：(1) 初始路线搜索和 (2) 批优化处理。具体来说，给定一组行程请求流 Q_n ，我们首先采用初始路线搜索生成一个高质量的初始路线组合 Π_n ，该组合包含了为该行程请求流中的每个请求指定的初始路线。接下来，我们执行批优化处理对初始路线组合中的每个初始路线进行优化。最终，我们将优化后的路线组合 Π_n 加入到全局的路线组合 Π 中去。每当我们处理完一批行程请求后，我们返回 Π 作为实时的规划结果。我们的自感知思想合理考虑了新规划的路线会影响未来的交通状态这一事实，即规划的路线会增加一些路段的车流量从而会影响该路段的实际通行时间。

2.4.1 初始路线搜索

初始路线搜索的目标是为新一批到达的行程请求流中的每个行程请求规划一条高质量的个人路线。每个路段的动态车流量由两部分组成的，一部分是在我们规划系统中的请求车辆所造成的交通流量，即我们规划的路线在各路段上造成的车流量，我们称之为系统内的车流量，一部分是系统外的车流量即在各路段上没有使用我们规划系统的车辆数目，我们把系统外的车流量直接作为算法输入。

2.4.1.1 路段标签

为了实现对系统内车流量的快速计算，我们在每个路段上维持一系列的路段标签 $L_e = \{l_1, l_2, \dots\}$ 。这些路段标签记录了经过该路段的路线在该路段的时间信息。每个路段标签 $l_i = \{t_a, t_b\}$ 记录了一条特定的路线进入路段 e 的时间 t_a 以及离开该路段的时间 t_b 。刚开始没有行程请求的时候，每个路段维持的路段标签是一个空集。之后每当我们处理完一批新的行程请求集合的时候，对应路段的路段标签会进行动态地更新。

2.4.1.2 系统内的车流量计算

我们可以快速地计算在各个路段上由我们规划系统规划的路线所产生的车流量。由我们规划系统规划的路线在路段 e ，时刻 t 所造成的车流量，也就是满足 $[l_i.t_a, l_i.t_b] \ni t$ 的路段标签 l_i 的数量，其中 $l_i \in L_e$ 。在我们的实验中，我们应用了一个优先队列来加速计算。

2.4.1.3 通行时间下界

我们用一个启发值 $H(v_i, v_j)$ 来代表从一个顶点 v_i 到另一个顶点 v_j 的通行时间下界。给定最小的系统外的车流量作为静态的车流量输入，该下界是由 Dijkstra 算法 [23] 预计算的。在本文中，我们将非请求车辆的车流量直接作为算法输入。

2.4.1.4 算法描述

算法 2-1: 初始路线搜索 ($G, q, \mathcal{L}$)

```

输入: 动态路网  $G = (V, E)$ ;
        行程请求  $q = (v_s, v_d, t_s)$ ;
        所有两点间的通行时间下界  $H(v_i, v_j)$ ;
        规划路线的路段标签集合  $\mathcal{L}$ 。
输出: 为请求  $q$  制定的初始化路线  $\pi$ 。

1 Init:  $\forall v \in V: v.t_s = \infty, v.t_d = H(v, v_d), v.et = t_s$ ;
    $v_s.pred = null, v_s.t_s = 0; \pi = \emptyset;$ 
2  $PQ \leftarrow \{v_s\};$ 
3 while  $PQ \neq \emptyset$  do                                     /* 主搜索循环 */
4    $v \leftarrow PQ.pop();$ 
5   if  $v = v_d$  then                                       /* 到达目的节点 */
6     while  $v_d.pred \neq null$  do
7        $\pi \leftarrow \{v_d, \pi\};$ 
8        $v_d \leftarrow v_d.pred;$ 
9     return  $\pi;$ 
10  for  $e(v, v') \in G$  do                                   /* 遍历邻接路段 */
11    计算当前时刻  $v.et$  下路段  $e$  的通行时间  $T(e, v.et)$ ;
12    if  $v.t_s + T(e, v.et) \leq v'.t_s$  then
13       $v'.t_s \leftarrow v.t_s + T(e, v.et);$ 
14       $v'.et \leftarrow t + v'.t_s;$ 
15       $v'.pred \leftarrow v;$ 
16      if  $v' \notin PQ$  then
17         $PQ.push(v');$ 
18 return  $\pi;$ 

```

算法 2-1 提出了初始路线搜索的伪代码。算法输入包含一个动态路网 $G = (V, E)$ ，一个行程请求 $q = (v_s, v_d, t_s)$ ，所有顶点间的提前计算好的通行时间下界 $H(v_i, v_j)$ 以及所有路段的路段标签集合 $\mathcal{L} = \{L_{e_1}, L_{e_2}, \dots\}$ 。算法输出是为该行程请求 q 制定的一条初始路线。每个顶点 $v \in V$ 包含以下记录信息：从起点 v_s 到达该点的精确通行时间 t_s ；从该点到达终点的通行时间下界 t_d ；从起点到达该点的最

小时刻 et 以及一个前驱节点记录 $pred$ 。首先，我们初始化每一个顶点 $v \in V$ 的信息记录：从起点 v_s 到达该点的精确通行时间 t_s 为无穷大；从该点到达终点的通行时间下界 t_d 由提前计算的表中直接索引；从起点到达该点的最小时刻 et 为出发时刻。接下来，初始化起点的前驱节点为空，从起点到达起点的精确通行时间为 0。最后，设置路线 π 是一个空集 (行 1)。接着我们把起点 v_s 加入一个优先队列 PQ 中。该优先队列 PQ 内部对顶点对象按照该点的 $v.t_s + v.t_d$ 的值从小到大排序，队头元素为具有最小 $v.t_s + v.t_d$ 的顶点 (行 2)。在搜索过程中，每一次我们从 PQ 选出对头元素 v 并探索它的邻接顶点。具体来说，每一次我们选出的 v 都具有最小的 $v.t_s + v.t_d$ ，之所以这样选择，是基于这样的顶点扩张可能会产生最小的通行时间 (行 4)。如果选择的 v 是行程请求的终点 v_d ，我们就利用相应节点的前驱节点记录生成一条路线 π ，并将 π 作为结果返回 (行 5–9)。如果选择的 v 不是行程请求的终点 v_d ，对于每一个从顶点 v 出发的路段 e ，我们计算当前时刻该路段的车流量 (行 11)。对于路段 $e(v, v')$ 的结束点 v' ，我们需要检查该点能否通过顶点 v 到达，并且所花的时间比从其他点到达该点更小 (行 12)。如果满足，我们将分别更新顶点 v' 对应的 t_s, et 和 $pred$ 记录 (行 12–17)。接下来，如果顶点 v' 不在优先队列 PQ 中，我们将其加入。当优先队列 PQ 为空或者我们已经扩张到行程请求对应的终点时，初始路线搜索算法终止。

2.4.2 批优化处理

初始规划路线能够在一定程度上优化个人的通行时间，但并没有考虑后续行程的影响。为了提高算法质量，我们提出了一个批优化处理方法对由算法2-1产生的初始路线进行优化。一个初始路线组合 Π_n 包含了为最近到达的行程请求 Q_n 制定的初始路线。不同于 Π_n 的是，全局的路线组合 Π 包含了所有在当前时间之前已经规划的路线。优化处理过程重新利用了初始路线组合 Π_n ，并通过一种自感知的批处理交换策略对 Π_n 中的每一条初始路线进行优化。批优化处理的精髓在于：在每一个优化过程中，我们选择一条路线 $\pi_i \in \Pi_n$ 。我们将除了该路线的其他正在规划的初始路线作为已知的路线规划输入到交通流量信息中，重新预测未来的交通状态并尝试重新分配一条新的路线 π'_i 给行程 q_i 。我们用 π' 对原始地初始路线 $\pi \in \Pi_n$ 进行交换，该交换操作可以用 $\Pi_n.swap(\pi, \pi')$ 表示。如果该交换操作能够使所有行程的通行时间之和减少至少 $1 + \epsilon$ 的比例 (例如， $\frac{TT(\{\Pi, \Pi_n\})}{TT(\{\Pi, \Pi_n.swap(\pi, \pi')\})} > (1 + \epsilon)$)，我们认为该操作是有效的并采用该操作去更新原有的初始路线。其中，我们采用一个极小的常数值 ϵ 排除一些“无用”的操作，这里无效操作指通过该操作只能减少很小的通行时间。此外， ϵ 的使用还保证了交换操作的次数是有限的。实际上，有效的交换操作的次数是和 ϵ 成反比的。具体来说，最大的有效交换操作的次数

是 $\log_{(1+\epsilon)} \frac{TT}{TT_m}$ 。其中 TT 是当前规划的初始路线组合的总的通行时间，而 TT_m 是理想的最小通行时间。当路线组合 Q_n 中不存在有效交换操作，不能再产生一个更好的规划结果，批优化处理算法终止。在本文中，我们也提出了一个预检查策略来进一步提高效率。

2.4.2.1 交换操作

在优化过程中，除了考虑系统外车流量和系统内已经规划的路线产生的车流量外，我们进一步考虑了当前正在规划的初始路线可能对未来交通产生的潜在影响。一个新的路段标签集合 $\mathcal{L}' = \{\mathcal{L}, \mathcal{L}(\Pi_n \setminus \pi_i)\}$ 是由原有的路段标签 $\mathcal{L}$ 以及预估的正在规划的初始路线的时间信息联合组成的 (参照算法 2-1)。把 $\mathcal{L}'$ 作为已知的交通信息输入，我们再次执行算法2-1为行程 q_i 分配一条新的路线 π'_i 。如果该交换操作被确定是有效的，我们将使用新路线 π'_i 替换原有的路线 $\pi_i \in \Pi_n$ 。

2.4.2.2 预检查策略

为了检查一个交换操作的有效性，我们必须更新所有路段的路段标签去计算所有行程总的通行时间的降低率，这是非常费时的。因此，我们提出了一个预检查策略进一步提高算法效率。具体来说，我们定义了一个所有行程总的通行时间的降低率上界 UB ，计算如下。

$$UB(\pi) = \frac{TT(\{\Pi, \Pi_n\})}{TT(\{\Pi, \Pi_n \setminus \pi\})} \quad (2-4)$$

注意 $TT(\{\Pi, \Pi_n \setminus \pi\}) \neq TT(\{\Pi, \Pi_n\}) - ET(\pi, t)$ ，在这里 $TT(\{\Pi, \Pi_n \setminus \pi\})$ 是将路线 π 剔除，假设该路线不存在下的所有路线的总的通行时间。我们不仅要剔除路线 π 本身的通行时间，也要消除路线 π 对其他行程的影响，因为路线 π 造成了额外的交通流量，会对其他路线的通行时间造成一定的影响。

2.4.2.3 算法描述

算法2-2提出了批优化处理算法的伪代码。算法输入包含一个动态路网 $G = (V, E)$ ，全局路线组合 Π ，初始路线组合 Π_n ，路段标签集合 $\mathcal{L}$ 以及提升参数 ϵ 。算法输出是优化后的路线组合 Π_n 。初始地，我们使用一个标志 **flag** 来标记在上一次“while”循环中是否存在有效的操作，算法开始我们设置其为 **true** (行 1)。在优化过程中，对于每一条初始路线 $\pi \in \Pi_n$ ，我们检查它能否被一条新的路线 π' 替换 (行 4-9)。具体来说，我们首先更改标志 **flag** 为 **false**，假设在本轮循环中不存在有效的交换操作 (行 3)。对于每一条路线 $\pi \in \Pi_n$ ，我们通过计算提升上界 $UB(\pi)$ 来预检查该交换操作的有效性。如果该交换操作是可能有效的，我们生成一个新的路段

算法 2-2: 批优化处理 ($G, \Pi, \Pi_n, \mathcal{L}, \epsilon$)

```

输入: 动态路网  $G = (V, E)$ ;
        全局路线组合  $\Pi$ ;
        初始路线组合  $\Pi_n$ ;
        路段标签集合  $\mathcal{L}$ ;
        提升参数  $\epsilon$ 。

输出: 优化后的路线组合  $\Pi_n$ 。

1 Init:  $flag \leftarrow true$ ;
2 while  $flag$  do                                     /* 批量迭代优化 */
3      $flag \leftarrow false$ ;
4     for  $\pi_i \in \Pi_n$  do                             /* 遍历当前路线集合 */
5         if  $UB(\pi_i) > (1 + \epsilon)$  then
6              $\mathcal{L}' \leftarrow \{\mathcal{L}, \mathcal{L}(\Pi_n \setminus \pi_i)\}$ ;
7              $\pi' \leftarrow$  初始路线搜索( $G, q_i, \mathcal{L}'$ );
8             if  $\Pi_n.swap(\pi_i, \pi')$  then             /* 可行替换 */
9                  $\Pi_n \leftarrow \Pi_n.swap(\pi_i, \pi')$ ;
10                 $flag \leftarrow true$ ;
11 return  $\Pi_n$ ;
    
```

标签 $\mathcal{L}'$ (行 6)。将 $\mathcal{L}'$ 作为输入, 我们将基于更新的车流量再次执行初始路线规划算法 2-1 产生一条新的路线 π' (行 7)。如果该交换操作最终被确定是有效的, 我们将采用这次交换操作并设置标志 $flag$ 为 $true$ 来记录当前循环仍然具有有效的交换操作(行 8–10)。当一轮循环, 对所有的 $\pi \in \Pi_n$ 都没有检测到有效的交换操作, 算法终止。这表明已经没有能够产生更好结果的有效操作存在。最后, 批优化算法返回当前优化后的路线组合 Π_n 作为结果。

2.4.3 持续最优路线组合问题的总体解决方案

通过整合上文提出的所有方法, 我们在这里提出针对持续最优路线组合问题的总体解决方案即持续最优路线组合算法。持续最优路线组合算法执行流程如下: 对于每一个新到达的行程请求 q , 我们先执行初始路线搜索为其分配一条初始个人路线。接着我们执行算法 2-1 周期性的批优化最近规划的初始路线, 这些初始路线是为最近一段时间发布的行程请求制定的。一旦有新的行程请求发布, 持续最优路线组合算法将不断执行上述操作。

2.4.3.1 优化间隔

在我们的设定中, 批优化算法是以固定的时间间隔周期性执行的(例如, 2s)。我们用 T 表示每两次批优化处理之间的时间间隔。通过利用这样一个时间间隔 T ,

我们合理考虑了更多的正在规划的初始路线对未来交通的潜在影响,在这种情况下我们能更准确地预测未来的交通状态,从而通过一次交换操作我们也许可以减少更多的通行时间,整个优化过程中总的交换次数也会减少,算法效率也就得到了提高。

算法 2-3: 持续最优路线组合 (G, Q, T, ϵ)

```

输入: 动态路网  $G = (V, E)$ ;
        行程请求流  $Q$ ;
        优化时间间隔  $T$ ;
        提升参数  $\epsilon$ 。

输出: 实时的最优路线组合  $\Pi$ 。

1 Init:  $\mathcal{L} \leftarrow \emptyset$ ;  $\Pi \leftarrow \emptyset$ ;  $\Pi_n \leftarrow \emptyset$ ;

2 while true do                                     /* 系统持续运行 */
3   for  $q \in Q$  do                                   /* 处理到达的行程请求 */
4      $\pi \leftarrow$  初始路线搜索( $G, q, \mathcal{L}$ );
5      $\Pi_n \leftarrow \{\Pi_n, \pi\}$ ;
6   if 当前时刻 mod  $T = 0$  then                       /* 周期性批量优化 */
7      $\Pi_n \leftarrow$  批优化处理( $G, \Pi, \Pi_n, \mathcal{L}, \epsilon$ );
8      $\Pi \leftarrow \{\Pi, \Pi_n\}$ ;
9      $\mathcal{L} \leftarrow \{\mathcal{L}, \mathcal{L}(\Pi_n)\}$ ;
10     $\Pi_n \leftarrow \emptyset$ ;
11    return  $\Pi$                                        // 实时输出结果

```

2.4.3.2 算法描述

算法 2-3 提出了针对持续最优路线组合问题的总体解决方案,即持续最优路线组合算法的伪代码。算法输入包含一个动态路网 $G = (V, E)$,行程请求流 Q ,优化时间间隔 T 以及提升参数 ϵ 。算法输出实时更新的路线组合 Π_n 。初始地,我们的规划系统中没有接收到任何行程请求,我们设置路段标签 $\mathcal{L}$ 和全局的路线组合 Π 都是空集。全局的路线组合 Π 记录了所有已经规划完毕的行程的路线。我们也使用了一个路线组合 Π_n 来记录为新的一批行程 Q_n 规划的初始路线,初始的 Π_n 也是空集(行 1)。首先我们执行初始路线规划算法 2-1 为每一个新到达的行程 $q \in Q$ 请求分配一条初始化路线(行 3–5)。我们持续地为新到达的请求生成初始路线直到下一次批优化处理(行 6)。在批优化处理过程中,我们执行批优化算法 2-2 去生成一个优化后的路线组合 Π_n (行 7)。接下来,我们将这些优化后的路线加入全局的路线组合 Π 中,并根据新规划的路线对所有路段的路段标签记录进行更新(行 7–10)。每一个优化处理完成后,由于所有的初始路线已经被优化了,我们设置 Π_n 为空并

继续用于记录下一批到达的行程的初始路线。每当我们处理完一批新的行程请求流，我们输出全局最优的路线组合 Π 作为实时的规划结果 (行 11)。

2.5 实验研究

在本节中，首先介绍实验设定，包括实验所使用的数据集，如何实时计算车流量，算法评估以及运行环境等，然后给出实验结果与分析。实验结果主要关注所提出的搜索算法的运行时间，即高效性方面的表现；以及全局通行时间的比较，即算法有效性方面的表现。实验的目的在于，通过设置不同的参数 (路线长度，位置点密度，空间-文本相似度阈值等)，对比不同的算法的运行时间并进行分析。

2.5.1 实验设定

2.5.1.1 数据集

我们使用两个路网数据集用于实验研究：San Joaquin County Road Network (TG 路网)^①和 the New York Road Network (NY 路网)^②。我们用邻接表进行路网图的存储。对于每个路段连边，我们基于该路段的长度分配一个数值为 20–100 间的车容量 C_e 。每个路段的最小通行时间 $T_m(e)$ 是随机生成的，位于 5–10 分钟之间。为了模拟非请求车辆，我们假设每个路段 e 上的非请求车辆的平均车流量 $\bar{x}$ 为 $0.4 \times C_e$ ，实时的非请求车辆在平均车流量附近周期性地动态变化 $0.8\bar{x}$ 到 $1.2\bar{x}$ 。给定最小的非请求车流量 $0.8\bar{x}$ 作为所有路段的静态车流量，我们提前计算好所有顶点两两间的通行时间下界，该下界即算法2-1中的启发值 $H(v_i, v_j)$ 。在路网较为密集的区域，我们随机采样起点-终点对来模拟行程请求。为了模拟持续到达的行程请求流，给定第一个行程的出发时间 $q_1.t$ ，接下来的第 i 个行程的出发时间 $q_i.t$ 在上一个行程请求的出发时间 $q_{i-1}.t$ 的基础上小幅度增加或保持不变。行程请求到达的速率设定见表2-2。

2.5.1.2 车流量的计算

在我们的实验设定中，在时刻 t 路段 e 实时的车流量 $f(e, t)$ 是由式 2-5 计算的。

$$f(e, t) = f'(e, t) + f''(e, t) \quad (2-5)$$

其中， $f'(e, t)$ 代表系统外的非请求车辆的车流量，而 $f''(e, t)$ 代表系统内请求车辆的车流量。为了模拟非请求车辆，我们假设 $f'(e, t)$ 是随时间周期性动态变化的 (例如， $f'(e, t + T) = f'(e, t)$, $T=2h$)。如何计算系统内请求车辆的车流量我们已经在算

① <https://www.cs.utah.edu/~lifeifei/SpatialDataset.htm>

② <https://publish.illinois.edu/dbwork/open-data>

	TG 路网	NY 路网
行程请求数 $ Q $	4,000-20,000 默认 4,000	2,000-10,000 默认 2,000
参数 ϵ	0.0002-0.0010 默认 0.001	0.0002-0.0010 默认 0.001
优化间隔 T	1s-5s 默认 2s	1s-5s 默认 2s
行程到达速率	20/s-100/s 默认 50/s	20/s-100/s 默认 50/s
α (参照式 2-1)	1-5 默认 2	1-5 默认 2
β (参照式 2-1)	1-3 默认 2	1-3 默认 2

表 2-2 参数设定

法2-1中给出。

2.5.1.3 算法评估

我们主要评估了自感知批处理算法，即持续最优路线组合算法的算法表现，表示为 **SBP**。为了评估该算法的结果质量，我们额外实施了一个基于个人的搜索算法，表示为 **Ind** 算法。具体来说，给定一组行程请求流 Q ，对于每一个行程请求 $q \in Q$ ，**Ind** 算法基于单个行程的出发时刻的交通状态生成一条最优的个人最优路线，这和一些已经存在的研究相符 [20, 21]。由于精确算法十分耗时，在默认设定下需要至少一天的时间，因此我们不研究精确算法的表现。我们知道持续最优路线组合算法由两部分组成：初始路线搜索和批优化处理。我们提出的初始路线搜索合理考虑了自感知的思想和网络的动态性，为了验证其优越性，我们分别又实施了 **SBP*SA** 算法和 **SBP*DA** 算法。其中，**SBP*SA** 算法是初始路线搜索没有采用自感知思想的持续最优路线组合算法，即它没有考虑由我们规划系统规划的路线随交通流量造成的额外影响。**SBP*DA** 算法是没有考虑网络动态性的持续最优路线组合算法，它在初始路线搜索过程中面向的是一个静态的交通状态快照即一个行程的出发时刻所对应的静态交通状态。

2.5.1.4 运行环境

我们使用 CPU 运行时间和所有行程总的通行时间 $TT(\Pi)$ 作为算法效率和算法准确性的评估指标。除非特别申明，我们的实验结果是超过 20 次独立实验的平均值结果。所有的算法都是在 Windows 10 平台上运行的，采用 Java 编程，使用 Intel(R) Core(TM) i5-9300H Processor (2.40 GHz) 的处理器和 16GB 的内存。具体的默认参数设定见表2-2。

2.5.2 实验结果

2.5.2.1 行程请求数目对算法效果的影响




图 2-2 行程请求数目 $|Q|$ 对算法运行时间和全局通行时间的影响

首先,在默认参数设定下,我们考察了不同行程请求规模 $|Q|$ 对算法性能的影响。随着 $|Q|$ 的增加,系统中需要同时处理与协调的请求数量上升,这一方面扩大了批优化的搜索空间,另一方面也增强了路径之间的耦合效应,从而对算法的计算开销与整体通行效率产生影响。图2-2展示了我们提出的算法在 TG 路网和 NY 路网上的表现。在 NY 与 TG 两个路网中,所有算法的 CPU 时间均随着 $|Q|$ 的增加而单调上升,且整体呈近似线性增长趋势。这表明各方法在请求规模扩展时具有良好的可扩展性,没有出现计算复杂度急剧增长的现象。在运行开销方面,Ind 算法始终具有最低的 CPU 时间,这是因为该方法对每个请求独立进行路径规划,不涉及跨请求的批量协调优化,因此避免了额外的组合计算开销。相比之下,SBP、SBP*SA 与 SBP*DA 由于引入批处理与持续优化机制,计算成本略有增加,但增长趋势平稳,整体仍处于可接受范围内。我们也同时发现 Ind 算法产生的全局路线组合中所有路线总的通行时间 $TT(\Pi)$ 比其他算法更大,特别是在行程请求数目较大的情况下(例如,当在 NY 路网中 $|Q| = 10,000$ 和在 TG 路网中 $|Q| = 20,000$ 时,和 Ind 算法比较,我们的持续最优路线组合算法能够减少超过 40% 的通行时

间).

然而, 在总通行时间 $TT(\Pi)$ 指标上, Ind 算法明显劣于其他批优化方法, 且随着 $|Q|$ 的增加, 这种差距进一步扩大。当请求规模较小时, 不同路径之间的冲突有限, 个体最优与全局最优之间的差异相对较小; 而当 $|Q|$ 增大时, 大量行程共享关键路段, 局部独立规划会加剧拥堵, 导致系统整体效率下降。相比之下, 持续最优路线组合方法能够在批级别进行协调分配, 缓解热点路段的负载压力, 从而获得更优的全局通行效果。在高负载场景下, 这种优势尤为明显。例如, 在 NY 路网 $|Q| = 10,000$ 以及 TG 路网 $|Q| = 20,000$ 时, 与 Ind 算法相比, 所提出方法能够降低超过 40% 的总通行时间。这表明, 在动态且高密度的交通环境中, 全局协同优化机制的收益会随着请求规模的扩大而进一步放大。此外, 从 SBP、SBP*SA 与 SBP*DA 的对比结果可以观察到, 引入更精细的调整策略能够进一步降低 $TT(\Pi)$, 但同时带来一定的计算开销增加。这种性能与效率之间的权衡在不同规模下均保持稳定, 没有出现明显波动, 说明所提出方法在不同请求规模下具有良好的鲁棒性与稳定性。综上所述, 实验结果验证了持续最优路线组合方法在大规模动态请求环境下的有效性与可扩展性, 在可控计算开销的前提下显著提升了全局交通效率。

和持续最优路线组合算法相比, SBP*SA 和 SBP*DA 表现较差。因为它们会在优化过程中进行较多次数的交换操作, 这是非常耗时的。具体来说, SBP*SA 没有考虑到已经规划的路线也会对路段交通增加额外的车流量, 因此它在初始化路线搜索阶段进行的交通预测是不可靠的。对于 SBP*DA 算法, 它以一个行程出发时刻的交通状态快照进行路径规划。因此, SBP*SA 算法和 SBP*DA 算法所指定的初始化路线往往是低质量的, 需要在批优化过程中采取大量的交换操作来对这些低质量的初始路线进行调整, 从而产生了更多的计算消耗去提高结果质量。从图2-2(b)和图2-2(d)我们也观察到这三种算法产生的全局路线组合的所有路线的总的通行时间是非常接近的, 而且我们的持续最优路线组合算法总能产生较小的通行时间 $TT(\Pi)$ 。这些实验结果证实了通过采用自感知的思想和考虑到网络动态性, 我们的初始路线搜索能够有效地产生高质量的处理路线, 这样的初始路线可以减少后续优化处理过程中的交换操作次数。

2.5.2.2 行程请求到达速率对算法效果的影响

图2-3展示了在不同行程请求到达速率下, 持续最优路线组合算法的性能表现。行程请求到达速率反映了单位时间内进入系统的请求数量。当到达速率增大时, 意味着在相同时间窗口内将有更多车辆被分配到路网中, 从而加剧各路段的交通负载与路径之间的耦合程度。在图2-3, 可以观察到, 在 NY 与 TG 两个路网中, CPU

时间均随着到达速率的增加而单调上升。这是因为更高的请求到达速率会在每个优化周期内产生更多待处理请求，从而扩大批处理规模并增加协调计算开销。同样可以观察到，在两个路网上 $TT(\Pi)$ 均呈现明显上升趋势。这是由于随着单位时间内车辆数量增加，各路段的流量迅速累积，路段通行时间随之增长，进而导致全局路线组合的总通行时间增加。这一现象符合交通流理论中关于拥堵随流量增长而加剧的基本规律。此外，可以明显看到，在相同到达速率下，TG 路网的 $TT(\Pi)$ 始终显著高于 NY 路网。这主要是由于在默认实验设定中，TG 路网对应的总体请求规模更大，导致系统整体负载更高，从而产生更大的累计通行时间。同时，TG 路网规模与结构特性的差异也会进一步放大流量增长带来的拥堵效应。总体而言，实验结果表明，随着行程请求到达速率的提升，算法的计算开销与系统总通行时间均呈现稳定上升趋势，但增长过程平滑且可控，验证了持续最优路线组合方法在高频动态请求环境下的适应能力与鲁棒性。




图 2-3 行程请求到达速率的影响

2.5.2.3 通行时间函数各参数对算法效果的影响

图2-4展示了当通行时间函数中的参数 α 和 β (参见式 2-1) 发生变化时，持续最优路线组合算法的性能变化情况。根据通行时间函数的定义， α 控制流量对路段通行时间的放大程度，而 β 则调节流量影响的增长形态。因此，从直觉上看，较大的 α 或较小的 β 都会使路段通行时间对流量变化更加敏感，从而可能加剧拥堵效应。在图2-4(a)中，可以观察到，当 α 从 1 增加到 5 时，无论是在 NY 还是 TG 路网中，CPU 时间与总通行时间 $TT(\Pi)$ 均呈现明显上升趋势。这是因为更大的 α 会放大流量对路段通行时间的影响，使得拥堵效应更加显著，进而导致整体路线组合的累计通行时间增加。同时，由于路段代价差异被进一步拉大，算法在协调不同路径分配时需要处理更复杂的权衡关系，从而带来一定的计算开销增长。相比之下，当 β 从 1 增加到 3 时，总通行时间 $TT(\Pi)$ 在两个路网中均呈现下降趋势。这表明

较大的 β 在当前函数设定下缓解了通行时间对流量增长的敏感程度，从而减弱了拥堵的累积效应，使得整体路线组合更加高效。值得注意的是，当改变 β 的取值时，CPU 时间并未表现出显著的单调变化趋势。其主要原因在于，CPU 时间主要取决于请求规模与批优化过程的计算复杂度，而并不直接依赖于通行时间函数参数本身。参数 β 的变化虽然会影响路段代价的数值分布，但不会显著改变算法的搜索空间规模或计算流程，因此对计算开销的影响较为有限。

总体而言，该实验结果表明，通行时间函数参数对系统总通行时间具有显著影响，而对算法计算开销的影响相对有限。这进一步验证了持续最优路线组合方法在不同交通流敏感度设定下的稳定性与适应能力。




图 2-4 参数 α & β 的影响

2.5.2.4 优化时间间隔对算法表现的影响

图2-5展示了当批优化时间间隔 T 发生变化时，持续最优路线组合算法的性能表现。参数 T 控制系统进行一次批量重优化的时间跨度。较大的 T 意味着请求在进入优化队列后需要等待更长时间，但同时也能够一次优化过程中纳入更多尚未完成的行程请求，从而提升全局协调能力。在这种情况下，我们通过交换操作大大减少所有行程总的通行时间 $TT(\Pi)$ 。在图2-5(a)，可以观察到，在 NY 与 TG 两个路网中，CPU 时间均随着 T 的增加而近似线性上升。这是因为更大的时间间隔

会在单次优化过程中累积更多请求，使得批处理规模扩大，从而增加路径重分配与交换操作的计算开销。因此，计算成本与 T 呈正相关关系。在图2-5(b)中，显示总通行时间 $TT(\Pi)$ 随 T 的增加呈现轻微下降趋势。这表明，当优化间隔适度增大时，算法能够在更大的请求集合上进行全局协调，通过路径交换与负载重分配操作更有效地缓解热点路段的拥堵，从而提升整体通行效率。换言之，较大的 T 提供了更充分的全局信息，使得优化结果更加接近系统层面的最优解。需要注意的是， $TT(\Pi)$ 的下降幅度相对平缓，说明在当前实验设置下，算法在较小 T 时已经能够获得较为合理的解，而进一步扩大时间间隔仅带来边际收益的提升。这也体现出算法在不同优化频率下的稳定性。

总体而言，该实验揭示了优化时间间隔 T 在计算开销与优化效果之间所起到的调节作用。较小的 T 能够降低等待时间与计算成本，而较大的 T 则有助于提升全局协调能力并略微改善总通行时间。因此，在实际应用中，应根据实时性需求与系统负载情况选择合适的优化时间间隔，以在效率与效果之间取得平衡。




图 2-5 批优化时间间隔 T 的影响

2.5.2.5 参数 ϵ 和预检查策略对算法表现的影响

这里，我们研究了参数 ϵ 以及预检查策略对持续最优路线组合算法性能的影响。我们将 ϵ 从 0.0002 逐步增加至 0.001，分析其对计算开销与总通行时间的影响。根据算法 2-3，在优化过程中，有效交换操作的触发条件与参数 ϵ 成反比关系。 ϵ 越大，意味着判定一次交换为“有效”的门槛越高，从而可执行的有效交换次数减少。因此，随着 ϵ 的增大，算法在单次优化过程中的搜索深度降低，CPU 运行时间随之减少。然而，一个更大的 ϵ 也会产生具有更大通行时间的全局路线组合 Π 。在图2-6(a)中，可以观察到，在 NY 与 TG 两个路网中，CPU 时间均随着 ϵ 的增大呈现下降趋势。尤其当 ϵ 从 0.0002 增加至 0.0004 时，CPU 时间降幅最为显著。例如，在 NY 路网与 TG 路网中，CPU 时间分别减少超过 36% 与 19%，表明在较小

阈值区间内适当放宽有效交换标准能够显著降低计算开销。

与此同时，图2-6(b)显示总通行时间 $TT(\Pi)$ 随 ϵ 的增加呈现轻微上升趋势。这是因为较大的 ϵ 会减少可执行的优化操作次数，从而限制了路径重分配的充分性，使得最终得到的全局路线组合在通行效率上略有下降。然而，该增长幅度相对平缓，说明算法对 ϵ 具有一定鲁棒性。综合考虑计算效率与优化效果，可以发现当 $\epsilon = 0.001$ 时，算法在 CPU 时间与 $TT(\Pi)$ 之间取得了较好的平衡，因此该取值在当前实验设置下是一个较为合适的选择。这表明，通过合理设定参数 ϵ ，可以在保证通行效率基本稳定的前提下显著降低计算成本，从而提升算法整体性能。此外，我们进一步评估了预检查策略对算法效率的影响。记未使用预检查策略的持续最优路线组合算法为“SBP*PC”。从图2-6(c)可以看出，在不同请求规模 $|Q|$ 下，引入预检查策略的算法始终具有更低的 CPU 运行时间。该结果说明，预检查机制能够在正式执行交换操作前提前过滤无效或低收益的候选操作，从而有效减少不必要的计算开销，进一步提升算法效率。

综上所述，实验结果表明，参数 ϵ 与预检查策略均对算法性能具有显著影响。通过合理选择 ϵ 并结合预检查机制，持续最优路线组合算法能够在计算效率与全局通行效率之间实现更加理想的权衡。




图 2-6 参数 ϵ 和预检查策略的影响 (a) CPU 运行时间; (b) 通行时间; (c) 预先检查策略的影响评估

2.6 本章小结

近年来，随着自动驾驶技术与车联网技术的迅速发展，大量车辆可以在极短时间内向路径规划系统提交行程请求。尤其在早晚高峰等特定时段，行程请求呈现出密集、持续到达的特点，从而形成行程请求流。在这一新兴应用场景下，传统“逐个独立规划”的策略逐渐暴露出局限性。若系统仅基于当前时刻的交通状态为每个请求独立生成个人最优路径，则可能忽略已规划路径对未来交通状态的影响，从而在局部最优决策的叠加下诱发全局拥堵。基于此，我们提出和调查了一个新

颖的路线规划问题（持续最优路线组合问题），该问题旨在为持续的形成请求搜寻最佳的路线组合。我们提出了一个自感知的批处理算法来高效解决持续最优路线组合问题。同时，一些修剪枝技术的提出也大大提升了算法效率。批处理算法包含初始路线规划和批优化处理两个步骤。在初始路线搜索中，对于每一个新到达的行程请求（包含起点，终点，出发时刻），寻找一条在出发时刻出发，从起点能最快到达终点的路径（最短路径）。假设车辆通过特定路段的时间是和该路段的属性和车流量决定的，而车流量由两部分组成。一部分是非请求车辆车流量，即没有使用我们路线规划系统的车辆，直接作为输入数据，不是我们研究的范畴；一部分是请求车辆的车流量，即使用了我们规划系统的车辆，这些车辆按照规划的路线行驶而在经过的路段上增加的车流量。由于路网每个路段车流量是动态变化的，通行时间也会随之动态变化，我们就是要在这样一个动态变化的路网中寻找从出发时刻出发，起点到终点的最短路径。

初始路线搜索过程从起点开始，对与起点相连的邻接顶点做网络扩张，接着选择一个新的顶点继续扩张，直到扩张到终点。我们的扩张策略是，每次选择一个最可能最快到达终点的顶点作为下一个扩张顶点，什么是最可能最快到达终点的顶点呢？即（从起点到该点的精确耗时 + 从该点到终点的最小耗时）最小的顶点。从起点到该点的精确耗时是根据每个路段的实时车流量准确计算出来的，而从该点到终点的最小耗时是预处理中计算的。在预处理中，我们取每个路段的最小车流量作为静态的车流量，利用 *dijkstra* 算法计算顶点两两之间的最短路径（即耗时最小的路径），并将顶点两两之间的最小耗时存储起来作为我们初始路线搜索的算法输入。综上，我们从起点开始，按照该扩张策略一直扩张，直到扩张到终点，则我们就找到了一条在出发时刻能最快到达终点的路径。

在批优化处理过程中，对于在较短时间间隔（比如 1s）内发出的行程请求集合（包含起点，终点，出发时刻），我们为这些请求分别调用初始路线搜索后，这些初始路线可能会导致潜在的拥堵，从而增加对应路段的通行时间，（比如说行程数量很多，而它们规划的路线都要经过同一路段，则可能造成拥堵）。因此这些最优路线的部分路段是需要优化的，我们将在同一时间间隔（比如 1s）内发出的行程请求作为一个整体，对我们之前为它们规划的初始路线集合进行批优化处理。对于一批初始路线集合，我们批优化策略如下：1）从该集合中选取其中一条路线，将该集合内的其他路线看作已经发布的路线（其实还没有发布），假定这些用户将会按照发布的路线行驶，对应道路上就会增加一定车流量，从而全局车辆（包括之前已经规划的车辆在每个路段的耗时也会变化）。我们需要计算这些路线在各个路段增加的车流量，更新路段上的车流量，更新所有行程在各路段的通行时间，这些就相当于更新了交通信息。2）对于这个选取的初始路线，我们根据 1）更新的交通信

息，重新查找一条从起点到终点的最短路径。如果该最短路径不是原来的初始路线且经过计算该最短路径可以减少全局所有行程的耗时超过一定幅度，我们称新搜索到的这条最短路线是有效的，将原来的初始路线更新为新的最短路径。3) 重复 1) 2) 过程直到对于每一条路线，都不存在新的有效最短路径。将该批次优化后的路线发布给用户。对应的实验研究证实了我们提出的算法能够有效地解决该问题，也证实了我们提出的剪枝技术有够有助于避免不必要的计算。

第三章 后截断章节

致 谢

本研究及学位论文是在我的导师商烁教授的亲切关怀和悉心指导下完成的。他严肃的科学态度，严谨的治学精神，精益求精的工作作风，深深地感染和激励着我。老师不仅在学业上给我以精心指导，同时还在思想、生活上给我以无微不至的关怀，在此谨向商烁教授致以诚挚的谢意和崇高的敬意。

感谢我的副导师吴刚副教授。吴老师在我攻博期间的科研道路中给予了我极大的帮助，每当遇到科研难题，吴老师都会为我提供正确的思路，并且耐心帮助我解决许多实际问题。在投稿学术论文和撰写博士学位论文的过程中，吴老师都帮助我进行了细致的审阅和修改，使我的科研内容顺利完成。

攻读博士学习时光已经接近尾声，在此我想对我的母校，我的父母、亲人们，我的老师和同学们表达我由衷的谢意。感谢东北大学的老师和同门的关心和鼓励。老师们课堂上的激情洋溢，课堂下的谆谆教诲；同学们在学习中的认真热情，生活上的热心主动，所有这些都让我的七年充满了感动。这次毕业论文设计我得到了很多老师和同学的帮助，其中我的论文指导老师王国仁老师对我的关心和支持尤为重要。王国仁老师不仅在学业上给我以精心指导，同时还在思想给我以无微不至的关怀，在此谨向王国仁老师致以诚挚的谢意和崇高的敬意。同时，本篇毕业论文的写作也得到了实验室的等老师的热情帮助。我要感谢和我在一个小组里并肩作战，共同学习的同学们，感谢李，以及实验室其他师姐师兄和师弟师妹和曾经在各个方面给予过我帮助的伙伴们，在此，我再一次真诚地向帮助过我的老师和同学表示感谢！

感谢培养教育我的学校，浓厚的学术氛围，舒适的学习环境我将终生难忘！祝母校蒸蒸日上，永创辉煌！感谢对我倾囊赐教、鞭策鼓励的东北大学诸位师长，诸位恩师的谆谆训诲我将铭记在心。祝恩师们身体健康，家庭幸福！感谢论文中引文的原作者，他们都是计算机界的名师大家，大师风范，高山仰止。祝他们寿域无疆，德业永辉！感谢同窗好友以及更多我无法逐一列出名字的朋友，他们和我共同度过了七年美好难忘的大学时光，我非常珍视和他们的友谊！祝他们前程似锦，事业有成！最后，我要感谢我的父母和亲人，无论我面对任何失败和挫折，你们都给予我最体贴的关怀和安慰，让我感受到家永远都是我最坚实的后盾，我才能无所畏惧的一路向前。你们坚定的支持给予我无限的动力，使我能够克服和战胜生活路上的艰难险阻，在人生路上不断前行。今后，我会用自己不懈的努力来回报你们的恩情。感谢生活中众多给了我鼓励和帮助的亲朋好友，我在这里无法一一列出

他们的名字，但是他们对我的恩情我永远不会忘记，在这里写下我对他们的感激。

The length of the *Acknowledgement* has exceeded the maximum limit of 1 page(s).

The length of the *Acknowledgement* has exceeded the maximum limit of 1 page(s).

The length of the *Acknowledgement* has exceeded the maximum limit of 1 page(s).

参考文献

- [1] Dumitrescu I, Boland N. Improved preprocessing, labeling and scaling algorithms for the weight-constrained shortest path problem[J]. *Networks*, 2003, 42(3): 135–153.
- [2] Sharifzadeh M, Kolahdouzan M R, Shahabi C. The optimal sequenced route query[J]. *VLDB J.*, 2008, 17(4): 765–787.
- [3] Levin R, Kanza Y, Safra E, et al. Interactive route search in the presence of order constraints[J]. *Proc. VLDB Endow.*, 2010, 3(1): 117–128.
- [4] Shang S, Lu H, Pedersen T B, et al. Modeling of traffic-aware travel time in spatial networks[C]. *MDM (1)*, IEEE Computer Society, 2013: 247–250.
- [5] Li J, Yang Y D, Mamoulis N. Optimal route queries with arbitrary order constraints[J]. *IEEE Trans. Knowl. Data Eng.*, 2013, 25(5): 1097–1110.
- [6] Zeng Y, Chen X, Cao X, et al. Optimal route search with the coverage of users' preferences[C]. *IJCAI*, AAAI Press, 2015: 2118–2124.
- [7] Xu Y, Chen L, Yao B, et al. Location-based top-k term querying over sliding window[C]. *WISE (1)*, Springer, vol. 10569 of Lecture Notes in Computer Science, 2017: 299–314.
- [8] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[J]. *TKDE*, 2016, 28(5): 1132–1146.
- [9] Guo C, Yang B, Hu J, et al. Learning to route with sparse trajectory sets[C]. *34th IEEE International Conference on Data Engineering, ICDE 2018, Paris, France, April 16-19, 2018*, IEEE Computer Society, 2018: 1073–1084.
- [10] Chen L, Shang S, Jensen C S, et al. Effective and efficient reuse of past travel behavior for route recommendation[C]. *KDD*, ACM, 2019: 488–498.
- [11] Chen L, Shang S, Guo T. Real-time route search by locations[C]. *AAAI*, AAAI Press, 2020: 574–581.
- [12] Chen L, Shang S, Yao B, et al. Pay your trip for traffic congestion: Dynamic pricing in traffic-aware road networks[C]. *AAAI*, AAAI Press, 2020: 582–589.
- [13] Chen Z, Shen H T, Zhou X, et al. Searching trajectories by locations: an efficiency study[C]. *SIGMOD Conference*, ACM, 2010: 255–266.
- [14] Cao X, Chen L, Cong G, et al. Keyword-aware optimal route search[J]. *Proc. VLDB Endow.*, 2012, 5(11): 1136–1147.
- [15] Shang S, Ding R, Zheng K, et al. Personalized trajectory matching in spatial networks[J]. *VLDB J.*, 2014, 23(3): 449–468.

- [16] Liebig T, Piatkowski N, Bockermann C, et al. Dynamic route planning with real-time traffic predictions[J]. *Inf. Syst.*, 2017, 64: 258–265.
- [17] Dafermos, C S. The traffic assignment problem for multiclass-user transportation networks[J]. *Transportation Science*, 1972, 6(1): 73-87.
- [18] Lim S, Rus D. Stochastic distributed multi-agent planning and applications to traffic[J]. *ICRA*, 2012: 2873-2879.
- [19] Babak J, Abbas B, (Avi) C A. Path-based capacity-restrained dynamic traffic assignment algorithm[J]. *Transportmetrica B: Transport Dynamics*, 2018: 1-24.
- [20] Malviya N, Madden S, Bhattacharya A. A continuous query system for dynamic route planning[C]. *ICDE*, IEEE Computer Society, 2011: 792–803.
- [21] Xu J, Guo L, Ding Z, et al. Traffic aware route planning in dynamic road networks[C]. *DASFAA* (1), Springer, vol. 7238 of *Lecture Notes in Computer Science*, 2012: 576–591.
- [22] Li K, Chen L, Shang S. Towards alleviating traffic congestion: Optimal route planning for massive-scale trips[C]. *IJCAI*, ijcai.org, 2020: 3400–3406.
- [23] Dijkstra E W. A note on two problems in connexion with graphs[J]. *Numerische Mathematik*, 1959, 1: 269-271.
- [24] Huang J, Huangfu X, Sun H, et al. Backward path growth for efficient mobile sequential recommendation[J]. *IEEE Trans. Knowl. Data Eng.*, 2015, 27(1): 46–60.
- [25] Dijkstra E W. A note on two problems in connexion with graphs[J]. *Numerische Mathematik*, 1959, 1: 269–271.
- [26] Zheng L, Chen L, Ye J. Order dispatch in price-aware ridesharing[J]. *Proc. VLDB Endow.*, 2018, 11(8): 853–865.
- [27] Ma S, Zheng Y, Wolfson O. T-share: A large-scale dynamic taxi ridesharing service[C]. *ICDE*, IEEE Computer Society, 2013: 410–421.
- [28] Huang Y, Bastani F, Jin R, et al. Large scale real-time ridesharing with service guarantee on road networks[J]. *Proc. VLDB Endow.*, 2014, 7(14): 2017–2028.
- [29] Ma S, Zheng Y, Wolfson O. Real-time city-scale taxi ridesharing[J]. *IEEE Trans. Knowl. Data Eng.*, 2015, 27(7): 1782–1795.
- [30] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[C]. *ICDE*, IEEE Computer Society, 2017: 59–60.
- [31] Li F, Cheng D, Hadjieleftheriou M, et al. On trip planning queries in spatial databases[C]. *SSTD*, Springer, vol. 3633 of *Lecture Notes in Computer Science*, 2005: 273–290.
- [32] Chen H, Ku W, Sun M, et al. The multi-rule partial sequenced route query[C]. *GIS*, ACM, 2008: 10.

-
- [33] Kanza Y, Safra E, Sagiv Y, et al. Heuristic algorithms for route-search queries over geographical data[C]. GIS, ACM, 2008: 11.
 - [34] Kanza Y, Levin R, Safra E, et al. An interactive approach to route search[C]. GIS, ACM, 2009: 408–411.
 - [35] Kanza Y, Safra E, Sagiv Y. Route search over probabilistic geospatial data[C]. SSTD, Springer, vol. 5644 of Lecture Notes in Computer Science, 2009: 153–170.
 - [36] Yao B, Tang M, Li F. Multi-approximate-keyword routing in GIS data[C]. GIS, ACM, 2011: 201–210.
 - [37] Zheng B, Su H, Hua W, et al. Efficient clue-based route search on road networks[J]. IEEE Trans. Knowl. Data Eng., 2017, 29(9): 1846–1859.
 - [38] Roy S B, Das G, Amer-Yahia S, et al. Interactive itinerary planning[C]. ICDE, IEEE Computer Society, 2011: 15–26.
 - [39] Cao X, Cong G, Jensen C S, et al. Collective spatial keyword querying[C]. SIGMOD Conference, ACM, 2011: 373–384.
 - [40] Ding B, Yu J X, Qin L. Finding time-dependent shortest paths over large graphs[C]. EDBT, ACM, vol. 261 of ACM International Conference Proceeding Series, 2008: 205–216.
 - [41] Cai X, Kloks T, Wong C K. Time-varying shortest path problems with constraints[J]. Networks, 1997, 29(3): 141–150.
 - [42] Kanoulas E, Du Y, Xia T, et al. Finding fastest paths on A road network with speed patterns[C]. ICDE, IEEE Computer Society, 2006: 10.
 - [43] Narváez P, Siu K, Tzeng H. New dynamic SPT algorithm based on a ball-and-string model[J]. IEEE/ACM Trans. Netw., 2001, 9(6): 706–718.
 - [44] Huang W, Yan C, Wang J, et al. A time-delay neural network for solving time-dependent shortest path problem[J]. Neural Networks, 2017, 90: 21–28.
 - [45] Liang H, Wang K. Top-k route search through submodularity modeling of recurrent POI features[C]. SIGIR, ACM, 2018: 545–554.
 - [46] Gionis A, Lappas T, Pelechrinis K, et al. Customized tour recommendations in urban areas[C]. WSDM, ACM, 2014: 313–322.
 - [47] Zhang C, Liang H, Wang K. Trip recommendation meets real-world constraints: POI availability, diversity, and traveling time uncertainty[J]. ACM Trans. Inf. Syst., 2016, 35(1): 5:1–5:28.
 - [48] Lu E H, Chen C, Tseng V S. Personalized trip recommendation with multiple constraints by mining user check-in behaviors[C]. SIGSPATIAL/GIS, ACM, 2012: 209–218.
 - [49] Terrovitis M, Bakiras S, Papadias D, et al. Constrained shortest path computation[C]. SSTD, Springer, vol. 3633 of Lecture Notes in Computer Science, 2005: 181–199.

- [50] Ma X, Shekhar S, Xiong H, et al. Exploiting a page-level upper bound for multi-type nearest neighbor queries[C]. GIS, ACM, 2006: 179–186.
- [51] Lim S, Balakrishnan H, Gifford D, et al. Stochastic motion planning and applications to traffic[J]. Int. J. Robotics Res., 2011, 30(6): 699–712.
- [52] Wilkie D, van den Berg J P, Lin M C, et al. Self-aware traffic route planning[C]. Proceedings of the Twenty-Fifth AAAI Conference on Artificial Intelligence, AAAI 2011, San Francisco, California, USA, August 7-11, 2011, AAAI Press.
- [53] Htoo H, Ohsawa Y, Sonehara N, et al. Optimal sequenced route query algorithm using visited POI graph[C]. Web-Age Information Management - 13th International Conference, WAIM 2012, Harbin, China, August 18-20, 2012. Proceedings, Springer, vol. 7418 of Lecture Notes in Computer Science, 2012: 198–209.
- [54] Chen H, Ku W, Sun M, et al. The partial sequenced route query with traveling rules in road networks[J]. GeoInformatica, 2011, 15(3): 541–569.
- [55] Jossé G, Schmid K A, Schubert M. Probabilistic resource route queries with reappearance[C]. Proceedings of the 18th International Conference on Extending Database Technology, EDBT 2015, Brussels, Belgium, March 23-27, 2015, OpenProceedings.org, 2015: 445–456.
- [56] Fan L, Bonomi L, Shahabi C, et al. Optimal group route query: Finding itinerary for group of users in spatial databases[J]. GeoInformatica, 2018, 22(4): 845–867.
- [57] Li Y, Yang W, Dan W, et al. Keyword-aware dominant route search for various user preferences[C]. Database Systems for Advanced Applications - 20th International Conference, DAS-FAA 2015, Hanoi, Vietnam, April 20-23, 2015, Proceedings, Part II, Springer, vol. 9050 of Lecture Notes in Computer Science, 2015: 207–222.
- [58] Yang B, Guo C, Ma Y, et al. Toward personalized, context-aware routing[J]. VLDB J., 2015, 24(2): 297–318.
- [59] Christofides N. Worst-case analysis of a new heuristic for the traveling salesman problem[J]. 1976.
- [60] Ceikute V, Jensen C S. Vehicle routing with user-generated trajectory data[C]. MDM (1), IEEE Computer Society, 2015: 14–23.
- [61] Luo W, Tan H, Chen L, et al. Finding time period-based most frequent path in big trajectory data[C]. SIGMOD Conference, ACM, 2013: 713–724.
- [62] Letchner J, Krumm J, Horvitz E. Trip router with individualized preferences (TRIP): incorporating personalization into route planning[C]. AAAI, AAAI Press, 2006: 1795–1800.
- [63] Balteanu A, Jossé G, Schubert M. Mining driving preferences in multi-cost networks[C]. SSTO, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 74–91.

- [64] Salgado C, Cheema M A, Taniar D. An efficient approximation algorithm for multi-criteria indoor route planning queries[C]. SIGSPATIAL/GIS, ACM, 2018: 448–451.
- [65] Ahmadi E, Nascimento M A. A mixed breadth-depth first search strategy for sequenced group trip planning queries[C]. 16th IEEE International Conference on Mobile Data Management, MDM 2015, Pittsburgh, PA, USA, June 15-18, 2015 - Volume 1, IEEE Computer Society, 2015: 24–33.
- [66] Hashem T, Barua S, Ali M E, et al. Efficient computation of trips with friends and families[C]. Proceedings of the 24th ACM International Conference on Information and Knowledge Management, CIKM 2015, Melbourne, VIC, Australia, October 19 - 23, 2015, ACM, 2015: 931–940.
- [67] Fan L, Bonomi L, Shahabi C, et al. Multi-user itinerary planning for optimal group preference[C]. Advances in Spatial and Temporal Databases - 15th International Symposium, SSTD 2017, Arlington, VA, USA, August 21-23, 2017, Proceedings, Springer, vol. 10411 of Lecture Notes in Computer Science, 2017: 3–23.
- [68] Hashem T, Hashem T, Ali M E, et al. Group trip planning queries in spatial databases[C]. Advances in Spatial and Temporal Databases - 13th International Symposium, SSTD 2013, Munich, Germany, August 21-23, 2013. Proceedings, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 259–276.
- [69] Li M, Li X, Yin J. TORD problem and its solution based on big trajectories data[J]. IEEE Trans. Intell. Transp. Syst., 2016, 17(6): 1666–1677.
- [70] Levin R, Kanza Y. TARS: traffic-aware route search[J]. GeoInformatica, 2014, 18(3): 461–500.
- [71] Anwar A, Hashem T. Optimal obstructed sequenced route queries in spatial databases[C]. Proceedings of the 20th International Conference on Extending Database Technology, EDBT 2017, Venice, Italy, March 21-24, 2017, OpenProceedings.org, 2017: 522–525.
- [72] Samrose S, Hashem T, Barua S, et al. Efficient computation of group optimal sequenced routes in road networks[C]. 16th IEEE International Conference on Mobile Data Management, MDM 2015, Pittsburgh, PA, USA, June 15-18, 2015 - Volume 1, IEEE Computer Society, 2015: 122–127.
- [73] Sharifzadeh M, Shahabi C. Processing optimal sequenced route queries using voronoi diagrams[J]. GeoInformatica, 2008, 12(4): 411–433.
- [74] Soma S C, Hashem T, Cheema M A, et al. Trip planning queries with location privacy in spatial databases[J]. World Wide Web, 2017, 20(2): 205–236.
- [75] Feng Z, Liu T, Li H, et al. Indoor top-k keyword-aware routing query[C]. ICDE, IEEE, 2020: 1213–1224.

- [76] Yawalkar P, Ranu S. Route recommendations on road networks for arbitrary user preference functions[C]. ICDE, IEEE, 2019: 602–613.
- [77] Li R, Qin L, Yu J X, et al. Optimal multi-meeting-point route search[J]. IEEE Trans. Knowl. Data Eng., 2016, 28(3): 770–784.
- [78] Dotoli M, Hammadi S, Jeribi K, et al. A multi-agent decision support system for optimization of co-modal transportation route planning services[C]. CDC, IEEE, 2013: 911–916.
- [79] Lim S, Rus D. Stochastic distributed multi-agent planning and applications to traffic[C]. ICRA, IEEE, 2012: 2873–2879.
- [80] Li W, Cao J, Guan J, et al. Efficient retrieval of bounded-cost informative routes[C]. ICDE, IEEE Computer Society, 2018: 1811–1812.
- [81] Wen Y T, Yeo J, Peng W, et al. Efficient keyword-aware representative travel route recommendation[J]. IEEE Trans. Knowl. Data Eng., 2017, 29(8): 1639–1652.
- [82] Pedersen S A, Yang B, Jensen C S. Anytime stochastic routing with hybrid learning[J]. Proc. VLDB Endow., 2020, 13(9): 1555–1567.
- [83] Pedersen S A, Yang B, Jensen C S. Fast stochastic routing under time-varying uncertainty[J]. VLDB J., 2020, 29(4): 819–839.
- [84] Guo C, Yang B, Hu J, et al. Context-aware, preference-based vehicle routing[J]. VLDB J., 2020, 29(5): 1149–1170.
- [85] Liu H, Jin C, Yang B, et al. Finding top-k optimal sequenced routes[C]. ICDE, IEEE Computer Society, 2018: 569–580.
- [86] Zeng Y, Tong Y, Song Y, et al. The simpler the better: An indexing approach for shared-route planning queries[J]. Proc. VLDB Endow., 2020, 13(13): 3517–3530.
- [87] Zhang C, Liang H, Wang K, et al. Personalized trip recommendation with POI availability and uncertain traveling time[C]. Proceedings of the 24th ACM International Conference on Information and Knowledge Management, CIKM 2015, Melbourne, VIC, Australia, October 19 - 23, 2015, ACM, 2015: 911–920.
- [88] Dai J, Yang B, Guo C, et al. Path cost distribution estimation using trajectory data[J]. Proc. VLDB Endow., 2016, 10(3): 85–96.
- [89] Yang B, Dai J, Guo C, et al. PACE: a path-centric paradigm for stochastic path finding[J]. VLDB J., 2018, 27(2): 153–178.
- [90] Frigioni D, Marchetti-Spaccamela A, Nanni U. Fully dynamic output bounded single source shortest path problem (extended abstract)[C]. SODA, ACM/SIAM, 1996: 212–221.
- [91] King V. Fully dynamic algorithms for maintaining all-pairs shortest paths and transitive closure in digraphs[C]. FOCS, IEEE Computer Society, 1999: 81–91.

-
- [92] Demetrescu C, Italiano G F. A new approach to dynamic all pairs shortest paths[J]. J. ACM, 2004, 51(6): 968–992.
 - [93] Roditty L, Zwick U. On dynamic shortest paths problems[J]. Algorithmica, 2011, 61(2): 389–401.
 - [94] Deng K, Zhou X, Shen H T. Multi-source skyline query processing in road networks[C]. ICDE, IEEE Computer Society, 2007: 796–805.
 - [95] Yang B, Guo C, Jensen C S, et al. Stochastic skyline route planning under time-varying uncertainty[C]. ICDE, IEEE Computer Society, 2014: 136–147.
 - [96] Wang Y, Li G, Tang N. Querying shortest paths on time dependent road networks[J]. Proc. VLDB Endow., 2019, 12(11): 1249–1261.
 - [97] Wilkie D, Baykal C, Lin M C. Participatory route planning[C]. SIGSPATIAL/GIS, ACM, 2014: 213–222.
 - [98] Shang S, Lu H, Pedersen T B, et al. Finding traffic-aware fastest paths in spatial networks[C]. SSTO, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 128–145.
 - [99] Kriegel H, Renz M, Schubert M. Route skyline queries: A multi-preference path planning approach[C]. ICDE, IEEE Computer Society, 2010: 261–272.
 - [100] Likhachev M, Ferguson D I, Gordon G J, et al. Anytime dynamic a*: An anytime, replanning algorithm[C]. ICAPS, AAAI, 2005: 262–271.
 - [101] Hershberger J, Maxel M, Suri S. Finding the k shortest simple paths: A new algorithm and its implementation[J]. ACM Trans. Algorithms, 2007, 3(4): 45.
 - [102] Aljubayrin S, Yang B, Jensen C S, et al. Finding non-dominated paths in uncertain road networks[C]. SIGSPATIAL/GIS, ACM, 2016: 15:1–15:10.
 - [103] Asghari M, Emrich T, Demiryurek U, et al. Probabilistic estimation of link travel times in dynamic road networks[C]. SIGSPATIAL/GIS, ACM, 2015: 47:1–47:10.
 - [104] Ge Y, Xiong H, Tuzhilin A, et al. An energy-efficient mobile recommender system[C]. Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Washington, DC, USA, July 25-28, 2010, ACM, 2010: 899–908.
 - [105] Ye Z, Xiao K, Deng Y. A unified theory of the mobile sequential recommendation problem[C]. IEEE International Conference on Data Mining, ICDM 2018, Singapore, November 17-20, 2018, IEEE Computer Society, 2018: 1380–1385.
 - [106] Ye Z, Xiao K, Ge Y, et al. Applying simulated annealing and parallel computing to the mobile sequential recommendation[J]. IEEE Trans. Knowl. Data Eng., 2019, 31(2): 243–256.

- [107] Ye Z, Zhang L, Xiao K, et al. Multi-user mobile sequential recommendation: An efficient parallel computing paradigm[C]. Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD 2018, London, UK, August 19-23, 2018, ACM, 2018: 2624–2633.
- [108] Huang J, Huangfu X, Sun H, et al. Backward path growth for efficient mobile sequential recommendation[J]. CoRR, 2013, abs/1304.2144.
- [109] Reza R M, Ali M E, Cheema M A. The optimal route and stops for a group of users in a road network[C]. Proceedings of the 25th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, GIS 2017, Redondo Beach, CA, USA, November 7-10, 2017, ACM, 2017: 4:1–4:10.
- [110] Brakatsoulas S, Pfoser D, Salas R, et al. On map-matching vehicle tracking data[C]. Proceedings of the 31st International Conference on Very Large Data Bases, ACM, 2005: 853–864.
- [111] Chondrogiannis T, Bouros P, Gamper J, et al. Finding k-shortest paths with limited overlap[J]. VLDB J., 2020, 29(5): 1023–1047.
- [112] Frentzos E, Gratsias K, Theodoridis Y. Index-based most similar trajectory search[C]. ICDE, IEEE Computer Society, 2007: 816–825.
- [113] Sankararaman S, Agarwal P K, Mølhave T, et al. Model-driven matching and segmentation of trajectories[C]. SIGSPATIAL/GIS, ACM, 2013: 234–243.
- [114] Agrawal R, Faloutsos C, Swami A N. Efficient similarity search in sequence databases[C]. FODO, Springer, vol. 730 of Lecture Notes in Computer Science, 1993: 69–84.
- [115] Morris B, Trivedi M M. Learning trajectory patterns by clustering: Experimental studies and comparative evaluation[C]. CVPR, IEEE Computer Society, 2009: 312–319.
- [116] Picciarelli C, Foresti G L. On-line trajectory clustering for anomalous events detection[J]. Pattern Recognit. Lett., 2006, 27(15): 1835–1842.
- [117] Zheng B, Yuan N J, Zheng K, et al. Approximate keyword search in semantic trajectory database[C]. ICDE, IEEE Computer Society, 2015: 975–986.
- [118] Lu E H, Lin C, Tseng V S. Trip-mine: An efficient trip planning approach with travel time constraints[C]. Mobile Data Management (1), IEEE Computer Society, 2011: 152–161.
- [119] Dai J, Yang B, Guo C, et al. Personalized route recommendation using big trajectory data[C]. ICDE, IEEE Computer Society, 2015: 543–554.
- [120] Yi B, Jagadish H V, Faloutsos C. Efficient retrieval of similar time sequences under time warping[C]. Proceedings of the Fourteenth International Conference on Data Engineering, Orlando, Florida, USA, February 23-27, 1998, IEEE Computer Society, 1998: 201–208.

- [121] Perng C, Wang H, Zhang S R, et al. Landmarks: a new model for similarity-based pattern querying in time series databases[C]. Proceedings of the 16th International Conference on Data Engineering, San Diego, California, USA, February 28 - March 3, 2000, IEEE Computer Society, 2000: 33–42.
- [122] Vlachos M, Gunopulos D, Kollios G. Discovering similar multidimensional trajectories[C]. Proceedings of the 18th International Conference on Data Engineering, San Jose, CA, USA, February 26 - March 1, 2002, IEEE Computer Society, 2002: 673–684.
- [123] Mamoulis N, Cao H, Kollios G, et al. Mining, indexing, and querying historical spatiotemporal data[C]. KDD, ACM, 2004: 236–245.
- [124] Giannotti F, Nanni M, Pinelli F, et al. Trajectory pattern mining[C]. KDD, ACM, 2007: 330–339.
- [125] Gonzalez H, Han J, Li X, et al. Adaptive fastest path computation on a road network: A traffic mining approach[C]. VLDB, ACM, 2007: 794–805.
- [126] Cancela B, Ortega M, Fernández A, et al. Trajectory similarity measures using minimal paths[C]. ICIAP (1), Springer, vol. 8156 of Lecture Notes in Computer Science, 2013: 400–409.
- [127] Chen L, Ng R T. On the marriage of lp-norms and edit distance[C]. (e)Proceedings of the Thirtieth International Conference on Very Large Data Bases, VLDB 2004, Toronto, Canada, August 31 - September 3 2004, Morgan Kaufmann, 2004: 792–803.
- [128] Chen L, Özsu M T, Oria V. Robust and fast similarity search for moving object trajectories[C]. Proceedings of the ACM SIGMOD International Conference on Management of Data, Baltimore, Maryland, USA, June 14-16, 2005, ACM, 2005: 491–502.
- [129] Wu G, Ding Y, Li Y, et al. Mining spatio-temporal reachable regions over massive trajectory data[C]. ICDE, IEEE Computer Society, 2017: 1283–1294.
- [130] Yao D, Zhang C, Zhu Z, et al. Learning deep representation for trajectory clustering[J]. Expert Syst. J. Knowl. Eng., 2018, 35(2).
- [131] Chen L, Shang S, Yang C, et al. Spatial keyword search: a survey[J]. GeoInformatica, 2020, 24(1): 85–106.
- [132] Shang S, Chen L, Wei Z, et al. Parallel trajectory similarity joins in spatial networks[J]. VLDB J., 2018, 27(3): 395–420.
- [133] Chen Y, Nascimento M A, Ooi B C, et al. Spade: On shape-based pattern detection in streaming time series[C]. Chirkova R, Dogac A, Özsu M T, et al., (Eds.) Proceedings of the 23rd International Conference on Data Engineering, ICDE 2007, The Marmara Hotel, Istanbul, Turkey, April 15-20, 2007, IEEE Computer Society, 2007: 786–795.

- [134] Alt H. The computational geometry of comparing shapes[C]. Albers S, Alt H, Näher S, (Eds.) *Efficient Algorithms, Essays Dedicated to Kurt Mehlhorn on the Occasion of His 60th Birthday*, Springer, vol. 5760 of *Lecture Notes in Computer Science*, 2009: 235–248.
- [135] Nakamura T, Taki K, Nomiya H, et al. A shape-based similarity measure for time series data with ensemble learning[J]. *Pattern Anal. Appl.*, 2013, 16(4): 535–548.
- [136] Chen L, Özsu M T, Oria V. Symbolic representation and retrieval of moving object trajectories[C]. Lew M S, Sebe N, Djeraba C, (Eds.) *Proceedings of the 6th ACM SIGMM International Workshop on Multimedia Information Retrieval, MIR 2004, October 15-16, 2004, New York, NY, USA, ACM*, 2004: 227–234.
- [137] Shang S, Chen L, Wei Z, et al. Trajectory similarity join in spatial networks[J]. *Proc. VLDB Endow.*, 2017, 10(11): 1178–1189.
- [138] Zhou Y, Yan S, Huang T S. Detecting anomaly in videos from trajectory similarity analysis[C]. *Proceedings of the 2007 IEEE International Conference on Multimedia and Expo, ICME 2007, July 2-5, 2007, Beijing, China, IEEE Computer Society*, 2007: 1087–1090.
- [139] de Oliveira E Silva R, Cui G, Rahimi S M, et al. Br²: A travel behavioral approach to personalized route recommendation based on GPS trajectories[C]. *Proceedings of the Workshops of the EDBT/ICDT 2020 Joint Conference, Copenhagen, Denmark, March 30, 2020, CEUR-WS.org*, vol. 2578 of *CEUR Workshop Proceedings*.
- [140] Shang S, Chen L, Jensen C S, et al. Searching trajectories by regions of interest[C]. *34th IEEE International Conference on Data Engineering, ICDE 2018, Paris, France, April 16-19, 2018, IEEE Computer Society*, 2018: 1741–1742.
- [141] Shang S, Ding R, Yuan B, et al. User oriented trajectory search for trip recommendation[C]. *15th International Conference on Extending Database Technology, EDBT '12, Berlin, Germany, March 27-30, 2012, Proceedings, ACM*, 2012: 156–167.
- [142] Zheng K, Shang S, Yuan N J, et al. Towards efficient search for activity trajectories[C]. Jensen C S, Jermaine C M, Zhou X, (Eds.) *29th IEEE International Conference on Data Engineering, ICDE 2013, Brisbane, Australia, April 8-12, 2013, IEEE Computer Society*, 2013: 230–241.
- [143] Morse M D, Patel J M. An efficient and accurate method for evaluating time series similarity[C]. Chan C Y, Ooi B C, Zhou A, (Eds.) *Proceedings of the ACM SIGMOD International Conference on Management of Data, Beijing, China, June 12-14, 2007, ACM*, 2007: 569–580.
- [144] Sherkat R, Rafiei D. On efficiently searching trajectories and archival data for historical similarities[J]. *Proc. VLDB Endow.*, 2008, 1(1): 896–908.

- [145] Chen Z, Shen H T, Zhou X. Discovering popular routes from trajectories[C]. Abiteboul S, Böhm K, Koch C, et al., (Eds.) Proceedings of the 27th International Conference on Data Engineering, ICDE 2011, April 11-16, 2011, Hannover, Germany, IEEE Computer Society, 2011: 900–911.
- [146] Wang S, Bao Z, Culpepper J S, et al. A survey on trajectory data management, analytics, and learning[J]. ACM Comput. Surv., 2021, 54(2): 39:1–39:36.
- [147] Mazimpaka J D, Timpf S. Trajectory data mining: A review of methods and applications[J]. J. Spatial Inf. Sci., 2016, 13(1): 61–99.
- [148] Su H, Liu S, Zheng B, et al. A survey of trajectory distance measures and performance evaluation[J]. VLDB J., 2020, 29(1): 3–32.
- [149] Mahmood A R, Punni S, Aref W G. Spatio-temporal access methods: a survey (2010 - 2017)[J]. GeoInformatica, 2019, 23(1): 1–36.
- [150] Mahmood A R, Aref W G. Scalable Processing of Spatial-Keyword Queries[M]. Synthesis Lectures on Data Management. Morgan & Claypool Publishers, 2019.
- [151] Cao X, Chen L, Cong G, et al. Spatial keyword querying[C]. Conceptual Modeling, Springer, 2012: 16–29.
- [152] Chen L, Cong G, Jensen C S, et al. Spatial keyword query processing: An experimental evaluation[J]. Proc. VLDB Endow., 2013, 6(3): 217–228.
- [153] Chen Z, Chen L, Cong G, et al. Location-and keyword-based querying of geo-textual data: a survey[J]. The VLDB Journal, 2021: 1–38.
- [154] Ranu S, P D, Telang A D, et al. Indexing and matching trajectories under inconsistent sampling rates[C]. ICDE, IEEE Computer Society, 2015: 999–1010.
- [155] Xu X, Yuruk N, Feng Z, et al. SCAN: a structural clustering algorithm for networks[C]. SIGKDD, ACM, 2007: 824–833.
- [156] Li H, Liu J, Wu K, et al. Spatio-temporal vessel trajectory clustering based on data mapping and density[J]. IEEE Access, 2018, 6: 58939–58954.
- [157] Lee J, Han J, Whang K. Trajectory clustering: a partition-and-group framework[C]. SIGKDD, ACM, 2007: 593–604.
- [158] Pelekis N, Kopanakis I, Kotsifakos E E, et al. Clustering trajectories of moving objects in an uncertain world[C]. ICDM, IEEE Computer Society, 2009: 417–427.
- [159] Li Z, Lee J, Li X, et al. Incremental clustering for trajectories[C]. DASFAA, Springer, vol. 5982 of Lecture Notes in Computer Science, 2010: 32–46.
- [160] Chen L, Gao Y, Fang Z, et al. Real-time distributed co-movement pattern detection on streaming trajectories[J]. Proc. VLDB Endow., 2019, 12(10): 1208–1220.

- [161] Su H, Zheng K, Wang H, et al. Calibrating trajectory data for similarity-based analysis[C]. SIGMOD, ACM, 2013: 833–844.
- [162] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. GIS, ACM, 2009: 286–295.
- [163] Güting R H, Schneider M. Realm-based spatial data types: The ROSE algebra[J]. VLDB J., 1995, 4(2): 243–286.
- [164] Wang H, Su H, Zheng K, et al. An effectiveness study on trajectory similarity measures[C]. ADC, Australian Computer Society, vol. 137 of CRPIT, 2013: 13–22.
- [165] Li X, Zhao K, Cong G, et al. Deep representation learning for trajectory similarity computation[C]. ICDE, IEEE Computer Society, 2018: 617–628.
- [166] Zhao Y, Chen Q, Cao W, et al. Deep learning for risk detection and trajectory tracking at construction sites[J]. IEEE Access, 2019, 7: 30905–30912.
- [167] Liu Y, Zhao K, Cong G, et al. Online anomalous trajectory detection with deep generative sequence modeling[C]. ICDE, IEEE, 2020: 949–960.
- [168] Zheng K, Zheng Y, Yuan N J, et al. Online discovery of gathering patterns over trajectories[J]. TKDE, 2014, 26(8): 1974–1988.
- [169] Rumhar D, offry Hnon†, Wams R. Learning representations by back-propagating errors[J]. Nature, 1986.
- [170] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[C]. NIPS, 2014: 3104–3112.
- [171] Yuan J, Zheng Y, Zhang C, et al. T-drive: driving directions based on taxi trajectories[C]. ACM-GIS, ACM, 2010: 99–108.
- [172] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C]. CVPR, IEEE Computer Society, 2015: 815–823.
- [173] Werbos, P J. Backpropagation through time: what it does and how to do it[J]. Proceedings of the IEEE, 1990, 78(10): 1550-1560.
- [174] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[C]. ICLR.
- [175] Naserian E, Wang X, Xu X, et al. Discovery of loose travelling companion patterns from human trajectories[C]. HPCC, IEEE Computer Society, 2016: 1238–1245.
- [176] Shein T T, Puntheeranurak S, Imamura M. Discovery of loose group companion from trajectory data streams[J]. IEEE Access, 2020, 8: 85856–85868.
- [177] Tanaka P S, Vieira M R, Kaster D S. An improved base algorithm for online discovery of flock patterns in trajectories[J]. J. Inf. Data Manag., 2016, 7(1): 52–67.

-
- [178] Wang Y, Lim E, Hwang S. Efficient mining of group patterns from user movement data[J]. *Data Knowl. Eng.*, 2006, 57(3): 240–282.
- [179] Li Y, Bailey J, Kulik L. Efficient mining of platoon patterns in trajectory databases[J]. *Data Knowl. Eng.*, 2015, 100: 167–187.
- [180] Fan Q, Zhang D, Wu H, et al. A general and parallel platform for mining co-movement patterns over large-scale trajectories[J]. *Proc. VLDB Endow.*, 2016, 10(4): 313–324.
- [181] Zheng K, Zheng Y, Yuan N J, et al. On discovery of gathering patterns from trajectories[C]. *ICDE*, IEEE Computer Society, 2013: 242–253.
- [182] Pei W, Tax D M J, van der Maaten L. Modeling time series similarity with siamese recurrent networks[J]. *CoRR*, 2016, abs/1603.04713. 1603.04713.
- [183] Yao D, Zhang C, Zhu Z, et al. Trajectory clustering via deep representation learning[C]. *IJCNN*, IEEE, 2017: 3880–3887.
- [184] Boyle J, Nawaz T, Ferryman J M. Deep trajectory representation-based clustering for motion pattern extraction in videos[C]. *AVSS*, IEEE Computer Society, 2017: 1–6.
- [185] Yao H, Zhang S, Hong R, et al. Deep representation learning with part loss for person re-identification[J]. *IEEE Trans. Image Process.*, 2019, 28(6): 2860–2871.
- [186] Bütepage J, Black M J, Kragic D, et al. Deep representation learning for human motion prediction and classification[C]. *CVPR*, IEEE Computer Society, 2017: 1591–1599.
- [187] Yao D, Cong G, Zhang C, et al. Computing trajectory similarity in linear time: A generic seed-guided neural metric learning approach[C]. *ICDE*, IEEE, 2019: 1358–1369.
- [188] Chen C, Liao C, Xie X, et al. Trip2vec: a deep embedding approach for clustering and profiling taxi trip purposes[J]. *Pers. Ubiquitous Comput.*, 2019, 23(1): 53–66.
- [189] Yue M, Li Y, Yang H, et al. DETECT: deep trajectory clustering for mobility-behavior analysis[C]. *IEEE International Conference on Big Data (Big Data)*, IEEE, 2019: 988–997.
- [190] Zhang Y, Liu A, Liu G, et al. Deep representation learning of activity trajectory similarity computation[C]. *ICWS*, IEEE, 2019: 312–319.
- [191] Fang Z, Du Y, Chen L, et al. E²dtc: An end to end deep trajectory clustering framework via self-training[C]. *ICDE*, IEEE, 2021: 696–707.
- [192] Zheng B, Xu J, Lee W C, et al. Grid-partition index: a hybrid method for nearest-neighbor queries in wireless location-based services[J]. *The VLDB Journal*, 2006, 15(1): 21–39.
- [193] Chen Z, Li K, Zhou S, et al. Towards robust trajectory similarity computation: Representation-based spatio-temporal similarity quantification[J]. *World Wide Web*, 2022: 1–24.
- [194] Ester M, Kriegel H, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]. *KDD-96*, AAAI Press, 1996: 226–231.

- [195] Ankerst M, Breunig M M, Kriegel H, et al. OPTICS: ordering points to identify the clustering structure[C]. SIGMOD, ACM Press, 1999: 49–60.
- [196] Park H, Jun C. A simple and fast algorithm for k-medoids clustering[J]. Expert Syst. Appl., 2009, 36(2): 3336–3341.
- [197] Zhang T, Ramakrishnan R, Livny M. BIRCH: an efficient data clustering method for very large databases[C]. SIGMOD, ACM Press, 1996: 103–114.
- [198] Wang W, Yang J, Muntz R R. STING: A statistical information grid approach to spatial data mining[C]. VLDB, Morgan Kaufmann, 1997: 186–195.
- [199] Fisher D H. Knowledge acquisition via incremental conceptual clustering[J]. Mach. Learn., 1987, 2(2): 139–172.
- [200] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying ”infected” moving objects[J]. Proc. VLDB Endow., 2020, 13(12): 2825–2828.
- [201] Yang C, Chen L, Wang H, et al. Towards efficient selection of activity trajectories based on diversity and coverage[C]. AAAI, AAAI Press, 2021: 689–696.
- [202] Chen L, Shang S, Feng S, et al. Parallel subtrajectory alignment over massive-scale trajectory data[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3613–3619.
- [203] Shang S, Zheng K, Jensen C S, et al. Discovery of path nearby clusters in spatial networks[J]. TKDE, 2015, 27(6): 1505–1518.
- [204] Shang S, Chen L, Jensen C S, et al. Searching trajectories by regions of interest[J]. TKDE, 2017, 29(7): 1549–1562.
- [205] Yao B, Chen Z, Gao X, et al. Flexible aggregate nearest neighbor queries in road networks[C]. ICDE, IEEE Computer Society, 2018: 761–772.
- [206] Li K, Chen L, Shang S, et al. Traffic congestion alleviation over dynamic road networks: Continuous optimal route combination for trip query streams[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3656–3662.
- [207] Han P, Li Z, Liu Y, et al. Contextualized point-of-interest recommendation[C]. Bessiere C, (Ed.) IJCAI, ijcai.org, 2020: 2484–2490.
- [208] Han P, Shang S, Sun A, et al. AUC-MF: point of interest recommendation with AUC maximization[C]. ICDE, IEEE, 2019: 1558–1561.
- [209] Chen L, Shang S. Region-based message exploration over spatio-temporal data streams[C]. AAAI, AAAI Press, 2019: 873–880.
- [210] Chen L, Shang S, Jensen C S, et al. Parallel semantic trajectory similarity join[C]. ICDE, IEEE, 2020: 997–1008.

- [211] Zhao Y, Shang S, Wang Y, et al. REST: A reference-based framework for spatio-temporal trajectory compression[C]. Guo Y, Farooq F, (Eds.) SIGMOD, ACM, 2018: 2797–2806.
- [212] Fang Z, Gao Y, Pan L, et al. Coming: A real-time co-movement mining system for streaming trajectories[C]. Maier D, Pottinger R, Doan A, et al., (Eds.) SIGMOD, ACM, 2020: 2777–2780.
- [213] Liu J, Zhao K, Sommer P, et al. A novel framework for online amnesic trajectory compression in resource-constrained environments[J]. IEEE Trans. Knowl. Data Eng., 2016, 28(11): 2827–2841.
- [214] Liu J, Zhao K, Sommer P, et al. Bounded quadrant system: Error-bounded trajectory compression on the go[C]. Gehrke J, Lehner W, Shim K, et al., (Eds.) ICDE, IEEE Computer Society, 2015: 987–998.
- [215] Shang S, Yuan B, Deng K, et al. PNN query processing on compressed trajectories[J]. GeoInformatica, 2012, 16(3): 467–496.
- [216] Liu K, Li Y, Ding Z, et al. Benchmarking big data for trip recommendation[C]. ICCCN, IEEE, 2014: 1–6.
- [217] Chen L, Shang S, Zheng K, et al. Cluster-based subscription matching for geo-textual data streams[C]. ICDE, IEEE, 2019: 890–901.
- [218] Chen L, Shang S, Jensen C S, et al. Top-k term publish/subscribe for geo-textual data streams[J]. VLDB J., 2020, 29(5): 1101–1128.
- [219] Rao X, Wang H, Zhang L, et al. FOGS: first-order gradient supervision with learning-based graph for traffic flow forecasting[C]. Raedt L D, (Ed.) IJCAI, ijcai.org, 2022: 3926–3932.
- [220] Liu A, Wang W, Shang S, et al. Efficient task assignment in spatial crowdsourcing with worker and task privacy protection[J]. GeoInformatica, 2018, 22(2): 335–362.
- [221] Feng S, Tran L V, Cong G, et al. HME: A hyperbolic metric embedding approach for next-poi recommendation[C]. SIGIR, ACM, 2020: 1429–1438.
- [222] Rao X, Chen L, Liu Y, et al. Graph-flashback network for next location recommendation[C]. KDD, ACM, 2022: 1463–1471.
- [223] Li M, Chen L, Cong G, et al. Efficient processing of location-aware group preference queries[C]. CIKM, ACM, 2016: 559–568.
- [224] Li X, Cheng Y, Cong G, et al. Discovering pollution sources and propagation patterns in urban area[C]. KDD, ACM, 2017: 1863–1872.
- [225] Zhao K, Chen L, Cong G. Topic exploration in spatio-temporal document collections[C]. SIGMOD, ACM, 2016: 985–998.
- [226] Han J, Zheng K, Sun A, et al. Discovering neighborhood pattern queries by sample answers in knowledge base[C]. ICDE, IEEE Computer Society, 2016: 1014–1025.

- [227] Shang S, Guo D, Liu J, et al. Finding regions of interest using location based social media[J]. *Neurocomputing*, 2016, 173: 118–123.
- [228] Chen L, Shang S. Approximate spatio-temporal top-k publish/subscribe[J]. *World Wide Web*, 2019, 22(5): 2153–2175.
- [229] Guo D, Zhu Y, Xu W, et al. How to find appropriate automobile exhibition halls: Towards a personalized recommendation service for auto show[J]. *Neurocomputing*, 2016, 213: 95–101.
- [230] Hua M, Pei J. Probabilistic path queries on road networks[J]. 2011.
- [231] Dafermos S C, Sparrow F T. The traffic assignment problem for a general network[J]. *National Bureau of Standards*, 1969.
- [232] Peeta S, Mahmassani H S. System optimal and user equilibrium time-dependent traffic assignment in congested networks[J]. *Ann. Oper. Res.*, 1995, 60(1): 81–113.
- [233] Shang S, Liu J, Zheng K, et al. Planning unobstructed paths in traffic-aware spatial networks[J]. *GeoInformatica*, 2015, 19(4): 723–746.
- [234] Shang S, Guo D, Liu J, et al. Prediction-based unobstructed route planning[J]. *Neurocomputing*, 2016, 213: 147–154.
- [235] Nikolova E, Brand M, Karger D R. Optimal route planning under uncertainty[C]. *ICAPS, AAAI*, 2006: 131–141.
- [236] Greenshields B. A study of traffic capacity[J]. *A Study of Traffic Capacity*, 1934, 14.
- [237] Hua M, Pei J. Probabilistic path queries in road networks: traffic uncertainty aware path selection[C]. *EDBT, ACM*, vol. 426 of *ACM International Conference Proceeding Series*, 2010: 347–358.
- [238] Özal A, Ranganathan A, Tatbul N. Real-time route planning with stream processing systems: a case study for the city of lucerne[C]. *GIS-IWGS, ACM*, 2011: 21–28.
- [239] Trajcevski G, Choudhary A, Wolfson O, et al. Uncertain range queries for necklaces[C]. *MDM*, 2010: 199–208.
- [240] Pfoser D, Jensen C S. Capturing the uncertainty of moving-object representations[C]. *SSD*, 1999: 111–132.
- [241] Moreira-Matias L, Gama J, Ferreira M, et al. Predicting taxi-passenger demand using streaming data[J]. *IEEE Trans. Intell. Transp. Syst.*, 2013, 14(3): 1393–1402.
- [242] Samet H. The quadtree and related hierarchical data structures[J]. *ACM Comput. Surv.*, 1984, 16(2): 187–260.
- [243] Zhang X, Ray S, Shoeleh F, et al. Efficient contact similarity query over uncertain trajectories[C]. *EDBT*, 2021: 403–408.

- [244] Zheng Y, Li Q, Chen Y, et al. Understanding mobility based on GPS data[C]. UbiComp, 2008: 312–321.
- [245] Zheng Y, Zhang L, Xie X, et al. Mining interesting locations and travel sequences from GPS trajectories[C]. WWW, 2009: 791–800.
- [246] Tampakis P, Doukeridis C, Pelekis N, et al. Distributed subtrajectory join on massive datasets[J]. ACM Trans. Spatial Algorithms Syst., 2020, 6(2): 8:1–8:29.
- [247] Chen Y, Patel J M. Design and evaluation of trajectory join algorithms[C]. 17th ACM SIGSPATIAL International Symposium on Advances in Geographic Information Systems, Washington, USA: ACM, 2009: 266–275.
- [248] Ding Y, Zhou X, Wu G, et al. Mining spatio-temporal reachable regions with multiple sources over massive trajectory data[J]. IEEE Trans. Knowl. Data Eng., 2021, 33(7): 2930–2942.
- [249] Han P, Wang J, Yao D, et al. A graph-based approach for trajectory similarity computation in spatial networks[C]. KDD, ACM, 2021: 556–564.
- [250] Chang Y, Tanin E, Cong G, et al. Trajectory similarity measurement: An efficiency perspective[J]. Proceedings of the VLDB Endowment, 2024, 17(9): 2293–2306.
- [251] Ward P G D, He Z, Zhang R, et al. Real-time continuous intersection joins over large sets of moving objects using graphic processing units[J]. VLDB J., 2014, 23(6): 965–985.
- [252] Nutanong S, Zhang R, Tanin E, et al. Analysis and evaluation of v^* -knn: an efficient algorithm for moving knn queries[J]. VLDB J., 2010, 19(3): 307–332.
- [253] Li K, Wang H, Chen Z, et al. Relaxed group pattern detection over massive-scale trajectories[J]. Future Generation Computer Systems, 2023, 144: 131–139.
- [254] Liang A, Yao B, Wang B, et al. Sub-trajectory clustering with deep reinforcement learning[J]. VLDB J., 2024, 33(3): 685–702.
- [255] Chao P, He D, Li L, et al. Efficient trajectory contact query processing[C]. DASFAA, 2021: 658–666.
- [256] Dolatshah M, Hadian A, Minaei-Bidgoli B. Ball*-tree: Efficient spatial indexing for constrained nearest-neighbor search in metric spaces[J]. CoRR, 2015.
- [257] Omohundro S M. Five balltree construction algorithms[M]. International Computer Science Institute Berkeley, 1989.
- [258] Moore A W. The anchors hierarchy: Using the triangle inequality to survive high dimensional data[C]. UAI, 2000: 397–405.
- [259] Liu T, Moore A W, Gray A G. New algorithms for efficient high-dimensional nonparametric classification[J]. J. Mach. Learn. Res., 2006, 7: 1135–1158.

- [260] Ciaccia P, Patella M, Zezula P. M-tree: An efficient access method for similarity search in metric spaces[C]. VLDB, 1997: 426–435.
- [261] Ciaccia P, Patella M, Rabitti F, et al. Indexing metric spaces with m-tree[C]. SEBD, 1997: 67–86.
- [262] Zhang M, Chen S, Jensen C S, et al. Effectively indexing uncertain moving objects for predictive queries[J]. Proc. VLDB Endow., 2009, 2(1): 1198–1209.
- [263] Bentley J L. Multidimensional binary search trees used for associative searching[J]. Commun. ACM, 1975, (9): 509–517.
- [264] Brinkhoff T, Kriegel H, Seeger B. Efficient processing of spatial joins using r-trees[C]. SIGMOD, 1993: 237–246.
- [265] Guttman A. R-trees: A dynamic index structure for spatial searching[C]. SIGMOD, 1984: 47–57.
- [266] Zheng Y, Xie X, Ma W. Geolife: A collaborative social networking service among user, location and trajectory[J]. IEEE Data Eng. Bull., 2010, 33(2): 32–39.
- [267] Li J, Ni C, He D, et al. Efficient knn query for moving objects on time-dependent road networks[J]. VLDB J., 2023, 32(3): 575–594.
- [268] Sistla A P, Wolfson O, Chamberlain S, et al. Modeling and querying moving objects[C]. ICDE, 1997: 422–432.
- [269] Li K, Chen L, Shang S, et al. Towards controlling the transmission of diseases: Continuous exposure discovery over massive-scale moving objects[C]. IJCAI, 2022: 3891–3897.
- [270] Forrest S, Recio M, Seddon P. Moving wildlife tracking forward under forested conditions with the swift gps algorithm[J]. Animal Biotelemetry, 2022, 10(1): 19.
- [271] Yi B, Faloutsos C. Fast time sequence indexing for arbitrary lp norms[C]. VLDB, Morgan Kaufmann, 2000: 385–394.
- [272] Bakalov P, Hadjieleftheriou M, Keogh E J, et al. Efficient trajectory joins using symbolic representations[C]. Chrysanthos P K, Samaras G, (Eds.) MDM, ACM, 2005: 86–93.
- [273] Zhang R, Lin D, Ramamohanarao K, et al. Continuous intersection joins over moving objects[C]. ICDE, 2008: 863–872.
- [274] Zhang R, Qi J, Lin D, et al. A highly optimized algorithm for continuous intersection join queries over moving objects[J]. VLDB J., 2012, 21(4): 561–586.
- [275] Saltenis S, Jensen C S, Leutenegger S T, et al. Indexing the positions of continuously moving objects[C]. SIGMOD, 2000: 331–342.
- [276] Patel J M, Chen Y, Chakka V P. STRIPES: an efficient index for predicted trajectories[C]. SIGMOD, 2004: 637–646.

- [277] Kong X, Chen Q, Hou M, et al. Mobility trajectory generation: a survey[J]. *Artif. Intell. Rev.*, 2023, 56(Supplement 3): 3057–3098.
- [278] Ding Z, Li K, Chen L, et al. Parallel online similarity join over trajectory streams[C]. *Proceedings of the ACM on Web Conference 2025*, 2025: 3426–3437.
- [279] Shang S, Chen L, Zheng K, et al. Parallel trajectory-to-location join[J]. *TKDE*, 2019, 31(6): 1194–1207.
- [280] Vishnu C, Abhinav V, Roy D, et al. Improving multi-agent trajectory prediction using traffic states on interactive driving scenarios[J]. *IEEE Robotics Autom. Lett.*, 2023, 8(5): 2708–2715.
- [281] Eusuf S S, Islam K A, Ali M E, et al. A web-based system for efficient contact tracing query in a large spatio-temporal database[C]. *SIGSPATIAL '20: 28th International Conference on Advances in Geographic Information Systems*, ACM, 2020: 473–476.
- [282] Tang L, Zheng Y, Yuan J, et al. On discovery of traveling companions from streaming trajectories[C]. *IEEE 28th International Conference on Data Engineering (ICDE 2012)*, IEEE Computer Society, 2012: 186–197.
- [283] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying "infected" moving objects[J]. *Proc. VLDB Endow.*, 2020, 13(12): 2825–2828.
- [284] He H, Li R, Wang R, et al. Efficient suspected infected crowds detection based on spatio-temporal trajectories[J]. *CoRR*, 2020, abs/2004.06653. 2004.06653.
- [285] Taha A A, Hanbury A. An efficient algorithm for calculating the exact hausdorff distance[J]. *IEEE Trans. Pattern Anal. Mach. Intell.*, 2015, 37(11): 2153–2163.
- [286] Yuan J, Zheng Y, Xie X, et al. Driving with knowledge from the physical world[C]. *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ACM, 2011: 316–324.
- [287] Alarabi L, Basalamah S M, Hendawi A M, et al. Traceall: A real-time processing for contact tracing using indoor trajectories[J]. *Inf.*, 2021, 12(5): 202.
- [288] Li Z, Ding B, Han J, et al. Swarm: Mining relaxed temporal moving object clusters[J]. *Proc. VLDB Endow.*, 2010, 3(1): 723–734.
- [289] Jeung H, Yiu M L, Zhou X, et al. Discovery of convoys in trajectory databases[J]. *Proc. VLDB Endow.*, 2008, 1(1): 1068–1080.
- [290] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. *17th ACM SIGSPATIAL International Symposium on Advances in Geographic Information Systems*, ACM-GIS 2009, ACM, 2009: 286–295.
- [291] Xiong L, Shahabi C, Da Y, et al. REACT: real-time contact tracing and risk monitoring using privacy-enhanced mobile tracking[J]. *ACM SIGSPATIAL Special*, 2020, 12(2): 3–14.

- [292] Zhou P, Zhang D, Salzberg B, et al. Close pair queries in moving object databases[C]. Shahabi C, Boucelma O, (Eds.) 13th ACM International Workshop on Geographic Information Systems, ACM-GIS 2005, November 4-5, 2005, Bremen, Germany, Proceedings, ACM, 2005: 2–11.
- [293] Ma C, Lu H, Shou L, et al. KSQ: top-(k) similarity query on uncertain trajectories[J]. IEEE Trans. Knowl. Data Eng., 2013, 25(9): 2049–2062.
- [294] Faloutsos C, Ranganathan M, Manolopoulos Y. Fast subsequence matching in time-series databases[C]. Proceedings of the 1994 ACM SIGMOD International Conference on Management of Data, ACM Press, 1994: 419–429.
- [295] Assent I, Wichterich M, Krieger R, et al. Anticipatory DTW for efficient similarity search in time series databases[J]. Proc. VLDB Endow., 2009, 2(1): 826–837.
- [296] Rong C, Lin C, Silva Y N, et al. Fast and scalable distributed set similarity joins for big data analytics[C]. 33rd IEEE International Conference on Data Engineering, ICDE 2017, IEEE Computer Society, 2017: 1059–1070.
- [297] Ojagh S, Saeedi S, Liang S H L. A person-to-person and person-to-place COVID-19 contact tracing system based on OGC indoorgml[J]. ISPRS Int. J. Geo Inf., 2021, 10(1): 2.
- [298] Xie D, Li F, Phillips J M. Distributed trajectory similarity search[J]. Proc. VLDB Endow., 2017, 10(11): 1478–1489.