

目 录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 研究目标	1
1.3 研究所面临的挑战	1
1.4 研究内容	1
1.4.1 面向大规模行程请求流的持续最优路线组合规划	2
1.4.2 基于轨迹数据的群体联合移动模式挖掘	2
1.4.3 大规模移动对象上的持续密切接触发现	2
1.4.4 面向时空运动范围的轨迹相似性连接方法	2
1.5 论文的主要贡献	2
1.6 论文的组织结构	2
第二章 面向时空运动范围的轨迹相似性连接方法	3
2.1 引言	4
2.1.1 研究背景与意义	4
2.1.2 研究内容与挑战	7
2.1.3 研究成果与贡献	8
2.2 问题描述	9
2.3 基于 M*-树的连接算法	12
2.3.1 M*-树	13
2.3.2 交集检查	13
2.3.3 算法细节	14
2.4 运动范围引导的匹配方法	15
2.4.1 时间区间预检查	16
2.4.2 基于 HBall-tree 的交集预检查	17
2.4.3 基于 HBall-tree 的 Join	19
2.5 实验研究	21
2.5.1 实验设置	21
2.5.2 实验结果与分析	23
2.6 IS-Join 的附加实验	26
2.7 本章小结	27

目 录

致 谢	29
参考文献	30

图目录

图 2-1	IS-Join 问题示例	7
图 2-2	Illustration of time-point motion range	10
图 2-3	时间区间交集相似性的示意图	12
图 2-4	M*-树的结构	13
图 2-5	时间区间运动范围示例	17
图 2-6	混合 Ball-tree 的示意图	17
图 2-7	不同 $ O $ 下的构建时间影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	24
图 2-8	不同 $ O $ 下的查询时间影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	24
图 2-9	POI 数量对运行时间的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	25
图 2-10	$ I $ 对运行时间的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	26
图 2-11	参数 ϵ 的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	26
图 2-12	相似度阈值的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	27
图 2-13	移动对象数量对节点访问次数的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验	27

表目录

表 2-1	符号说明汇总.....	9
表 2-2	评估参数设置.....	22
表 2-3	剪枝性能.....	23

第一章 绪论

1.1 研究背景与意义

二零二六年三月三日 16:55 随着汽车产业、智能移动设备以及基于位置服务的快速发展，带有地理位置信息的时空数据呈现爆炸式增长。其中，路网数据和轨迹数据是两个代表性的时空数据。路径规划、轨迹分析等基于时空数据挖掘的位置服务在城市计算中扮演着日益重要的角色。一个动态路网是由顶点集和边集构成的，其中顶点代表路段的连接点，交叉点；连边则代表具体的路段。每条边连接着两个顶点。为了便于描述，我们假定所有行程请求的起点和终点位置都已经映射到离它们最近的顶点上。

路径规划不仅直接影响人们的日常出行方式，也关系到物流运输、智慧城市管理以及能源优化等多个领域。近年来，随着网络购物、共享出行和自动驾驶技术的发展，城市路网中行程请求呈现出高频、密集和动态的特点，传统基于单次行程或静态路径集合的最优路径规划方法已难以适应实时、连续的行程请求流。

综上，城市计算中面临的核心挑战包括大规模数据处理、动态环境适应以及对象间潜在交互的准确建模。围绕路径规划、联合移动模式挖掘、接触搜索与轨迹相似连接等任务，设计高效算法与索引结构不仅具有理论价值，也具有显著应用潜力：一方面可提升城市交通系统的调度效率与拥堵缓解能力；另一方面可支持公共卫生管理、生态监测及智能出行等多领域的决策优化。基于此，本文旨在系统研究城市计算中高效算法设计问题，通过统一的时空数据建模与高性能计算框架，实现对移动对象行为的实时、准确与可扩展分析，为智慧城市应用提供技术支撑。

1.2 研究目标

1.3 研究所面临的挑战

1.4 研究内容

在此背景下，本研究聚焦于四类关键问题：持续最优路径规划、联合移动模式挖掘、接触搜索与轨迹相似连接。这些问题均涉及海量移动对象和复杂时空约束，典型研究意义如下：

1.4.1 面向大规模行程请求流的持续最优路线组合规划

交通拥堵是城市化进程中普遍存在的问题。传统路径规划往往基于单一行程或当前交通状态进行局部优化，忽略了新到达请求对未来路网负载的影响。面对持续到达的行程请求流，单次最优路径规划可能导致集中拥堵，降低整体通行效率。因此，需要设计面向持续请求流的全局协同路径规划算法，实现对时间窗口内行程请求的联合优化，从整体视角缓解交通拥堵，提高路网利用率。

1.4.2 基于轨迹数据的群体联合移动模式挖掘

在大规模移动对象环境中，识别群体运动模式（如 flock、convoy、swarm 等）可揭示潜在的协同行为与社会动态规律。这类模式在拼车推荐、交通拥堵预测、异常行为检测以及生态监测中具有广泛应用。高效挖掘联合移动模式的核心挑战在于对象轨迹在时间上可能暂时离群或不连续，导致候选群体数量指数级增长，需要设计高效的索引结构与过滤策略以保证算法可扩展性。

1.4.3 大规模移动对象上的持续密切接触发现

在公共卫生管理与疫情防控中，及时识别个体间潜在接触事件对于控制疾病传播具有关键意义。由于移动对象的轨迹数据通常存在采样间隔与定位误差，仅依赖离散采样点判断接触关系容易产生误判。面向大规模连续轨迹数据的接触搜索算法必须支持高并发、低延迟处理，并在动态更新环境下保证结果的准确性与一致性，为公共卫生决策提供数据支撑。

1.4.4 面向时空运动范围的轨迹相似性连接方法

传统轨迹相似性连接方法多依赖离散采样点计算对象间距离，难以刻画未观测时间区间内的潜在交互。IS-Join 通过引入运动范围的概念，将对象在给定时间段内可能经过的空间区域作为分析单元，采用交集相似性度量量化对象间潜在重叠关系。这一方法可应用于交通监控、野生动物迁徙分析、接触追踪等场景，在稀疏采样或不确定条件下仍能稳健地识别潜在关联。

1.5 论文的主要贡献

1.6 论文的组织结构

第二章 面向时空运动范围的轨迹相似性连接方法

本章研究如何在存在位置不确定性的移动对象数据上，设计一种面向大规模数据的运动范围感知相似连接方法，以更加准确地刻画对象之间的潜在时空交互关系。随着智能手机、车载导航系统以及可穿戴设备等 GPS 终端的普及，海量轨迹数据被持续采集与存储，围绕移动对象的连接 (join)、范围查询、 k NN 查询以及相似性查询等问题已成为时空数据管理领域的研究热点。然而，在真实应用场景中，由于采样频率不一致、定位误差不可避免、以及相邻采样点之间运动过程不可观测等因素，轨迹数据往往具有不确定性与稀疏性特征。现有多数相似性连接方法主要基于离散采样点进行距离计算，难以有效反映对象在采样间隔内的连续运动状态，从而可能遗漏在现实中具有重要意义的潜在交互行为。

为克服上述局限，本章提出了一种新的相似连接模型——Intersection Similarity Join (IS-Join)。不同于传统基于点邻近关系的建模方式，IS-Join 以对象在给定时间区间内的潜在运动范围为基本分析单元。我们首先将运动范围定义为对象在某一时间段内可能到达的空间区域，用以刻画位置不确定性；在此基础上，引入交集相似性度量，用于量化两个对象运动范围之间的重叠程度。通过该建模方式，IS-Join 能够从“区域交互”的角度识别对象对，从而更真实地反映移动对象之间的潜在接触或协同行为。

在问题描述上，我们形式化定义了时间区间、运动范围模型、交集相似度函数以及 IS-Join 查询语义。具体而言，给定一组移动对象及其在统一时间区间内的运动范围表示，IS-Join 旨在检索所有满足交集相似度不低于给定阈值的对象对。每个对象的运动范围由其轨迹点及速度约束推导得到，并在时间维度上保持对齐。在满足时间一致性的前提下，通过计算不同对象运动范围之间的空间重叠比例，判断其是否满足连接条件。

综上，IS-Join 问题的核心在于：在存在位置不确定性的时空环境中，以区域重叠替代点距离作为相似性判定标准，在保证查询语义合理性的同时，实现高效的大规模对象对筛选。例如，在城市交通监测场景中，车辆在采样间隔内可能存在路径偏移，仅依赖离散采样点可能无法捕捉真实的近距离接触；在野生动物追踪或接触追踪场景中，对象之间的潜在活动区域重叠往往比瞬时位置更具分析价值。因此，从运动范围交集的角度进行相似连接具有重要的理论意义与应用价值。

在解决方案上，由于 IS-Join 需要在大规模对象集合上进行区域重叠判定，其计算复杂度在最坏情况下接近二次方级别，难以直接应用于实时或准实时系统。为

此，本章设计了一种带有重划分策略的 Hybrid Ball-tree 索引结构，通过层次化组织运动范围并动态调整节点划分边界，实现高效的候选对象过滤。同时，引入预检查（pre-checking）与多层剪枝（pruning）机制，在索引遍历阶段提前排除不可能满足交集条件的对象对，从而显著降低精确计算阶段的开销。

最后，基于两个真实轨迹数据集开展了系统实验评估。实验结果表明，与精心设计的对比方法相比，IS-Join 在保证结果准确性的同时，在运行效率上最高可实现约 3× 的加速，即运行时间降低至原来的 1/3。上述结果验证了所提模型与索引结构在准确性、效率与可扩展性方面的优势，也为城市出行分析、交通监测、野生动物追踪以及公共卫生场景中的接触分析等应用提供了新的技术支撑。

2.1 引言

2.1.1 研究背景与意义

相似移动对象对的匹配问题（Similarity Join）是时空数据管理领域中的一项目基础性操作，在轨迹分析、群体行为发现、异常检测以及公共安全等应用中具有重要意义。现有研究工作 [2, 123, 142, 177, 190] 通常将移动对象建模为一系列带时间戳的离散位置采样点，并基于同步时间点或插值后采样点之间的空间邻近关系来度量对象间的相似性。

尽管上述基于点的表示方式具有建模简洁、计算高效等优点，但其隐含前提是对对象轨迹具有足够高的采样频率。然而，在真实应用场景中，由于隐私保护要求、商业数据限制、通信带宽约束、设备能耗限制以及数据丢失等因素 [191]，移动对象往往只能以较低频率被观测。此时，相邻观测点之间的实际运动路径不可直接获取，导致对象在两个连续时间戳之间存在显著的空间不确定性。在稀疏采样条件下，传统基于采样点邻近性的相似性度量方法可能严重低估对象之间的真实交互程度，从而错误地遗漏本应满足相似性条件的对象对。

为缓解上述问题，已有研究提出了多种增强表示模型。一类方法利用最小外接矩形（Minimum Bounding Rectangle, MBR）结合速度约束构建基于运动模型的表示方式，用以近似刻画对象在观测间隔内的可能位置区域 [192–196]。另一类方法 [197] 采用分段聚合近似（Piecewise Aggregate Approximation, PAA）[198] 技术，将轨迹划分为若干片段，并将每个片段映射为来自预定义字母表的符号，从而将轨迹转换为符号序列以支持高效匹配。

尽管上述方法在一定程度上提升了轨迹建模的灵活性，并增强了相似性计算的可扩展性，但它们仍难以精确刻画采样点之间的连续运动过程。特别是在稀疏采样轨迹场景下，这些方法通常采用区域近似或符号抽象，缺乏对对象潜在运动

轨迹之间“运动交集”关系的显式建模能力。因此，当两个对象在未观测时间区间内存在真实空间交叠或运动重叠时，现有方法可能由于建模能力不足而将其错误剪枝。

由此可见，如何在存在观测不确定性的条件下有效刻画移动对象之间的潜在运动交集关系，并在海量移动对象数据环境下高效地发现所有满足交集条件的对象对，仍然是一个亟待解决的开放性问题。

为解决上述挑战，本文提出了面向移动对象的交集相似性连接问题（Intersection Similarity Join, IS-Join）。该问题通过引入“运动范围”（motion range）的概念，对对象在相邻观测样本之间可能访问的空间区域进行建模。具体而言，我们将对象在某一时间点或给定时间区间内可能到达的空间区域定义为其运动范围。基于此，两个对象之间的交集相似性不再依赖于离散采样点之间的距离，而是由其运动范围内特征区域的重叠程度来刻画。

形式上，给定关系表 `MovingObject` 中的一组移动对象以及相似性阈值 θ ，我们定义交集相似性连接（IS-Join）操作如下所示。^①

```
SELECT o.id, o'.id
FROM MovingObject AS o, MovingObject AS o'
WHERE o.id < o'.id AND IS(o, o', I) ≥ θ
```

每个对象 o 由一个 id 属性、两个位置坐标属性以及两个时间戳属性来表征，其中时间戳表示对象访问对应位置的时间。条件 $o.id < o'.id$ 用于避免重复比较。函数 $IS(o, o', I)$ 用于度量对象 o 与 o' 在时间区间 I 内基于各自运动范围中特征重叠程度的交集相似性。参数 θ 为预先设定的相似性阈值。

IS-Join 问题在多个实际应用场景中具有重要价值，例如疾病防控、轨迹数据清洗、拼车推荐以及交通拥堵预测等 [20, 199]。这些场景的共同特点在于：对象之间的潜在交互往往发生在未被精确观测的时间区间内，因此仅依赖离散采样点难以准确刻画真实关系。通过引入运动范围并基于区域交集进行相似性度量，IS-Join 能够更稳健地建模对象之间的潜在交互行为。下面讨论若干代表性应用场景。

2.1.1.0.1 场景一：城市交通监测与拥堵分析 在城市交通管理系统中，移动对象通常对应于车辆，其运动轨迹反映了实时交通状态。特征集合可以包括道路路段、交叉路口以及交通信号灯等交通基础设施要素。通过计算车辆之间的交集相似性，可以刻画其在一定时间区间内经历相似交通环境或共享道路资源的程度，从而辅助拥堵预测、异常路段识别以及交通调度优化。

^① 为便于表述，本文以自连接（self-join）的形式给出 IS-Join 的定义。需要指出的是，本文提出的模型与算法同样适用于非自连接（non-self join）场景。

对于兴趣点 (Point of Interest, POI) 和道路交叉口等点状特征, 可为每一个特征分配唯一标识符 (ID)。对于线状道路网络, 为保证建模粒度的一致性, 可将道路划分为等长度子路段, 并为每个子路段分配唯一 ID。基于此表示方式, 车辆在某时间区间内的运动范围可映射为一组可能访问的路段或节点集合。若两辆车辆的运动范围在特征集合层面存在显著交集, 则说明它们可能受到相似交通流影响。相比传统基于同步采样点距离的相似性计算方法, IS-Join 能够在稀疏采样条件下更准确地反映潜在交通关联关系。

2.1.1.0.2 场景二: 野生动物迁徙分析 在生态监测与保护领域, 移动对象可对应于佩戴定位设备的野生动物。由于设备能耗限制与通信条件约束, 动物轨迹通常具有较低采样频率。在此背景下, 基于采样点的直接距离度量难以识别共享迁徙路径或潜在接触行为。

通过引入运动范围, 可以综合考虑栖息地、水源分布以及已知迁徙通道等环境特征, 构建动物在观测间隔内的潜在活动区域。交集相似性用于衡量不同个体之间在生态特征空间中的重叠程度, 从而识别共享迁徙走廊或高频活动区域。此外, 该建模方式在节能数据采集与准确交互检测之间提供了一种有效折中方案 [200]: 即在降低采样频率的同时, 仍能通过区域建模保持对关键交互事件的识别能力。

2.1.1.0.3 场景三: 接触追踪与疾病传播控制 在公共卫生领域, 移动对象可表示为个体用户, 其潜在接触关系是疾病传播建模的关键因素。在诸如新冠疫情等大规模传染病暴发期间, 精准识别高风险接触事件对于抑制传播链条具有重要意义 [125]。

由于实际系统中定位数据通常存在时间间隔和空间误差, 仅依据同步采样点判断是否发生接触容易产生误判。通过运动范围建模, 可以估计个体在给定时间区间内的潜在活动区域, 从而更合理地推断可能的接触事件。交集相似性度量反映了两个个体在潜在活动区域层面的重叠程度, 可用于评估感染风险等级并支持后续防控决策。

综上所述, 不同应用场景虽然关注对象类型与特征集合各不相同, 但其核心需求均可归结为: 在存在观测不确定性的条件下, 识别对象之间的潜在运动交集关系。IS-Join 通过统一的运动范围建模与区域交集度量框架, 为上述问题提供了通用且可扩展的解决方案。

示例 2.1 如图 2-1 所示, 考虑三个移动对象 o_1, o_2 和 o_3 , 它们在时间戳 t_1 至 t_5 之间均具有位置采样点。为便于说明, 假设这些采样点在时间维度上是对齐的。

在时间区间 $[t_1, t_3]$ 内, 对象 o_1 与 o_2 在 t_2 时刻的位置采样缺失或由于噪声过大而不可用。若采用传统基于采样点距离阈值的相似性连接方法, 仅判断同步时




图 2-1 IS-Join 问题示例

间点上两对象之间的欧氏距离是否小于给定阈值，则可能得到 (o_1, o_2) 在 $[t_1, t_3]$ 内不满足相似性条件的结论。然而，在实际运动过程中，两对象在 t_2 时刻的真实距离可能低于该阈值，从而存在潜在的空间交集。由此可见，单纯依赖离散采样点进行判断，容易在稀疏采样或存在数据噪声的情况下产生误判。

2.1.2 研究内容与挑战

为克服上述局限性，本文引入“运动范围”以刻画对象在观测间隔内的潜在可达区域。以对象 o_3 在 t_1 和 t_2 时刻的位置为例，其在时间区间 $[t_1, t_2]$ 内任意时间点 t 的运动范围可表示为由速度约束确定的透镜形区域（其严格定义将在第 ?? 节给出）。类似地，对象 o_1 和 o_2 在时间区间 (t_1, t_3) 内的运动范围分别对应图中的紫色与棕色透镜区域。可以观察到，两者的运动范围在某些时间点存在重叠区域（图中阴影部分），这表明两对象在未观测时间段内可能存在空间交集。

进一步地，考虑时间区间 $[t_4, t_5]$ 。图中展示了对对象 o_2 和 o_3 在该区间若干离散时间点上的运动范围示意。为在理论上处理连续时间区间，本文将区间 $[t_4, t_5]$ 内的交集相似性定义为该区间内交集相似性函数的时间平均值。换言之，若记 $S(t)$ 表示时间点 t 上的交集相似性，则区间相似性定义为

$$\frac{1}{|t_5 - t_4|} \int_{t_4}^{t_5} S(t) dt,$$

其离散近似形式将在问题定义部分给出。

给定时间区间 $[T_s, T_e]$ 以及相似性阈值 θ ，IS-Join 问题旨在识别并返回所有在

该时间区间内平均交集相似性不低于 θ 的对象对。

与现有移动对象相似性连接研究主要基于离散采样点或区域近似不同, 本文首次的连接语义层面显式引入“运动范围”概念, 并将相似性度量从点级距离扩展至连续时间下的区域交集度量。这一转变显著提升了在稀疏采样条件下识别潜在交互关系的能力。

然而, 使 IS-Join 在实际系统中具备可行性面临两项关键挑战:

- (1) **连续时间计算挑战。** 交集相似性在连续时间区间上定义, 理论上涉及无限多个时间点, 直接计算精确结果在实际中不可行。因此, 需要构建可计算的等价离散化模型或可证明误差界的近似计算方法。
- (2) **高效连接挑战。** 现有相似性连接算法主要针对基于点距离或静态区域重叠的查询而设计, 无法直接支持连续时间下的运动范围交集计算。若直接改造现有方法, 往往导致候选对数量急剧膨胀, 从而产生显著的计算开销。

2.1.3 研究成果与贡献

为应对上述挑战, 本文提出了一种由时间区间运动范围引导的高效求解框架。具体而言, 我们设计了一种基于 HBall-tree 的层次化索引结构, 用于组织对象在时间区间内的运动范围, 并结合重划分策略与多级剪枝技术, 有效减少候选对象对数量。在多个真实与合成数据集上的实验结果表明, 相较于精心设计的基线方法, 所提出算法的平均运行时间可降低约 3 倍, 同时保持结果的准确性与完整性。

本文围绕移动对象在稀疏采样条件下的潜在运动交集建模与高效连接计算问题展开研究, 主要贡献总结如下:

- **问题建模创新。** 本文提出了一种新的移动对象相似性连接问题——交集相似性连接 (Intersection Similarity Join, IS-Join)。与传统基于离散位置采样点距离或静态区域重叠的相似性连接不同, IS-Join 在语义层面显式引入“运动范围”概念, 将相似性度量从点级邻近关系扩展至连续时间下的区域交集关系。该建模方式能够更准确地刻画稀疏采样轨迹中潜在的运动交互行为, 从而弥补现有方法在未观测时间区间内建模能力不足的缺陷。
- **高效求解框架设计。** 针对 IS-Join 在连续时间区间下计算复杂、候选对象对规模庞大的挑战, 本文提出了一种由时间区间运动范围引导的高效求解框架。具体而言, 我们设计了混合 Ball-tree (Hybrid Ball-tree, HBall-tree) 索引结构, 用于层次化组织对象在时间区间内的运动范围表示, 并结合重划分策略与多级剪枝技术, 实现对候选对象对的有效过滤。该框架在保证结果正确性与完整性的前提下, 显著降低了计算开销。

- **系统化实验验证。**本文在两个真实世界数据集上开展了系统性的实验评估，从运行时间、可扩展性以及参数敏感性等多个维度对所提出方法进行了深入分析。实验结果表明，相较于精心设计的基线方法，本文方法在保持查询结果准确性的同时，在整体性能上取得了显著提升，验证了所提出模型与算法的有效性与实用价值。

2.2 问题描述

符号	含义
o	一个移动对象
s	一个带时间戳的位置采样点
$[x, y], t$	坐标 / 时间戳
I	一个时间区间
$MR(\cdot)$	对象的运动范围
$dist(\cdot)$	距离度量函数
$\mathcal{F}(\cdot)$	运动范围的特征集合
$IS(\cdot)$	交集相似性度量
θ	交集相似性阈值
ϵ	放宽划分参数
T^ϵ	采样时间戳集合
$\mathcal{A}, \mathcal{B}$	两个移动对象集合
$\mathcal{R}$	IS-Join 的结果集合

表 2-1 符号说明汇总

本节首先给出移动对象运动范围 (Motion Range) 的形式化定义, 并在此基础上定义移动对象之间的交集相似性。随后, 引入放宽交集相似性 (Relaxed Intersection Similarity) 的概念, 并对交集相似性连接 (IS-Join) 问题进行严格的形式化描述。本文中使用的符号汇总于表 2-1。

定义 2.1 (带时间戳的位置采样) 移动对象的一个带时间戳的位置采样表示为 $s = ([x, y], t)$, 其中 $[x, y] \in \mathbb{R}^2$ 表示对象在二维空间中的坐标位置, $t \in \mathbb{R}$ 表示对应的时间戳。对于移动对象 o , 其轨迹可表示为按时间升序排列的采样序列 $\{s_1, s_2, \dots, s_n\}$, 且满足 $t_1 < t_2 < \dots < t_n$ 。

定义 2.2 (时间点运动范围) 给定移动对象 o 的两个连续位置采样点 $s_i = ([x_i, y_i], t_i)$ 和 $s_j = ([x_j, y_j], t_j)$, 其中 $t_i < t_j$, 以及对象的最大速度 $v_{\max} > 0$, 则对于任意时间点 $t \in [t_i, t_j]$, 对象 o 在时间 t 的运动范围 (Motion Range) 记为 $MR(o, t)$, 其定义如下:




图 2-2 Illustration of time-point motion range

$$MR(o, t) = \{(x, y) \in \mathbb{R}^2 \mid dist((x, y), (x_i, y_i)) \leq v_{\max}(t - t_i) \wedge dist((x, y), (x_j, y_j)) \leq v_{\max}(t_j - t)\} \quad (2-1)$$

其中 $dist(\cdot, \cdot)$ 表示欧氏距离度量。几何上, $MR(o, t)$ 为两个圆形区域的交集, 呈透镜 (lens) 形状, 如图 2-2 所示, 其两个半径分别为 $r_i = v_{\max}(t - t_i)$ 和 $r_j = v_{\max}(t_j - t)$ 。

上述时间点运动范围的建模方式与不确定移动对象研究中的经典模型保持一致 [211, 220, 221]。通过引入最大速度约束, 所构建的运动范围在理论上能够覆盖对象在采样间隔内的所有可能位置, 从而保证结果的完备性。

特别地, 当 $t = t_i$ 或 $t = t_j$ 时, 有 $MR(o, t_i) = \{(x_i, y_i)\}$, $MR(o, t_j) = \{(x_j, y_j)\}$, 即运动范围退化为对应时间戳处的采样点。

需要指出的是, 若采样时间间隔异常长, 则基于最大速度构建的运动范围可能过于宽松, 从而导致候选区域显著扩大。本文假设采样间隔处于合理范围内, 异常长间隔的处理不在本文讨论范围之内。

定义 2.3 (运动范围特征) 设 $\mathcal{F}(o, t)$ 表示位于运动范围 $MR(o, t)$ 内的一组特定特征, 即 $\mathcal{F}(o, t) = \{f \mid f \text{ 位于 } MR(o, t)\}$ 。该特征集合可根据具体应用进行定义, 例如运动范围的面积度量、范围内的兴趣点集合、经过的道路路段集合, 或与地理空间区域及环境因素相关的特征等。

定义 2.4 (时间点交集相似性) 对象 o 与 o' 在时间 t 处的时间点交集相似性记为 $IS(o, o', t)$, 用于度量其特征集合的重叠程度, 定义如下:

$$IS(o, o', t) = \frac{|\mathcal{F}(o, t) \cap \mathcal{F}(o', t)|}{|\mathcal{F}(o, t)|} \cdot \frac{|\mathcal{F}(o, t) \cap \mathcal{F}(o', t)|}{|\mathcal{F}(o', t)|}. \quad (2-2)$$

其中, $|\mathcal{F}(\cdot)|$ 表示特征集合的基数, $\cap$ 表示集合交运算。相似性取值范围为 $[0, 1]$: 当两个特征集合完全重叠时取值为 1, 当不存在任何重叠时取值为 0。

时间点交集相似性的定义基于如下考虑。 $MR(o, t)$ 描述对象 o 在时间 t 可能

占据的位置范围，而 $\mathcal{F}(o, t)$ 表示该范围内的相关特征集合。采用乘积形式意味着两个比例因子必须同时较大，相似性才会取得较高数值，从而保证仅当运动范围重叠程度高且特征相似性强这两个条件同时满足时，相似性得分才显著提升。相比 Jaccard 指数、算术平均或最小值策略，该定义能够更有效地平衡覆盖率与一致性。

定义 2.5（时间区间交集相似性） 给定时间区间 $I = [t_s, t_e]$ ，对象 o 与 o' 在区间 I 上的交集相似性定义为时间点交集相似性的时间平均值：

$$IS(o, o', I) = \frac{\int_{t_s}^{t_e} IS(o, o', t) dt}{t_e - t_s}. \quad (2-3)$$

计算时间区间交集相似性并非易事。由于时间区间的连续性，理论上需要在无限多个时间点上评估 $IS(o, o', t)$ 。为在大规模移动对象数据场景下实现可扩展计算，并在不显著损失一般性的前提下获得高效近似结果，本文进一步提出了一种放宽的交集相似性定义。

定义 2.6（ ϵ -放宽的时间区间交集相似性） 给定一个较小的常数 ϵ ，我们对时间区间 $I = [t_s, t_e]$ 进行 ϵ -采样，通过均匀采样得到一组时间点 $T^\epsilon = \{t_1^\epsilon, \dots, t_m^\epsilon\}$ ，其中 $t_1^\epsilon = t_s$ ， $t_m^\epsilon = t_e$ ，且满足 $t_{i+1}^\epsilon - t_i^\epsilon = \epsilon$ 。随后，我们将 ϵ -放宽的时间区间交集相似性定义为对象 o 与 o' 在所有采样时间点 $t^\epsilon \in T^\epsilon$ 上的时间点交集相似性的平均值，记为 $IS(o, o', I, \epsilon)$ ，其计算方式如公式 2-4 所示。

$$IS(o, o', I, \epsilon) = \frac{\sum_{i=1}^m IS(o, o', t_i^\epsilon)}{m} \quad (2-4)$$

从本质上看，时间区间相似性的计算需要对多个时间点上的时间点交集相似性进行评估。在下文中，如无特殊说明，为表述简洁起见，我们使用“交集相似性”来指代 ϵ -放宽的交集相似性。当 ϵ 趋近于 0 时， $IS(o, o', I, \epsilon)$ 将收敛到 $IS(o, o', I)$ 。

示例 2.2 图 2-3 给出了一个时间区间交集相似性计算的示例。考虑时间区间 $I = (t_4, t_5)$ ，令 $\epsilon = |I|/4$ ，则采样得到的时间集合为 $T^\epsilon = t_4, t_4 + \epsilon, t_4 + 2\epsilon, t_4 + 3\epsilon, t_5$ 。两个移动对象 o_2 和 o_3 在 T^ϵ 中各采样时间点处均具有对应的时间点运动范围。在时间点 t_4 和 $t_4 + \epsilon$ 处，两者的运动范围不存在交集，因此 $IS(o_2, o_3, t_4) = 0$ 且 $IS(o_2, o_3, t_4 + \epsilon) = 0$ 。在 t_5 时刻， o_2 与 o_3 的位置采样点相同，从而得到 $IS(o_2, o_3, t_5) = 1$ 。因此，区间 I 上的 ϵ -放宽时间区间交集相似性可计算为 $(0 + 0 + IS(o_2, o_3, t_4 + 2\epsilon) + IS(o_2, o_3, t_4 + 3\epsilon) + 1)/5$ 。其中， $IS(o_2, o_3, t_4 + 2\epsilon)$ 和 $IS(o_2, o_3, t_4 + 3\epsilon)$ 的取值依据公式 2-2 计算，该公式能够适应不同应用场景下的具体需求。

我们在定义 2.7 中对交集相似性连接问题进行形式化描述。

定义 2.7（IS-Join） 给定对象集合 $\mathcal{A}$ 和 $\mathcal{B}$ 、带有放宽划分参数 ϵ 的查询时间区间 I ，以及相似性阈值 θ ，交集相似性连接（Intersection Similarity Join, IS-Join）旨




图 2-3 时间区间交集相似性的示意图

在从这两个集合中找出所有交集相似性不小于 θ 的对象对所构成的集合 $\mathcal{P}$ ，即对于任意 $(o_i, o_j) \in (\mathcal{A} \times \mathcal{B}) \setminus \mathcal{P}$ ，均有 $(IS(o_i, o_j, I, \epsilon) < \theta)$ 。

2.3 基于 M*-树的连接算法

首先，我们介绍一种基于 M*-树的连接算法 (MBJ-Alg) 用于计算 IS-Join，作为本文的基线方法。M*-树是经典 M-tree 的扩展 [206, 207]。M-tree 是一种面向一般度量空间 (metric space) 的动态平衡索引结构，其设计建立在距离函数满足三角不等式的基础之上，因此能够在不依赖具体空间坐标结构的情况下进行有效剪枝。M*-树继承了这一性质，并针对时间区间运动范围的近似表示进行了结构扩展。

MBJ-Alg 采用两阶段处理框架，并结合预检查 (pre-check) 策略以增强候选对象的过滤能力。该框架遵循“先粗后精”的思想：首先利用度量空间索引结构进行快速筛选，随后对候选对象进行精确验证，从而在保证正确性的前提下提升整体效率。

在阶段 1 中，M*-树使用近似圆 (approximated circle) 对时间区间 I 内的运动范围 $MR(o, I)$ 进行紧凑表示，并基于圆心与覆盖半径构建层次化索引结构。具体而言，每个时间区间运动范围被映射为一个能够完全覆盖该范围的最小近似圆。由于圆之间的相交关系可通过中心距离与半径之和进行判定，因此可以在树遍历过程中基于三角不等式进行安全剪枝。该阶段的目标是快速识别所有“可能相交”的候选对象对，而不进行昂贵的相似性计算。

在阶段 2 中，对阶段 1 产生的候选对象对执行精炼 (refinement) 操作，即基于时间点运动范围计算 ϵ -放宽的时间区间交集相似性 $IS(o, o', I, \epsilon)$ ，并根据阈值 θ 进行最终判定。由于精炼阶段仅作用于候选集合，因此可以显著降低总体计算成本。

下面将详细介绍 M*-树的结构设计及其在 IS-Join 查询中的具体应用。




图 2-4 M*-树的结构

2.3.1 M*-树

首先，我们介绍一种基于 M*-树的连接算法（MBJ-Alg）用于计算 IS-Join，这作为基线方法。M*-树是 M-tree 的一种扩展 [206, 207]。MBJ-Alg 是一个两阶段算法，结合了预检查策略，其中使用 M-tree 的变体来增强候选对象的过滤能力。

在阶段 1 中，M*-树使用近似圆来索引时间区间内的运动范围。这种圆形索引允许提前剪枝不合格对象，从而集中于更可能发生交集的候选对象。在阶段 2 中，对候选对象在时间点运动范围级别进行评估。下面将介绍 M*-树的结构及其在 IS-Join 查询中的应用。

图 2-4 展示了 M*-树的结构，其指定容量为 $M = 4$ ，表示每个叶节点的最大条目数。近似圆被视为单独的条目，并独立存储在叶节点中。我们使用近似圆表示时间区间的运动范围，并在 M*-树中对其进行索引。每个圆存储为条目 $E = \{o, x, y, r, MR(o, I)\}$ ，其中 o 为对象标识， (x, y) 表示圆心， r 为半径， $MR(o, I)$ 包含时间区间的运动范围。M*-树中的每个节点 N 选择叶节点中的一个条目 E 作为其路由对象，格式为 $N = \{E, R, pt(child)\}$ 。这里， E 是路由对象， R 是能够覆盖 N 中所有条目（即圆）的半径， $pt(child)$ 是指向子节点的指针。需要注意的是，M*-树在条目插入策略、节点分裂策略和路由对象选择策略上遵循了已有研究 [207, 211] 的做法，并将这些策略适配到 M*-树结构中。

值得注意的是，同一 M*-树内的时间区间运动范围在时间上是对齐的。我们为特定时间区间索引所有运动范围，当时间区间改变时，需要重建 M*-树索引。

2.3.2 交集检查

我们从查询条目 $E_q = (q, x_q, y_q, r_q, MR(q, I))$ 和 M*-树的根节点开始。目标是检索所有可能与 E_q 相交的条目 $E = \{o, x, y, r, MR(o, I)\}$ 。为了确定潜在交集，我们计算查询对象 q 与每个条目 E 之间的距离 $d(q, E) = \sqrt{(x_q - x)^2 + (y_q - y)^2}$ 。如

果 $d(q, E) \leq r + r_q$ ，则时间区间运动范围 $MR(q, I)$ 和 $MR(o, I)$ 可能相交。其中， r 和 r_q 分别表示条目 E 和 E_q 的半径。对于每个查询对象 q ，我们索引所有满足 $d(q, E) \leq r + r_q$ 的条目，并将对应的 (q, o) 加入候选集合，其中 o 是与条目 E 关联的对象标识。

2.3.3 算法细节

算法 2-1: $MBJ(\mathcal{A}, \mathcal{B}, N_r, I, \epsilon, \theta)$

```

输入: 两组移动对象,  $\mathcal{A}$  和  $\mathcal{B}$ ;
        M*-树的根节点  $N_r$ ;
        时间间隔  $I$ ;
        分区参数  $\epsilon$ ;
        交集相似度阈值  $\theta$ 。

输出:  $\mathcal{R} = \{(o, o') \mid IS(o, o', I, \epsilon) \geq \theta, (o, o') \in \mathcal{A} \times \mathcal{B}\}$ 。

1  初始化:  $\mathcal{R} \leftarrow \emptyset$ ;
2  for  $o \in \mathcal{A}$  do                                     /* 遍历集合  $\mathcal{A}$  */
3       $\mathcal{L} \leftarrow \{N_r\}$ ;
4      while  $\mathcal{L} \neq \emptyset$  do                             /* M*-树遍历 */
5           $N \leftarrow \mathcal{L}.pop()$ ;
6          if  $N$  是非叶子节点 then                             /* 非叶子节点 */
7              for  $N_c \in N.pt(child)$  do                     /* 遍历子节点 */
8                  if  $d(o, N_c) \leq N_c.R + o.r$  then
9                       $\mathcal{L}.push(N_c)$ ;
10             else                                           /* 叶子节点处理 */
11                 if  $d(o, N) > N.R + o.r$  then
12                      $prune(o, N.o)$ ;                         // 预检查策略
13                 if  $IS(o, N.o, I, \epsilon) \geq \theta$  then
14                      $\mathcal{R} \leftarrow \{\mathcal{R}, (o, N.o)\}$ ;         // 精炼步骤
15 return  $\mathcal{R}$ ;
    
```

算法 2-1 给出了基于 M*-树的两阶段剪枝匹配算法 (MBJ-Alg) 的伪代码。算法的输入包括两个移动对象集合、M*-树的根节点、带分区参数 ϵ 的时间区间，以及相似度阈值 θ 。我们使用列表 $\mathcal{R}$ 存储所有满足条件的对象对，初始时 $\mathcal{R}$ 为空（第 1 行）。

该算法由两个阶段组成：(1) 基于 M*-树的预检查（第 3–12 行），以及 (2) 精炼过程（第 13–14 行）。在预检查阶段，我们根据 M*-树获取候选对象集合。我们使用列表 $\mathcal{L}$ 存储可能与移动对象相交的节点，初始时 $\mathcal{L}$ 仅包含根节点（第 3 行）。

当 $\mathcal{L}$ 非空时，我们从中取出与对象 o 的距离 $d(o, N)$ 最小的 M*-树节点 N （第

5 行)。如果 N 不是叶节点, 则考虑其子节点。对于 N 的每个子节点 N_c , 我们检查 o 与 N_c 之间的距离。如果该距离不大于 o 与 N_c 半径之和, 则将 N_c 压入优先队列 (第 7–9 行)。

如果 N 是叶节点, 且 $d(o, N) > N.R + o.r$, 则可以安全地剪枝 $(o, N.o)$ (第 11–12 行)。当交集相似度不小于阈值 θ 时, 我们通过将 $(o, N.o)$ 添加到结果集来更新 $\mathcal{R}$ (第 14 行)。

最后, 返回 $\mathcal{R}$ 作为得到的交集对象对 (第 15 行)。

2.3.3.1 时间复杂度分析

一般来说, 构建 M^* -树需要 $O(|\mathcal{B}| \times n)$ 的时间, 其中 $\mathcal{B}$ 是被 M^* -树索引的对象集合, n 是节点分裂操作的次数。具体来说, 当由于对象插入导致节点已满时, 需要将其分裂为多个节点, 这一操作的时间复杂度为 $O(|\mathcal{B}|)$ 。值得注意的是, 实际构建时间可能会因数据分布等因素而有所不同。

设 $\mathcal{A}$ 为查询对象集合。为了找到所有候选对象, 过滤过程的时间复杂度为 $O(|\mathcal{A}| \times \log |\mathcal{B}|)$ 。若时间点运动范围内的 POI 平均数量为 p , 则每次计算 $IS(o, o', I, \epsilon)$ 的时间复杂度为 $O(|I|/\epsilon \times p)$ 。

设 $\mathcal{C}$ 为候选对象集合。对候选对象进行精炼的时间复杂度为 $O(|\mathcal{C}| \times |I|/\epsilon \times p)$ 。

因此, MBJ-Alg 每轮执行的总时间复杂度为

$$O(|\mathcal{B}| \times n + |\mathcal{A}| \times \log |\mathcal{B}| + |\mathcal{C}| \times |I|/\epsilon \times p)。$$

2.4 运动范围引导的匹配方法

为高效地回答 IS-Join 查询, 我们提出了一种由时间区间运动范围引导的匹配方法。在时间区间阶段, 我们首先进行预检查, 以判断两个对象的时间点运动范围之间是否存在交集。具体而言, 我们定义时间区间运动范围 $MR(o, I)$, 用于刻画对象 o 在区间 I 内可能到达的所有位置。如果 $MR(o, I) \cap MR(o', I) = \emptyset$, 则可推出 $IS(o, o', I, \epsilon) = 0$, 从而对对象对 (o, o') 进行剪枝。为高效判定 $MR(o, I) \cap MR(o', I) = \emptyset$, 我们提出了一种新的混合 Ball-tree (Hybrid Ball-tree, HBall-tree) 结构。同时, 我们引入了一种基于交集相似度上界的剪枝增强方法, 以进一步剔除不满足条件的对象对, 从而细化整体处理流程。在精化阶段, 计算运动范围内特征的交集以度量交集相似度。我们首先介绍基于时间区间运动范围的预检查策略, 随后给出基于混合 Ball-tree 的连接算法 (HBJ-Join)。

2.4.1 时间区间预检查

本节介绍时间区间运动范围的概念，并给出具有理论保证的预检查策略。

定义 2.8 (时间区间运动范围) 给定移动对象 o 的两个带时间戳的位置样本 $s_i = ([x_i, y_i], t_i)$ 和 $s_j = ([x_j, y_j], t_j)$ ，以及在 t_i 与 t_j 之间的最大速度 v_{max} ，对象 o 在时间区间 $I = [t_i, t_j]$ 内的运动范围，记为 $MR(o, I)$ ，被定义为对象 o 在区间 I 内可能到达的空间区域。

定理 2.1 给出了计算 $MR(o, I)$ 的方法。

定理 2.1 对象 o 的运动范围 $MR(o, I)$ 是由公式 2-5 表示的一个椭圆区域。椭圆的中心点记为 (x_c, y_c) ，由公式 2-6 计算得到；椭圆的旋转角度记为 α ，由公式 2-7 计算，其中 a 和 b 分别表示半长轴和半短轴。

$$\left[\frac{(x - x_c) \cos \alpha + (y - y_c) \sin \alpha}{a} \right]^2 + \left[\frac{(x_c - x) \sin \alpha + (y - y_c) \cos \alpha}{b} \right]^2 = 1 \quad (2-5)$$

$$\begin{aligned} x_c &= \frac{x_i + x_j}{2}, \quad y_c = \frac{y_i + y_j}{2}, \\ a &= \frac{v_{max} \cdot (t_j - t_i)}{2}, \\ b &= \frac{\sqrt{v_{max}^2 \cdot (t_j - t_i)^2 - (x_j - x_i)^2 - (y_j - y_i)^2}}{2} \end{aligned} \quad (2-6)$$

$$\alpha = \arctan\left(\frac{y_j - y_i}{x_j - x_i}\right) \quad (2-7)$$

证明：对象 o 在时间区间 I 内能够行进的最大距离为 $(t_j - t_i) \cdot v_{max}$ ，该结论同时适用于欧氏空间和路网空间。给定两个位置样本 s_i 和 s_j ，对象 o 在某一具体时间点 t 的运动范围可由公式 ?? 定义。需要注意的是，椭圆上任意一点到其两个焦点的距离之和为常数 $2a$ 。当 $v_{max} \cdot (t_j - t_i) = 2a$ 时，从 t_i 到 t_j 的所有可能到达位置构成一个以 (x_i, y_i) 和 (x_j, y_j) 为焦点的椭圆区域，如图 2-5 所示。我们对时间区间运动范围的建模方式与已有研究保持一致 [211, 221]。 ■

基于定理 2.2，我们提出了一种预检查策略：若 $MR(o, I) \cap MR(o', I) = \emptyset$ ，则可以在早期阶段安全地剪枝对象对 (o, o') ，从而避免对特征集合（例如 POI、运动范围面积等）进行不必要的交集计算。

定理 2.2 给定两个对象 o 和 o' ，若 $MR(o, I) \cap MR(o', I) = \emptyset$ ，则 $IS(o, o', I, \epsilon) = 0$ 。

证明：对于对象 o 和 o' ，如果它们在时间区间 I 内的时间区间运动范围不相交，则在 I 内任意时间点上， o 与 o' 的时间点运动范围都不可能发生重叠。由于与




图 2-5 时间区间运动范围示例

各自时间点运动范围相关的特征集合 $P(o, t)$ 和 $P(o', t)$ 在整个区间 I 内均不存在交集，因此在区间 I 上的交集相似度为 0。 ■

为了判断两个时间区间运动范围是否相交，一种直接的方法是计算它们的两两距离。具体而言，若距离 $dist(MR(o, I), MR(o', I))$ 大于 $MR(o, I).a + MR(o', I).a$ ，则两个运动范围不相交。其中， $dist(MR(o, I), MR(o', I))$ 表示 $MR(o, I)$ 与 $MR(o', I)$ 中心点之间的距离， a 表示运动范围的半长轴。这种直接方法在进行一对一比较时需要 $O(\mathcal{A} \times \mathcal{B})$ 的时间复杂度，计算代价较高。




图 2-6 混合 Ball-tree 的示意图

2.4.2 基于 HBall-tree 的交集预检查

我们提出了一种混合 Ball-tree (Hybrid Ball-tree, HBall-tree)，这是一种面向高效预检查的改进型索引结构，并展示了其如何提升“过滤-精化”过程的整体效率。

2.4.2.1 HBall-tree

我们选择 Ball-tree [208, 209, 222] 作为基础索引结构，这是因为相较于 R-tree [176] 和四叉树 [223] 等索引，Ball-tree 在处理类圆对象时表现更优 [206, 207, 211]。然而，当将 Ball-tree 应用于 IS-Join 查询时，仍然存在两个关键局限性。首先，Ball-tree 主要面向点或圆级别的最近邻搜索设计，无法直接支持时间区间运动范围的索引。其次，其划分过程未考虑数据点的分布情况，可能导致划分不均衡，从而形成高度不平衡的树结构 [210]。

为了解决第一个问题，我们将每个时间区间运动范围近似为一个圆 [211]。具体而言，该圆以时间区间运动范围的中心为圆心，其半径等于半长轴长度。该近似方式简化了时间区间运动范围的表示，使我们能够直接利用现有针对圆形对象设计的空间索引结构。其关键推论在于：如果两个近似圆不相交，则其对应的时间区间运动范围也必然不相交。该推论构成了我们过滤策略的基础，从而能够高效识别不可能发生交集的对象对。

为了解决第二个问题，我们提出了混合 Ball-tree (HBall-tree)，这是一种能够考虑数据分布特性的全新索引结构。图 2-6 给出了 HBall-tree 的示意图。每个时间区间运动范围被表示为 $E = \{o, x, y, r, MR(o, I)\}$ ，其中 (x, y) 和 r 分别表示近似圆的中心和半径， o 表示对象标识符。与原始 Ball-tree 每个非叶节点仅包含两个子节点不同，HBall-tree 通过一种重新划分 (repartition) 技术，使得每个父节点最多可以拥有三个子节点。每个节点的结构表示为 $N = \{p, R, pt(child_l), pt(child_m), pt(child_r), \mathcal{I}\}$ ，其中 p 表示节点 N 所覆盖的时间区间运动范围的中心点， R 表示能够包围节点 N 中所有条目（即圆）的半径， $pt(\cdot)$ 为指向子节点的指针， $\mathcal{I}$ 表示该节点中包含的时间区间运动范围集合。HBall-tree 中的插入策略、分裂策略以及枢轴点选择均遵循已有研究中的成熟方法 [222]。当某一子划分中的对象数量低于预定义阈值（即生成新子节点所需的最小对象数）时，子划分过程终止。

2.4.2.2 HBall-tree 的重新划分策略

直观上，更加平衡的树结构通常能够在搜索过程中减少节点访问次数。重新划分方法的整体思想如下：对于每一个初始划分，我们评估其两个子划分中的点数差异是否超过重新划分阈值 β ($\beta \in (0, 1)$)。如果差异超过该阈值，则保留点数较少的子划分，并将点数较多的子划分进一步划分为两个新的子划分。考虑一个节点 N ，初始时 $N.child_m = \emptyset$ 。当较大的子划分规模至少以比例 β 超过较小子划分时，即触发重新划分。例如，当 $|N.child_l.\mathcal{I}| > |N.child_r.\mathcal{I}|$ ，且 $\frac{|N.child_l.\mathcal{I}| - |N.child_r.\mathcal{I}|}{|N.child_r.\mathcal{I}|} \geq \beta$ ，

则触发重新划分。从理论上讲，较小的重新划分阈值会使初始子树更容易被重新划分，从而增加三叉节点的数量，使树结构更加平衡。然而，三叉节点数量的增加也可能导致节点访问次数上升，因此需要在树高与三叉节点数量之间进行权衡。

对于非叶节点，初始划分基于 $N.I$ 中选取的两个最远点进行。具体而言，树构建过程中两个最远点的选取步骤如下：(i) 随机种子点：从 $N.I$ 中随机选择一个点作为初始种子；(ii) 第一个最远点：在数据集中找到距离该种子点最远的点；(iii) 第二个最远点：在数据集中找到距离第一个最远点最远的点。设这两个最远点分别为 $N.child_l.p$ 和 $N.child_r.p$ ，我们计算二者的中点，并在 $N.I$ 中选取距离该中点最近的中心点，记为 p_m 。点数较少的子划分被视为稳定划分，而我们对点数较多的子划分进行重新划分。具体地，若 $|N.child_l.I| > |N.child_r.I|$ ，则使用 p_m 和 $N.child_l.p$ 将 $N.child_l.I$ 中的运动范围重新划分为两个新的子划分，其中一个保留在 $N.child_l.I$ ，另一个分配给 $N.child_m.I$ ；反之，若 $|N.child_l.I| < |N.child_r.I|$ ，则使用 p_m 和 $N.child_r.p$ 对 $N.child_r.I$ 进行重新划分，一个子划分保留在 $N.child_r.I$ ，另一个分配给 $N.child_m.I$ 。最终，重新划分将原有的两个子划分扩展为三个子划分，新生成的子划分由 $N.pt(child_m)$ 索引。该重新划分技术带来了两方面优势：(1) 降低树高与划分数量：通过提升平衡性，减少树的高度并最小化划分数量；(2) 提升搜索效率：更加平衡的树结构能够减少树节点访问次数，从而提高搜索效率。“

2.4.3 基于 HBall-tree 的 Join

我们提出了一种基于 HBall-tree 的 Join 算法。为了进一步提升效率，我们引入了一种剪枝增强方法，利用交集相似度的上界来进一步剔除不满足条件的对象对，从而优化整体处理流程。

2.4.3.1 剪枝增强策略

由于运动范围交集形状的不规则性，直接计算两个特征集合 $\mathcal{F}(o, t)$ 与 $\mathcal{F}(o', t)$ 的交集并非易事。给定时间点 t ，若 $MR(o, t) \cap MR(o', t) \neq \emptyset$ ，当其中一个对象的运动范围完全被另一个对象覆盖时， $IS(o, o', t)$ 取得其最大值。基于这一观察，公式 2-8 给出了 $IS(o, o', t)$ 的一个上界。将公式 2-8 代入公式 2-4，可得到公式 2-9，用于估计 $IS(o, o', I, \epsilon)$ 的上界。若 $IS(o, o', I, \epsilon)_{ub} < \theta$ ，则可以安全地剪枝对象对 (o, o') 。

$$IS(o, o', t)_{ub} = \frac{\min(|\mathcal{F}(o, t)|, |\mathcal{F}(o', t)|)}{\max(|\mathcal{F}(o, t)|, |\mathcal{F}(o', t)|)} \geq IS(o, o', t) \quad (2-8)$$

$$IS(o, o', I, \epsilon)_{ub} = \frac{\sum_{i=1}^m IS(o, o', t_i^\epsilon)_{ub}}{m} \quad (2-9)$$

算法 2-2: $HBJ(\mathcal{A}, \mathcal{B}, N_r, I, \epsilon, \beta, \theta)$

输入: 两组移动对象, $\mathcal{A}$ 和 $\mathcal{B}$;
 HBall-tree 的根节点 N_r ;
 时间间隔 I ;
 松弛参数 ϵ ;
 重分区阈值 β ;
 交集相似度阈值 θ 。

输出: IS-Join 结果, $\mathcal{R}$ 。

```

1  初始化:  $\mathcal{R} \leftarrow \emptyset$ ;
2  for  $o \in \mathcal{A}$  do                                     /* 遍历所有移动对象 */
3       $\mathcal{L} \leftarrow \{N_r\}$ ;
4      while  $\mathcal{L} \neq \emptyset$  do                       /* BFS 遍历 HBall-tree */
5           $N \leftarrow \mathcal{L}.pop()$ ;
6          if  $N$  是非叶子节点 then                       /* 非叶子节点分支 */
7              for  $N_c \in N.pt(child)$  do               /* 遍历子节点 */
8                  if  $dist(o, N_c) \leq N_c.R + o.r$  then
9                       $\mathcal{L}.push(N_c)$ ;
10         else                                           /* 叶子节点处理 */
11             for  $E \in N.I$  do                           /* 遍历叶子节点对象 */
12                 if  $dist(o, E) > E.r + o.r$  then
13                      $prune(o, E.o)$ ;                    // 预检查策略
14                 if  $IS(o, E.o, I, \epsilon)_{ub} < \theta$  then
15                      $prune(o, E.o)$ ;                    // 剪枝增强策略
16                 if  $IS(o, E.o, I, \epsilon) \geq \theta$  then
17                      $\mathcal{R} \leftarrow \{\mathcal{R}, (o, E.o)\}$ ;    // 精炼步骤
18 return  $\mathcal{R}$ ;
    
```

2.4.3.2 算法细节

算法 2-2 给出了基于 HBall-tree 的 Join 算法 (HBJ-Alg) 的伪代码。该算法的输入包括两个移动对象集合、HBall-tree 的根节点、重分区阈值以及交集相似度阈值; 输出结果为交集对象对集合 $\mathcal{R}$ 。初始时, $\mathcal{R}$ 为空 (第 1 行)。对于每一个 $o \in \mathcal{A}$, 我们使用列表 $\mathcal{L}$ 存储可能与 $MR(o, I)$ 发生交集的候选节点, 初始时 $\mathcal{L}$ 仅包含根节点 N_r (第 3 行)。HBall-tree 通过插入对象集合 $\mathcal{B}$ 的时间区间运动范围构建完成。

当 $\mathcal{L}$ 非空时, 算法调用 $\mathcal{L}.pop()$ 取出一个节点 N (第 5 行)。随后, 在“圆级

别”执行基于 HBall-tree 的过滤，以识别潜在的交集候选（第 6–9 行）。具体而言，我们检索 HBall-tree 中满足 $dist(o, N_c) \leq R + r_q$ 的节点，从而判断 $MR(o, I)$ 与 N_c 之间是否可能存在交集。若 N 为非叶节点，则检查其子节点。对于每个子节点 N_c ，若对象 o 与 N_c 的距离不大于二者半径之和，则将 N_c 压入优先队列（第 8–9 行）。

若 N 为叶节点，则遍历 $N.I$ 中的所有条目。对于每个条目 E ，计算 $(E.x, E.y)$ 与 $(MR(o, I).x_c, MR(o, I).y_c)$ 之间的欧氏距离 $dist(o, E)$ 。若 $dist(o, E) > E.r + o.r$ ，则可安全剪枝 $(o, E.o)$ （第 12–13 行）。否则，继续执行进一步的剪枝操作，即剪枝增强策略（第 14–15 行）。仅对保留下来的对象对，才进行精确的交集相似度计算，即利用公式 2-2 计算多个时间点的交集相似度（第 16–17 行）。最终返回结果集合 $\mathcal{R}$ （第 18 行）。

2.4.3.3 时间复杂度

HBall-tree 的构建时间复杂度为 $O(|\mathcal{B}| \times \log |\mathcal{B}|)$ 。预检查阶段的时间复杂度为 $O(|\mathcal{A}| \times \log |\mathcal{B}|)$ 。设 $\mathcal{C}'$ 为候选集合，则候选精化阶段的时间复杂度为 $O(|\mathcal{C}'| \times |I|/\epsilon \times p)$ 。因此，HBJ-Alg 的总体时间复杂度为

$$O((|\mathcal{A}| + |\mathcal{B}|) \times \log |\mathcal{B}| + |\mathcal{C}'| \times |I|/\epsilon \times p).$$

HBJ-Alg 得益于增强的剪枝策略，显著减少了需要进行精化计算的候选对象对数量。

2.5 实验研究

在本节中，开展了广泛的实验对本章算法性能进行评估。首先介绍实验设定，包括实验所使用的数据集，运行环境等，然后给出实验结果与分析。实验结果主要关注所提出的搜索算法的运行时间，即高效性方面的表现。实验的目的在于，通过设置不同的参数（查询关键字数目，查询区域大小，解析阈值，覆盖率阈值，索引查询数目等），对比不同的算法的运行时间并进行分析。

2.5.1 实验设置

2.5.1.1 数据准备

实验研究^①在两个真实世界的轨迹数据集上进行。第一个数据集 Geolife [202, 224] 包含来自 182 名用户、历时四年的 17,621 条轨迹，涵盖了多种户外移动行为，包括日常通勤以及购物、骑行等休闲活动。第二个数据集 Porto [225] 包含在葡萄牙波尔图市 19 个月内记录的超过 170 万条出租车轨迹。Porto 数据集的轨迹以 15

^① 代码已开源：<https://github.com/likemelike/IS-Join>

秒为采样间隔记录，而 Geolife 的采样频率则不固定。时间戳被限定在 24 小时范围内，而不考虑具体日期，因为大多数城市交通出行行为具有日常重复性。我们将对象的最大速度 v_{max} 定义为其在给定时间区间内观测到的最高速度。确定 v_{max} 的真实取值或最优设置超出了本文的研究范围。为保证实际应用相关性，我们剔除了采样时间间隔过大（超过一小时）的极端轨迹，因为这类轨迹在现实应用中实用性有限，因此不纳入本研究。我们注意到，在隧道等环境中 GPS 信号可能较弱甚至完全丢失，从而导致异常位置或较低的采样率。尽管对这类异常值进行显式建模超出了本文的研究范围，但我们的数据预处理流程通过基于经度、纬度、轨迹长度和速度等约束过滤异常轨迹，从而在一定程度上缓解了这些影响。预处理后，Geolife 数据集中保留了 18,670 条轨迹中的 12,015 条有效轨迹，Porto 数据集中保留了 1,710,670 条轨迹中的 1,392,385 条。随后，从数据集中随机选取两个包含相同数量移动对象的对象组。

2.5.1.2 对比算法

我们将所提出的方法与一种设计良好的基于 M-tree 的连接算法 [211]（见附录）进行对比，记为 MBJ-Alg，作为基线方法。为评估剪枝增强策略的影响，我们还测试了不包含剪枝增强策略的 HBJ-Alg，记为 HBJ-Alg#。在效率评估方面，我们同时衡量剪枝率和 CPU 时间。剪枝率定义为 $1 - |C|/|O|^2$ ，其中 C 表示候选集。CPU 时间表示算法每一轮的平均运行时间。此外，我们还评估了不采用重新划分策略的 HBJ-Alg，记为 HBJ-Alg*。

	Geolife	Porto
$ O $	$\{4,6,8,10,12\} \times 10^3$ 8K (默认)	$\{1,2,3,4,5\} \times 10^4$ 10K (默认)
$ I $	$\{10s, 20s, 30s, 40s, 50s\}$ 30s (默认)	$\{15s, 30s, 45s, 60s, 75s\}$ 45s (默认)
$ \mathcal{F} $	$\{2, 4, 6, 8, 10\} \times 10^5$ 600K (默认)	$\{1, 2, 3, 4, 5\} \times 10^5$ 100K (默认)
ϵ	$\{\frac{ I }{2}, \frac{ I }{4}, \frac{ I }{6}, \frac{ I }{8}, \frac{ I }{10}\}$ $\frac{ I }{6}$ (默认)	$\{\frac{ I }{2}, \frac{ I }{4}, \frac{ I }{6}, \frac{ I }{8}, \frac{ I }{10}\}$ $\frac{ I }{6}$ (默认)

表 2-2 评估参数设置

2.5.1.3 参数设置

参数设置如表 2-2 所示。M*-tree 和 HBall-tree 的叶节点容量均设置为 10。默认情况下，重新划分阈值 α 设为 0.5。在实验中，特征集合 $\mathcal{F}$ 由随机生成的兴趣点

(POIs) 构成。具体而言, 我们首先确定所有轨迹的最小和最大经度与纬度值, 在该空间范围内使用均匀分布随机生成固定数量的 POIs。默认情况下, 在 Porto 数据集的坐标范围内生成 100,000 个 POIs, 在 Geolife 数据集中生成 600,000 个 POIs。默认距离度量采用欧氏距离。所有方法均使用 Java 实现, 并在配备 AMD Ryzen 5 CPU (3.6GHz) 和 32GB 内存的 Ubuntu 系统上进行评测, 采用单线程执行。除非另有说明, 实验结果均为 20 次独立实验的平均值, 每次实验使用不同的轨迹数据和特征集。

2.5.2 实验结果与分析

2.5.2.1 剪枝有效性评估

首先, 我们在默认参数设置下考察各算法的剪枝有效性。实验结果如表 2-3 所示。通过比较 MBJ-Alg 与 HBJ-Alg 的候选集规模和剪枝率可以发现, 在 Geolife 和 Porto 数据集上, HBJ-Alg 的候选集规模分别仅为 MBJ-Alg 的 0.5% 和 2.3%。这些结果表明, 所提出的方法能够显著压缩搜索空间。

方法 指标/数据集	MBJ-Alg	HBJ-Alg
候选集规模 (Geolife)	6540764	28862
剪枝率 (Geolife)	89.7800%	99.9549%
候选集规模 (Porto)	2142988	50072
剪枝率 (Porto)	97.8570%	99.9499%

表 2-3 剪枝性能

接下来, 我们在不同参数设置下进一步评估所提出算法的性能。需要说明的是, 在改变某一个参数时, 其余参数均保持为默认值。

2.5.2.2 移动对象基数的影响

我们研究了不同移动对象基数 $|O|$ 对算法性能的影响。直观上, 较大的 $|O|$ 会导致需要处理更多的时间区间运动范围, 因此所有算法的运行时间都将随之增加。首先, 我们评估了 MBJ-Alg、HBJ-Alg 以及 HBJ-Alg* 的索引构建时间, 结果如图 2-7 所示。可以清楚地看到, MBJ-Alg 的构建开销明显高于 HBJ-Alg。与 HBJ-Alg* 相比, HBJ-Alg 表现出相近且略有提升的性能。这一改进主要得益于 HBJ-Alg 中的再划分技术: 尽管在触发再划分时会引入额外计算开销, 但该技术能够减少总体分区数量, 从而在整体上有助于降低构建时间。

接下来, 我们分析了所提出算法在 IS-Join 查询中的总运行时间。随着移动对




图 2-7 不同 $|O|$ 下的构建时间影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验




图 2-8 不同 $|O|$ 下的查询时间影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验

象数量的增加, 由于交集候选对数量增多, 计算负载显著上升, 所有算法的时间复杂度均随之提高。从图 2-8 可以观察到, 随着数据规模的扩大, MBJ-Alg 的 CPU 时间显著增加。例如, 在 Geolife 数据集包含 12K 个移动对象、Porto 数据集包含 50K 个移动对象时, MBJ-Alg 的查询时间分别超过 3 秒和 30 秒, 计算开销较大。相比之下, HBJ-Alg 和 HBJ-Alg# 始终优于 MBJ-Alg, 尤其在大规模数据集上表现出更高的效率。值得注意的是, HBJ-Alg 的 CPU 时间几乎没有明显退化, 充分体现了所提出方法的良好可扩展性。此外, 与 HBJ-Alg# 相比, HBJ-Alg 的运行时间降低了约 30%, 突出了剪枝增强策略所带来的性能提升。具体而言, 在 Geolife 数据集包含 12,000 个移动对象、Porto 数据集包含 50,000 个移动对象时, HBJ-Alg 相比 MBJ-Alg 在 Geolife 上实现了 3.1x 的加速, 在 Porto 上实现了 3.3x 的加速。




图 2-9 POI 数量对运行时间的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验

2.5.2.3 特征数量的影响

在实验中，我们将运动范围的特征集合设定为兴趣点（POI）。直观而言，在相同的时间区间运动范围内，较大的 $|F|$ 意味着两个对象之间存在更多潜在的交集位置，这可能由于需要进行额外的位置检查而导致运行时间增加。如图 2-9 所示，随着 $|F|$ 的增大，所有算法的运行时间均呈现出轻微的上升趋势。然而，所提出的预检查策略和剪枝增强方法能够在早期阶段有效地剔除大量不可能满足条件的对象对，从而显著减少需要进行 POI 交集计算的候选数量。因此，POI 集合规模对整体运行时间的影响较小，进一步验证了所提出方法的良好可扩展性。

2.5.2.4 时间区间的影响

我们使用 $|I|$ 表示给定时间区间的持续时长。具体而言，在 Geolife 数据集中， $|I|$ 从 10 秒变化到 50 秒；在 Porto 数据集中， $|I|$ 从 15 秒变化到 75 秒。较大的 $|I|$ 会扩大潜在的时间区间运动范围，从而导致具有交集的对象对数量增加以及候选集规模增大。因此，所有算法在识别满足条件的对象对时都需要更多的计算开销。图 2-10 展示了随着 $|I|$ 增大时的效率表现。正如预期的那样，随着 $|I|$ 的增加，所有算法的运行时间均呈上升趋势，其中 HBJ-Alg 在所有参数设置下始终优于 MBJ-Alg 和 HBJ-Alg#。通过利用 M*-tree，我们在一定程度上提升了过滤性能，并减少了后续需要进一步处理的候选对象数量。然而，由于 M-tree 的原始设计在构建阶段需要进行耗时的节点分裂操作，其并不适合直接用于 IS-Join 查询。此外，在大规模移动对象场景下，对仅覆盖单个时间区间运动范围的圆进行索引，可能会导致搜索空间膨胀，从而对查询性能产生不利影响。




图 2-10 $|I|$ 对运行时间的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验




图 2-11 参数 ϵ 的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验

2.5.2.5 ϵ 的影响

较小的 ϵ 值意味着需要探测更多的时间点运动范围,使得放松后的相似度更加接近真实的交集相似度,从而带来更高的计算开销,并导致运行时间的增加。图 2-11 展示了在变化放松参数 ϵ 时的效率表现。在实验中,我们将时间点运动范围的数量从 2 变化到 10。随着 ϵ 的变化,可以观察到运行时间呈现出轻微的上升趋势。同时也可以看到,在所有参数设置下, HBJ-Alg 始终表现出最优的性能。

2.6 IS-Join 的附加实验

2.6.0.1 相似度阈值的影响

对于 HBJ-Alg, 增加相似度阈值 θ 可以提高剪枝效果。较大的 θ 减少搜索空间,从而降低 CPU 时间和访问的时间区间运动范围数量。图 2-12 展示了在改变相似度阈值时的效率表现。与 MBJ-Alg 对比, HBJ-Alg 在所有设置下均优于 MBJ-




图 2-12 相似度阈值的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验




图 2-13 移动对象数量对节点访问次数的影响 (a):Geolife 数据集下的实验; (b):Porto 数据集下的实验

Alg，运行时间最多可提升 3 倍。虽然 HBJ-Alg 在较高阈值下运行时间略有下降，但 MBJ-Alg 和 HBJ-Alg# 的趋势不明显。

2.6.0.2 重新分区策略的评估

我们比较 HBJ-Alg 和 HBJ-Alg* 的性能，主要指标为节点访问总次数。图 2-13 显示了移动对象数量对重新分区策略性能的影响（默认设置）。随着移动对象数量增加，节点访问总数也增加。HBJ-Alg 与 HBJ-Alg* 的性能差距随对象数量增长而扩大。HBJ-Alg 的重新分区策略可在不增加索引构建时间的情况下，将节点访问数减少约 10%，甚至可能降低索引构建时间（见图 2-7）。因此，重新分区策略有助于提升整体效率，处理大规模数据集时更有效。

2.7 本章小结

本文提出了一种新的面向移动对象的运动范围感知相似连接框架 IS-Join。该框架通过引入对象在时间区间内的潜在运动区域，而非仅依赖离散的轨迹点，有效刻画了对象之间连续且不确定的时空交互关系，从而弥补了传统基于点匹配方法在表达能力上的不足。

经调研，现有轨迹相似性连接研究在相似性度量设计与索引优化方面取得了显著进展，并逐步将相似性语义从单纯的位置邻近扩展至时间融合、符号抽象以及局部匹配等更复杂形式。然而，这些方法仍主要基于离散采样点序列或轨迹片段进行建模，其相似性判定通常依赖于同步时间点距离、序列匹配或片段重叠。

与之不同，本文关注的是在连续时间语义下基于“运动范围”的区域交集相似性连接问题。IS-Join 不再直接比较采样点或轨迹片段之间的距离，而是评估对象在给定时间区间内潜在可达区域之间的交集程度。这一建模方式能够在稀疏采样或存在观测不确定性的条件下更准确地识别潜在交互关系。因此，现有轨迹相似性连接算法无法直接适用于 IS-Join，需要构建新的索引组织与剪枝机制以支持连续时间区域交集计算。不同于现有轨迹相似连接方法侧重于点序列之间的距离度量，IS-Join 以运动范围之间的交集相似度为核心建模对象，使查询语义更加直观且具有更强的鲁棒性，能够自然地支持多种时空分析需求，适用于交通监控、野生动物追踪、公共安全分析以及接触追踪等典型应用场景。

围绕 IS-Join 查询的高效处理问题，本文系统分析了其计算挑战，包括候选对象规模庞大、时间区间对齐要求严格以及交集判定代价较高等难点。为此，我们设计了一种融合重划分策略的 HBall-tree 索引结构，通过对运动范围进行层次化组织与动态重划分，有效缓解数据分布不均带来的性能瓶颈。同时，我们提出了预检查与多层剪枝机制，在索引遍历阶段提前过滤大量不可能相交的对象对，从而显著降低精确计算阶段的开销，提高整体查询效率与可扩展性。

最后，基于两个真实世界数据集开展了系统而全面的实验评估。实验结果表明，在不同数据规模与参数设置下，所提出的方法均表现出稳定且优越的性能表现；与精心设计的基线方法相比，在典型场景下最高可获得约 3 倍的加速效果，验证了所提框架与索引结构在理论设计与工程实现层面的有效性与实用价值。

致 谢

本论文的完成，凝聚了诸多师长、亲友和同窗的关心与帮助。值此论文付梓之际，谨向所有给予我支持与帮助的人致以最诚挚的感谢。

本研究及学位论文是在我的导师商烁教授的亲切关怀和悉心指导下完成的。商老师严谨求实的治学态度、敏锐深刻的学术洞察力以及精益求精的科研精神，始终激励着我不断进步。在论文选题、研究思路构建、关键技术突破以及论文整体结构把握等方面，商老师都给予了我耐心细致的指导。每一次讨论都让我受益匪浅，使我在学术视野与研究能力上不断提升。老师不仅在科研上给予我悉心培养，也在思想和生活上给予我关怀与支持，使我在攻读博士学位的过程中始终保持坚定与从容。在此谨向商烁教授致以最诚挚的谢意和崇高的敬意。

衷心感谢我的副导师陈力思教授。陈老师在科研方法、论文写作以及学术表达方面给予了我重要指导。在论文撰写与修改过程中，陈老师多次提出宝贵意见，从整体框架到细节表述均给予认真审阅与精心修改，使论文更加严谨和完善。每当科研工作遇到困难时，陈老师都耐心分析问题、指引方向，使我能够理清思路、稳步推进研究工作。在此谨向陈力思教授表示衷心的感谢与敬意。

感谢学院与实验室为我提供良好的科研环境与学术氛围。浓厚的学术交流氛围和开放包容的研究环境，使我能够专注于学术探索，不断拓展研究视野。感谢实验室的各位老师们在学术讨论中的启发与帮助，感谢师兄师姐、师弟师妹以及同窗好友在学习与生活中的支持与陪伴。与大家并肩奋斗的时光，是我博士生涯中最宝贵的记忆之一。

同时，感谢论文中所引用文献的作者们，他们严谨而卓越的研究成果为本论文奠定了重要的理论基础，使我得以在前人工作的基础上不断探索与创新。

最后，我要特别感谢我的父母和家人。无论在顺境还是逆境，你们始终给予我理解、包容与坚定的支持，是我坚持学术道路最坚实的后盾。你们无私的付出与默默的守护，使我能够心无旁骛地完成学业。未来我将以更加努力的工作与生活来回报你们的关爱与期望。

谨以此文，向所有关心、帮助和支持过我的师长、亲友和同学们致以最诚挚的感谢！

参考文献

- [1] Chen L, Shang S, Yang C, et al. Spatial keyword search: a survey[J]. *GeoInformatica*, 2020, 24(1): 85–106.
- [2] Shang S, Chen L, Wei Z, et al. Parallel trajectory similarity joins in spatial networks[J]. *VLDB J.*, 2018, 27(3): 395–420.
- [3] Zeng Y, Chen X, Cao X, et al. Optimal route search with the coverage of users' preferences[C]. *IJCAI, AAAI Press*, 2015: 2118–2124.
- [4] Cao X, Chen L, Cong G, et al. Keyword-aware optimal route search[J]. *Proc. VLDB Endow.*, 2012, 5(11): 1136–1147.
- [5] Wang S, Bao Z, Culpepper J S, et al. A survey on trajectory data management, analytics, and learning[J]. *ACM Comput. Surv.*, 2021, 54(2): 39:1–39:36.
- [6] Mazimpaka J D, Timpf S. Trajectory data mining: A review of methods and applications[J]. *J. Spatial Inf. Sci.*, 2016, 13(1): 61–99.
- [7] Su H, Liu S, Zheng B, et al. A survey of trajectory distance measures and performance evaluation[J]. *VLDB J.*, 2020, 29(1): 3–32.
- [8] Mahmood A R, Punni S, Aref W G. Spatio-temporal access methods: a survey (2010 - 2017)[J]. *GeoInformatica*, 2019, 23(1): 1–36.
- [9] Mahmood A R, Aref W G. Scalable Processing of Spatial-Keyword Queries[M]. *Synthesis Lectures on Data Management*. Morgan & Claypool Publishers, 2019.
- [10] Cao X, Chen L, Cong G, et al. Spatial keyword querying[C]. *Conceptual Modeling*, Springer, 2012: 16–29.
- [11] Chen L, Cong G, Jensen C S, et al. Spatial keyword query processing: An experimental evaluation[J]. *Proc. VLDB Endow.*, 2013, 6(3): 217–228.
- [12] Chen Z, Chen L, Cong G, et al. Location-and keyword-based querying of geo-textual data: a survey[J]. *The VLDB Journal*, 2021: 1–38.
- [13] Liang H, Wang K. Top-k route search through submodularity modeling of recurrent POI features[C]. *SIGIR, ACM*, 2018: 545–554.
- [14] Pedersen S A, Yang B, Jensen C S. Fast stochastic routing under time-varying uncertainty[J]. *VLDB J.*, 2020, 29(4): 819–839.
- [15] Pedersen S A, Yang B, Jensen C S. Anytime stochastic routing with hybrid learning[J]. *Proc. VLDB Endow.*, 2020, 13(9): 1555–1567.

-
- [16] Guo C, Yang B, Hu J, et al. Context-aware, preference-based vehicle routing[J]. VLDB J., 2020, 29(5): 1149–1170.
 - [17] Yang C, Chen L, Wang H, et al. Towards efficient selection of activity trajectories based on diversity and coverage[C]. AAAI, AAAI Press, 2021: 689–696.
 - [18] Xu J, Guo L, Ding Z, et al. Traffic aware route planning in dynamic road networks[C]. DASFAA (1), Springer, vol. 7238 of Lecture Notes in Computer Science, 2012: 576–591.
 - [19] Wilkie D, van den Berg J P, Lin M C, et al. Self-aware traffic route planning[C]. Proceedings of the Twenty-Fifth AAAI Conference on Artificial Intelligence, AAAI 2011, San Francisco, California, USA, August 7-11, 2011, AAAI Press.
 - [20] Li K, Chen L, Shang S. Towards alleviating traffic congestion: Optimal route planning for massive-scale trips[C]. IJCAI, ijcai.org, 2020: 3400–3406.
 - [21] Wilkie D, Baykal C, Lin M C. Participatory route planning[C]. SIGSPATIAL/GIS, ACM, 2014: 213–222.
 - [22] Ding B, Yu J X, Qin L. Finding time-dependent shortest paths over large graphs[C]. EDBT, ACM, vol. 261 of ACM International Conference Proceeding Series, 2008: 205–216.
 - [23] Cai X, Kloks T, Wong C K. Time-varying shortest path problems with constraints[J]. Networks, 1997, 29(3): 141–150.
 - [24] Kanoulas E, Du Y, Xia T, et al. Finding fastest paths on A road network with speed patterns[C]. ICDE, IEEE Computer Society, 2006: 10.
 - [25] Narváez P, Siu K, Tzeng H. New dynamic SPT algorithm based on a ball-and-string model[J]. IEEE/ACM Trans. Netw., 2001, 9(6): 706–718.
 - [26] Wang Y, Li G, Tang N. Querying shortest paths on time dependent road networks[J]. Proc. VLDB Endow., 2019, 12(11): 1249–1261.
 - [27] Shang S, Liu J, Zheng K, et al. Planning unobstructed paths in traffic-aware spatial networks[J]. GeoInformatica, 2015, 19(4): 723–746.
 - [28] Shang S, Guo D, Liu J, et al. Prediction-based unobstructed route planning[J]. Neurocomputing, 2016, 213: 147–154.
 - [29] Ranu S, P D, Telang A D, et al. Indexing and matching trajectories under inconsistent sampling rates[C]. ICDE, IEEE Computer Society, 2015: 999–1010.
 - [30] Su H, Zheng K, Wang H, et al. Calibrating trajectory data for similarity-based analysis[C]. SIGMOD, ACM, 2013: 833–844.
 - [31] Brakatsoulas S, Pfoser D, Salas R, et al. On map-matching vehicle tracking data[C]. Proceedings of the 31st International Conference on Very Large Data Bases, ACM, 2005: 853–864.

- [32] Ge Y, Xiong H, Tuzhilin A, et al. An energy-efficient mobile recommender system[C]. Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Washington, DC, USA, July 25-28, 2010, ACM, 2010: 899–908.
- [33] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[C]. ICDE, IEEE Computer Society, 2017: 59–60.
- [34] Li F, Cheng D, Hadjieleftheriou M, et al. On trip planning queries in spatial databases[C]. SSTD, Springer, vol. 3633 of Lecture Notes in Computer Science, 2005: 273–290.
- [35] Sharifzadeh M, Kolahdouzan M R, Shahabi C. The optimal sequenced route query[J]. VLDB J., 2008, 17(4): 765–787.
- [36] Mamoulis N, Cao H, Kollios G, et al. Mining, indexing, and querying historical spatiotemporal data[C]. KDD, ACM, 2004: 236–245.
- [37] Giannotti F, Nanni M, Pinelli F, et al. Trajectory pattern mining[C]. KDD, ACM, 2007: 330–339.
- [38] Gonzalez H, Han J, Li X, et al. Adaptive fastest path computation on a road network: A traffic mining approach[C]. VLDB, ACM, 2007: 794–805.
- [39] Zheng Y, Zhang L, Xie X, et al. Mining interesting locations and travel sequences from GPS trajectories[C]. WWW, 2009: 791–800.
- [40] Zheng B, Yuan N J, Zheng K, et al. Approximate keyword search in semantic trajectory database[C]. ICDE, IEEE Computer Society, 2015: 975–986.
- [41] Dai J, Yang B, Guo C, et al. Personalized route recommendation using big trajectory data[C]. ICDE, IEEE Computer Society, 2015: 543–554.
- [42] Agrawal R, Faloutsos C, Swami A N. Efficient similarity search in sequence databases[C]. FODO, Springer, vol. 730 of Lecture Notes in Computer Science, 1993: 69–84.
- [43] Yi B, Jagadish H V, Faloutsos C. Efficient retrieval of similar time sequences under time warping[C]. Proceedings of the Fourteenth International Conference on Data Engineering, Orlando, Florida, USA, February 23-27, 1998, IEEE Computer Society, 1998: 201–208.
- [44] Vlachos M, Gunopulos D, Kollios G. Discovering similar multidimensional trajectories[C]. Proceedings of the 18th International Conference on Data Engineering, San Jose, CA, USA, February 26 - March 1, 2002, IEEE Computer Society, 2002: 673–684.
- [45] Chen L, Ng R T. On the marriage of lp-norms and edit distance[C]. (e)Proceedings of the Thirtieth International Conference on Very Large Data Bases, VLDB 2004, Toronto, Canada, August 31 - September 3 2004, Morgan Kaufmann, 2004: 792–803.

-
- [46] Chen L, Özsu M T, Oria V. Robust and fast similarity search for moving object trajectories[C]. Proceedings of the ACM SIGMOD International Conference on Management of Data, Baltimore, Maryland, USA, June 14-16, 2005, ACM, 2005: 491–502.
- [47] Perng C, Wang H, Zhang S R, et al. Landmarks: a new model for similarity-based pattern querying in time series databases[C]. Proceedings of the 16th International Conference on Data Engineering, San Diego, California, USA, February 28 - March 3, 2000, IEEE Computer Society, 2000: 33–42.
- [48] Chen Y, Nascimento M A, Ooi B C, et al. Spade: On shape-based pattern detection in streaming time series[C]. Chirkova R, Dogac A, Özsu M T, et al., (Eds.) Proceedings of the 23rd International Conference on Data Engineering, ICDE 2007, The Marmara Hotel, Istanbul, Turkey, April 15-20, 2007, IEEE Computer Society, 2007: 786–795.
- [49] Li X, Zhao K, Cong G, et al. Deep representation learning for trajectory similarity computation[C]. ICDE, IEEE Computer Society, 2018: 617–628.
- [50] Yao D, Cong G, Zhang C, et al. Computing trajectory similarity in linear time: A generic seed-guided neural metric learning approach[C]. ICDE, IEEE, 2019: 1358–1369.
- [51] Dijkstra E W. A note on two problems in connexion with graphs[J]. *Numerische Mathematik*, 1959, 1: 269–271.
- [52] Likhachev M, Ferguson D I, Gordon G J, et al. Anytime dynamic a*: An anytime, replanning algorithm[C]. ICAPS, AAAI, 2005: 262–271.
- [53] Malviya N, Madden S, Bhattacharya A. A continuous query system for dynamic route planning[C]. ICDE, IEEE Computer Society, 2011: 792–803.
- [54] Yang B, Guo C, Ma Y, et al. Toward personalized, context-aware routing[J]. *VLDB J.*, 2015, 24(2): 297–318.
- [55] Letchner J, Krumm J, Horvitz E. Trip router with individualized preferences (TRIP): incorporating personalization into route planning[C]. AAAI, AAAI Press, 2006: 1795–1800.
- [56] Balteanu A, Jossé G, Schubert M. Mining driving preferences in multi-cost networks[C]. *SSTD*, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 74–91.
- [57] Deng K, Zhou X, Shen H T. Multi-source skyline query processing in road networks[C]. ICDE, IEEE Computer Society, 2007: 796–805.
- [58] Kriegel H, Renz M, Schubert M. Route skyline queries: A multi-preference path planning approach[C]. ICDE, IEEE Computer Society, 2010: 261–272.
- [59] Lim S, Balakrishnan H, Gifford D, et al. Stochastic motion planning and applications to traffic[J]. *Int. J. Robotics Res.*, 2011, 30(6): 699–712.

- [60] Yang B, Guo C, Jensen C S, et al. Stochastic skyline route planning under time-varying uncertainty[C]. ICDE, IEEE Computer Society, 2014: 136–147.
- [61] Hua M, Pei J. Probabilistic path queries in road networks: traffic uncertainty aware path selection[C]. EDBT, ACM, vol. 426 of ACM International Conference Proceeding Series, 2010: 347–358.
- [62] Huang J, Huangfu X, Sun H, et al. Backward path growth for efficient mobile sequential recommendation[J]. IEEE Trans. Knowl. Data Eng., 2015, 27(1): 46–60.
- [63] Ye Z, Xiao K, Deng Y. A unified theory of the mobile sequential recommendation problem[C]. IEEE International Conference on Data Mining, ICDM 2018, Singapore, November 17-20, 2018, IEEE Computer Society, 2018: 1380–1385.
- [64] Ye Z, Xiao K, Ge Y, et al. Applying simulated annealing and parallel computing to the mobile sequential recommendation[J]. IEEE Trans. Knowl. Data Eng., 2019, 31(2): 243–256.
- [65] Ye Z, Zhang L, Xiao K, et al. Multi-user mobile sequential recommendation: An efficient parallel computing paradigm[C]. Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD 2018, London, UK, August 19-23, 2018, ACM, 2018: 2624–2633.
- [66] Chen Z, Shen H T, Zhou X, et al. Searching trajectories by locations: an efficiency study[C]. SIGMOD Conference, ACM, 2010: 255–266.
- [67] Zheng K, Shang S, Yuan N J, et al. Towards efficient search for activity trajectories[C]. Jensen C S, Jermaine C M, Zhou X, (Eds.) 29th IEEE International Conference on Data Engineering, ICDE 2013, Brisbane, Australia, April 8-12, 2013, IEEE Computer Society, 2013: 230–241.
- [68] Shang S, Lu H, Pedersen T B, et al. Finding traffic-aware fastest paths in spatial networks[C]. SSTD, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 128–145.
- [69] Chen L, Shang S, Jensen C S, et al. Effective and efficient reuse of past travel behavior for route recommendation[C]. KDD, ACM, 2019: 488–498.
- [70] Chen L, Shang S, Guo T. Real-time route search by locations[C]. AAAI, AAAI Press, 2020: 574–581.
- [71] Li R, Qin L, Yu J X, et al. Optimal multi-meeting-point route search[J]. IEEE Trans. Knowl. Data Eng., 2016, 28(3): 770–784.
- [72] Reza R M, Ali M E, Cheema M A. The optimal route and stops for a group of users in a road network[C]. Proceedings of the 25th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, GIS 2017, Redondo Beach, CA, USA, November 7-10, 2017, ACM, 2017: 4:1–4:10.

- [73] Hashem T, Hashem T, Ali M E, et al. Group trip planning queries in spatial databases[C]. *Advances in Spatial and Temporal Databases - 13th International Symposium, SSTD 2013, Munich, Germany, August 21-23, 2013. Proceedings*, Springer, vol. 8098 of *Lecture Notes in Computer Science*, 2013: 259–276.
- [74] Hashem T, Barua S, Ali M E, et al. Efficient computation of trips with friends and families[C]. *Proceedings of the 24th ACM International Conference on Information and Knowledge Management, CIKM 2015, Melbourne, VIC, Australia, October 19 - 23, 2015*, ACM, 2015: 931–940.
- [75] Lim S, Rus D. Stochastic distributed multi-agent planning and applications to traffic[C]. *ICRA*, IEEE, 2012: 2873–2879.
- [76] Zeng Y, Tong Y, Song Y, et al. The simpler the better: An indexing approach for shared-route planning queries[J]. *Proc. VLDB Endow.*, 2020, 13(13): 3517–3530.
- [77] Zheng L, Chen L, Ye J. Order dispatch in price-aware ridesharing[J]. *Proc. VLDB Endow.*, 2018, 11(8): 853–865.
- [78] Yao B, Tang M, Li F. Multi-approximate-keyword routing in GIS data[C]. *GIS*, ACM, 2011: 201–210.
- [79] Zheng B, Su H, Hua W, et al. Efficient clue-based route search on road networks[J]. *IEEE Trans. Knowl. Data Eng.*, 2017, 29(9): 1846–1859.
- [80] Wen Y T, Yeo J, Peng W, et al. Efficient keyword-aware representative travel route recommendation[J]. *IEEE Trans. Knowl. Data Eng.*, 2017, 29(8): 1639–1652.
- [81] Li W, Cao J, Guan J, et al. Efficient retrieval of bounded-cost informative routes[C]. *ICDE*, IEEE Computer Society, 2018: 1811–1812.
- [82] Jossé G, Schmid K A, Schubert M. Probabilistic resource route queries with reappearance[C]. *Proceedings of the 18th International Conference on Extending Database Technology, EDBT 2015, Brussels, Belgium, March 23-27, 2015*, OpenProceedings.org, 2015: 445–456.
- [83] Christofides N. Worst-case analysis of a new heuristic for the traveling salesman problem[J]. 1976.
- [84] Zhang C, Liang H, Wang K, et al. Personalized trip recommendation with POI availability and uncertain traveling time[C]. *Proceedings of the 24th ACM International Conference on Information and Knowledge Management, CIKM 2015, Melbourne, VIC, Australia, October 19 - 23, 2015*, ACM, 2015: 911–920.
- [85] Yawalkar P, Ranu S. Route recommendations on road networks for arbitrary user preference functions[C]. *ICDE*, IEEE, 2019: 602–613.

- [86] Ma X, Shekhar S, Xiong H, et al. Exploiting a page-level upper bound for multi-type nearest neighbor queries[C]. GIS, ACM, 2006: 179–186.
- [87] Chen H, Ku W, Sun M, et al. The multi-rule partial sequenced route query[C]. GIS, ACM, 2008: 10.
- [88] Chen H, Ku W, Sun M, et al. The partial sequenced route query with traveling rules in road networks[J]. GeoInformatica, 2011, 15(3): 541–569.
- [89] Li J, Yang Y D, Mamoulis N. Optimal route queries with arbitrary order constraints[J]. IEEE Trans. Knowl. Data Eng., 2013, 25(5): 1097–1110.
- [90] Sharifzadeh M, Shahabi C. Processing optimal sequenced route queries using voronoi diagrams[J]. GeoInformatica, 2008, 12(4): 411–433.
- [91] Li Y, Yang W, Dan W, et al. Keyword-aware dominant route search for various user preferences[C]. Database Systems for Advanced Applications - 20th International Conference, DAS-FAA 2015, Hanoi, Vietnam, April 20-23, 2015, Proceedings, Part II, Springer, vol. 9050 of Lecture Notes in Computer Science, 2015: 207–222.
- [92] Kanza Y, Safra E, Sagiv Y, et al. Heuristic algorithms for route-search queries over geographical data[C]. GIS, ACM, 2008: 11.
- [93] Lu E H, Lin C, Tseng V S. Trip-mine: An efficient trip planning approach with travel time constraints[C]. Mobile Data Management (1), IEEE Computer Society, 2011: 152–161.
- [94] Kanza Y, Levin R, Safra E, et al. An interactive approach to route search[C]. GIS, ACM, 2009: 408–411.
- [95] Levin R, Kanza Y, Safra E, et al. Interactive route search in the presence of order constraints[J]. Proc. VLDB Endow., 2010, 3(1): 117–128.
- [96] Roy S B, Das G, Amer-Yahia S, et al. Interactive itinerary planning[C]. ICDE, IEEE Computer Society, 2011: 15–26.
- [97] Fan L, Bonomi L, Shahabi C, et al. Multi-user itinerary planning for optimal group preference[C]. Advances in Spatial and Temporal Databases - 15th International Symposium, SSTD 2017, Arlington, VA, USA, August 21-23, 2017, Proceedings, Springer, vol. 10411 of Lecture Notes in Computer Science, 2017: 3–23.
- [98] Fan L, Bonomi L, Shahabi C, et al. Optimal group route query: Finding itinerary for group of users in spatial databases[J]. GeoInformatica, 2018, 22(4): 845–867.
- [99] Levin R, Kanza Y. TARS: traffic-aware route search[J]. GeoInformatica, 2014, 18(3): 461–500.
- [100] Salgado C, Cheema M A, Taniar D. An efficient approximation algorithm for multi-criteria indoor route planning queries[C]. SIGSPATIAL/GIS, ACM, 2018: 448–451.

-
- [101] Feng Z, Liu T, Li H, et al. Indoor top-k keyword-aware routing query[C]. ICDE, IEEE, 2020: 1213–1224.
- [102] Dumitrescu I, Boland N. Improved preprocessing, labeling and scaling algorithms for the weight-constrained shortest path problem[J]. Networks, 2003, 42(3): 135–153.
- [103] Shang S, Lu H, Pedersen T B, et al. Modeling of traffic-aware travel time in spatial networks[C]. MDM (1), IEEE Computer Society, 2013: 247–250.
- [104] Xu Y, Chen L, Yao B, et al. Location-based top-k term querying over sliding window[C]. WISE (1), Springer, vol. 10569 of Lecture Notes in Computer Science, 2017: 299–314.
- [105] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[J]. TKDE, 2016, 28(5): 1132–1146.
- [106] Guo C, Yang B, Hu J, et al. Learning to route with sparse trajectory sets[C]. 34th IEEE International Conference on Data Engineering, ICDE 2018, Paris, France, April 16-19, 2018, IEEE Computer Society, 2018: 1073–1084.
- [107] Chen L, Shang S, Yao B, et al. Pay your trip for traffic congestion: Dynamic pricing in traffic-aware road networks[C]. AAAI, AAAI Press, 2020: 582–589.
- [108] Shang S, Ding R, Zheng K, et al. Personalized trajectory matching in spatial networks[J]. VLDB J., 2014, 23(3): 449–468.
- [109] Liebig T, Piatkowski N, Bockermann C, et al. Dynamic route planning with real-time traffic predictions[J]. Inf. Syst., 2017, 64: 258–265.
- [110] Dafermos, C S. The traffic assignment problem for multiclass-user transportation networks[J]. Transportation Science, 1972, 6(1): 73-87.
- [111] Lim S, Rus D. Stochastic distributed multi-agent planning and applications to traffic[J]. ICRA, 2012: 2873-2879.
- [112] Babak J, Abbas B, (Avi) C A. Path-based capacity-restrained dynamic traffic assignment algorithm[J]. Transportmetrica B: Transport Dynamics, 2018: 1-24.
- [113] Dijkstra E W. A note on two problems in connexion with graphs[J]. Numerische Mathematik, 1959, 1: 269-271.
- [114] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. GIS, ACM, 2009: 286–295.
- [115] Tanaka P S, Vieira M R, Kaster D S. An improved base algorithm for online discovery of flock patterns in trajectories[J]. J. Inf. Data Manag., 2016, 7(1): 52–67.
- [116] Jeung H, Yiu M L, Zhou X, et al. Discovery of convoys in trajectory databases[J]. Proc. VLDB Endow., 2008, 1(1): 1068–1080.

- [117] Li Z, Ding B, Han J, et al. Swarm: Mining relaxed temporal moving object clusters[J]. *Proc. VLDB Endow.*, 2010, 3(1): 723–734.
- [118] Wang Y, Lim E, Hwang S. Efficient mining of group patterns from user movement data[J]. *Data Knowl. Eng.*, 2006, 57(3): 240–282.
- [119] Li Y, Bailey J, Kulik L. Efficient mining of platoon patterns in trajectory databases[J]. *Data Knowl. Eng.*, 2015, 100: 167–187.
- [120] Zheng K, Zheng Y, Yuan N J, et al. On discovery of gathering patterns from trajectories[C]. *ICDE, IEEE Computer Society*, 2013: 242–253.
- [121] Zheng K, Zheng Y, Yuan N J, et al. Online discovery of gathering patterns over trajectories[J]. *TKDE*, 2014, 26(8): 1974–1988.
- [122] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying ”infected” moving objects[J]. *Proc. VLDB Endow.*, 2020, 13(12): 2825–2828.
- [123] Alarabi L, Basalamah S M, Hendawi A M, et al. Traceall: A real-time processing for contact tracing using indoor trajectories[J]. *Inf.*, 2021, 12(5): 202.
- [124] Liu Y, Zhao K, Cong G, et al. Online anomalous trajectory detection with deep generative sequence modeling[C]. *ICDE, IEEE*, 2020: 949–960.
- [125] Li K, Chen L, Shang S, et al. Towards controlling the transmission of diseases: Continuous exposure discovery over massive-scale moving objects[C]. *IJCAI*, 2022: 3891–3897.
- [126] Chen Z, Li K, Zhou S, et al. Towards robust trajectory similarity computation: Representation-based spatio-temporal similarity quantification[J]. *World Wide Web*, 2022: 1–24.
- [127] Zheng B, Xu J, Lee W C, et al. Grid-partition index: a hybrid method for nearest-neighbor queries in wireless location-based services[J]. *The VLDB Journal*, 2006, 15(1): 21–39.
- [128] Xu X, Yuruk N, Feng Z, et al. SCAN: a structural clustering algorithm for networks[C]. *SIGKDD, ACM*, 2007: 824–833.
- [129] Han P, Wang J, Yao D, et al. A graph-based approach for trajectory similarity computation in spatial networks[C]. *KDD, ACM*, 2021: 556–564.
- [130] Chen L, Shang S, Feng S, et al. Parallel subtrajectory alignment over massive-scale trajectory data[C]. Zhou Z, (Ed.) *IJCAI, ijcai.org*, 2021: 3613–3619.
- [131] Shang S, Zheng K, Jensen C S, et al. Discovery of path nearby clusters in spatial networks[J]. *TKDE*, 2015, 27(6): 1505–1518.
- [132] Shang S, Chen L, Jensen C S, et al. Searching trajectories by regions of interest[J]. *TKDE*, 2017, 29(7): 1549–1562.
- [133] Shang S, Chen L, Wei Z, et al. Trajectory similarity join in spatial networks[J]. *Proc. VLDB Endow.*, 2017, 10(11): 1178–1189.

-
- [134] Chen L, Shang S, Jensen C S, et al. Parallel semantic trajectory similarity join[C]. ICDE, IEEE, 2020: 997–1008.
- [135] Zhao Y, Shang S, Wang Y, et al. REST: A reference-based framework for spatio-temporal trajectory compression[C]. Guo Y, Farooq F, (Eds.) SIGMOD, ACM, 2018: 2797–2806.
- [136] Liu J, Zhao K, Sommer P, et al. A novel framework for online amnesic trajectory compression in resource-constrained environments[J]. IEEE Trans. Knowl. Data Eng., 2016, 28(11): 2827–2841.
- [137] Liu J, Zhao K, Sommer P, et al. Bounded quadrant system: Error-bounded trajectory compression on the go[C]. Gehrke J, Lehner W, Shim K, et al., (Eds.) ICDE, IEEE Computer Society, 2015: 987–998.
- [138] Shang S, Yuan B, Deng K, et al. PNN query processing on compressed trajectories[J]. GeoInformatica, 2012, 16(3): 467–496.
- [139] Yao B, Chen Z, Gao X, et al. Flexible aggregate nearest neighbor queries in road networks[C]. ICDE, IEEE Computer Society, 2018: 761–772.
- [140] Han P, Li Z, Liu Y, et al. Contextualized point-of-interest recommendation[C]. Bessiere C, (Ed.) IJCAI, ijcai.org, 2020: 2484–2490.
- [141] Han P, Shang S, Sun A, et al. AUC-MF: point of interest recommendation with AUC maximization[C]. ICDE, IEEE, 2019: 1558–1561.
- [142] Shang S, Chen L, Zheng K, et al. Parallel trajectory-to-location join[J]. TKDE, 2019, 31(6): 1194–1207.
- [143] Feng S, Tran L V, Cong G, et al. HME: A hyperbolic metric embedding approach for next-poi recommendation[C]. SIGIR, ACM, 2020: 1429–1438.
- [144] Rao X, Chen L, Liu Y, et al. Graph-flashback network for next location recommendation[C]. KDD, ACM, 2022: 1463–1471.
- [145] Guo D, Zhu Y, Xu W, et al. How to find appropriate automobile exhibition halls: Towards a personalized recommendation service for auto show[J]. Neurocomputing, 2016, 213: 95–101.
- [146] Li K, Chen L, Shang S, et al. Traffic congestion alleviation over dynamic road networks: Continuous optimal route combination for trip query streams[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3656–3662.
- [147] Shang S, Ding R, Yuan B, et al. User oriented trajectory search for trip recommendation[C]. 15th International Conference on Extending Database Technology, EDBT '12, Berlin, Germany, March 27–30, 2012, Proceedings, ACM, 2012: 156–167.
- [148] Liu K, Li Y, Ding Z, et al. Benchmarking big data for trip recommendation[C]. ICCCN, IEEE, 2014: 1–6.

- [149] Rao X, Wang H, Zhang L, et al. FOGS: first-order gradient supervision with learning-based graph for traffic flow forecasting[C]. Raedt L D, (Ed.) IJCAI, ijcai.org, 2022: 3926–3932.
- [150] Liu A, Wang W, Shang S, et al. Efficient task assignment in spatial crowdsourcing with worker and task privacy protection[J]. *GeoInformatica*, 2018, 22(2): 335–362.
- [151] Fan Q, Zhang D, Wu H, et al. A general and parallel platform for mining co-movement patterns over large-scale trajectories[J]. *Proc. VLDB Endow.*, 2016, 10(4): 313–324.
- [152] Naserian E, Wang X, Xu X, et al. Discovery of loose travelling companion patterns from human trajectories[C]. *HPCC, IEEE Computer Society*, 2016: 1238–1245.
- [153] Shein T T, Puntheeranurak S, Imamura M. Discovery of loose group companion from trajectory data streams[J]. *IEEE Access*, 2020, 8: 85856–85868.
- [154] Fang Z, Gao Y, Pan L, et al. Coming: A real-time co-movement mining system for streaming trajectories[C]. Maier D, Pottinger R, Doan A, et al., (Eds.) *SIGMOD, ACM*, 2020: 2777–2780.
- [155] Chen L, Gao Y, Fang Z, et al. Real-time distributed co-movement pattern detection on streaming trajectories[J]. *Proc. VLDB Endow.*, 2019, 12(10): 1208–1220.
- [156] Zhao Y, Chen Q, Cao W, et al. Deep learning for risk detection and trajectory tracking at construction sites[J]. *IEEE Access*, 2019, 7: 30905–30912.
- [157] Zhang Y, Liu A, Liu G, et al. Deep representation learning of activity trajectory similarity computation[C]. *ICWS, IEEE*, 2019: 312–319.
- [158] Yao D, Zhang C, Zhu Z, et al. Trajectory clustering via deep representation learning[C]. *IJCNN, IEEE*, 2017: 3880–3887.
- [159] Boyle J, Nawaz T, Ferryman J M. Deep trajectory representation-based clustering for motion pattern extraction in videos[C]. *AVSS, IEEE Computer Society*, 2017: 1–6.
- [160] Fang Z, Du Y, Chen L, et al. E²dtc: An end to end deep trajectory clustering framework via self-training[C]. *ICDE, IEEE*, 2021: 696–707.
- [161] Li M, Chen L, Cong G, et al. Efficient processing of location-aware group preference queries[C]. *CIKM, ACM*, 2016: 559–568.
- [162] Shang S, Guo D, Liu J, et al. Finding regions of interest using location based social media[J]. *Neurocomputing*, 2016, 173: 118–123.
- [163] Chen L, Shang S. Approximate spatio-temporal top-k publish/subscribe[J]. *World Wide Web*, 2019, 22(5): 2153–2175.
- [164] Chen L, Shang S, Jensen C S, et al. Top-k term publish/subscribe for geo-textual data streams[J]. *VLDB J.*, 2020, 29(5): 1101–1128.
- [165] Zhao K, Chen L, Cong G. Topic exploration in spatio-temporal document collections[C]. *SIGMOD, ACM*, 2016: 985–998.

- [166] Chen L, Shang S. Region-based message exploration over spatio-temporal data streams[C]. AAAI, AAAI Press, 2019: 873–880.
- [167] Chen L, Shang S, Zheng K, et al. Cluster-based subscription matching for geo-textual data streams[C]. ICDE, IEEE, 2019: 890–901.
- [168] Li X, Cheng Y, Cong G, et al. Discovering pollution sources and propagation patterns in urban area[C]. KDD, ACM, 2017: 1863–1872.
- [169] Han J, Zheng K, Sun A, et al. Discovering neighborhood pattern queries by sample answers in knowledge base[C]. ICDE, IEEE Computer Society, 2016: 1014–1025.
- [170] Pelekis N, Kopanakis I, Kotsifakos E E, et al. Clustering trajectories of moving objects in an uncertain world[C]. ICDM, IEEE Computer Society, 2009: 417–427.
- [171] Lee J, Han J, Whang K. Trajectory clustering: a partition-and-group framework[C]. SIGKDD, ACM, 2007: 593–604.
- [172] Li Z, Lee J, Li X, et al. Incremental clustering for trajectories[C]. DASFAA, Springer, vol. 5982 of Lecture Notes in Computer Science, 2010: 32–46.
- [173] Li H, Liu J, Wu K, et al. Spatio-temporal vessel trajectory clustering based on data mapping and density[J]. IEEE Access, 2018, 6: 58939–58954.
- [174] Yuan J, Zheng Y, Xie X, et al. Driving with knowledge from the physical world[C]. Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, ACM, 2011: 316–324.
- [175] Yuan J, Zheng Y, Zhang C, et al. T-drive: driving directions based on taxi trajectories[C]. ACM-GIS, ACM, 2010: 99–108.
- [176] Guttman A. R-trees: A dynamic index structure for spatial searching[C]. SIGMOD, 1984: 47–57.
- [177] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying ”infected” moving objects[J]. Proc. VLDB Endow., 2020, 13(12): 2825–2828.
- [178] Chao P, He D, Li L, et al. Efficient trajectory contact query processing[C]. DASFAA, 2021: 658–666.
- [179] Xiong L, Shahabi C, Da Y, et al. REACT: real-time contact tracing and risk monitoring using privacy-enhanced mobile tracking[J]. ACM SIGSPATIAL Special, 2020, 12(2): 3–14.
- [180] Faloutsos C, Ranganathan M, Manolopoulos Y. Fast subsequence matching in time-series databases[C]. Proceedings of the 1994 ACM SIGMOD International Conference on Management of Data, ACM Press, 1994: 419–429.
- [181] Assent I, Wichterich M, Krieger R, et al. Anticipatory DTW for efficient similarity search in time series databases[J]. Proc. VLDB Endow., 2009, 2(1): 826–837.

- [182] Rong C, Lin C, Silva Y N, et al. Fast and scalable distributed set similarity joins for big data analytics[C]. 33rd IEEE International Conference on Data Engineering, ICDE 2017, IEEE Computer Society, 2017: 1059–1070.
- [183] Xie D, Li F, Phillips J M. Distributed trajectory similarity search[J]. Proc. VLDB Endow., 2017, 10(11): 1478–1489.
- [184] He H, Li R, Wang R, et al. Efficient suspected infected crowds detection based on spatio-temporal trajectories[J]. CoRR, 2020, abs/2004.06653. 2004.06653.
- [185] Ojagh S, Saeedi S, Liang S H L. A person-to-person and person-to-place COVID-19 contact tracing system based on OGC indoorgml[J]. ISPRS Int. J. Geo Inf., 2021, 10(1): 2.
- [186] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. 17th ACM SIGSPATIAL International Symposium on Advances in Geographic Information Systems, ACM-GIS 2009, ACM, 2009: 286–295.
- [187] Tang L, Zheng Y, Yuan J, et al. On discovery of traveling companions from streaming trajectories[C]. IEEE 28th International Conference on Data Engineering (ICDE 2012), IEEE Computer Society, 2012: 186–197.
- [188] Eusuf S S, Islam K A, Ali M E, et al. A web-based system for efficient contact tracing query in a large spatio-temporal database[C]. SIGSPATIAL '20: 28th International Conference on Advances in Geographic Information Systems, ACM, 2020: 473–476.
- [189] Taha A A, Hanbury A. An efficient algorithm for calculating the exact hausdorff distance[J]. IEEE Trans. Pattern Anal. Mach. Intell., 2015, 37(11): 2153–2163.
- [190] Ding Z, Li K, Chen L, et al. Parallel online similarity join over trajectory streams[C]. Proceedings of the ACM on Web Conference 2025, 2025: 3426–3437.
- [191] Kong X, Chen Q, Hou M, et al. Mobility trajectory generation: a survey[J]. Artif. Intell. Rev., 2023, 56(Supplement 3): 3057–3098.
- [192] Sistla A P, Wolfson O, Chamberlain S, et al. Modeling and querying moving objects[C]. ICDE, 1997: 422–432.
- [193] Patel J M, Chen Y, Chakka V P. STRIPES: an efficient index for predicted trajectories[C]. SIGMOD, 2004: 637–646.
- [194] Saltenis S, Jensen C S, Leutenegger S T, et al. Indexing the positions of continuously moving objects[C]. SIGMOD, 2000: 331–342.
- [195] Zhang R, Lin D, Ramamohanarao K, et al. Continuous intersection joins over moving objects[C]. ICDE, 2008: 863–872.
- [196] Zhang R, Qi J, Lin D, et al. A highly optimized algorithm for continuous intersection join queries over moving objects[J]. VLDB J., 2012, 21(4): 561–586.

- [197] Bakalov P, Hadjieleftheriou M, Keogh E J, et al. Efficient trajectory joins using symbolic representations[C]. Chrysanthos P K, Samaras G, (Eds.) MDM, ACM, 2005: 86–93.
- [198] Yi B, Faloutsos C. Fast time sequence indexing for arbitrary lp norms[C]. VLDB, Morgan Kaufmann, 2000: 385–394.
- [199] Vishnu C, Abhinav V, Roy D, et al. Improving multi-agent trajectory prediction using traffic states on interactive driving scenarios[J]. IEEE Robotics Autom. Lett., 2023, 8(5): 2708–2715.
- [200] Forrest S, Recio M, Seddon P. Moving wildlife tracking forward under forested conditions with the swift gps algorithm[J]. Animal Biotelemetry, 2022, 10(1): 19.
- [201] Li J, Ni C, He D, et al. Efficient knn query for moving objects on time-dependent road networks[J]. VLDB J., 2023, 32(3): 575–594.
- [202] Zheng Y, Xie X, Ma W. Geolife: A collaborative social networking service among user, location and trajectory[J]. IEEE Data Eng. Bull., 2010, 33(2): 32–39.
- [203] Brinkhoff T, Kriegel H, Seeger B. Efficient processing of spatial joins using r-trees[C]. SIGMOD, 1993: 237–246.
- [204] Bentley J L. Multidimensional binary search trees used for associative searching[J]. Commun. ACM, 1975, (9): 509–517.
- [205] Zhang M, Chen S, Jensen C S, et al. Effectively indexing uncertain moving objects for predictive queries[J]. Proc. VLDB Endow., 2009, 2(1): 1198–1209.
- [206] Ciaccia P, Patella M, Rabitti F, et al. Indexing metric spaces with m-tree[C]. SEBD, 1997: 67–86.
- [207] Ciaccia P, Patella M, Zezula P. M-tree: An efficient access method for similarity search in metric spaces[C]. VLDB, 1997: 426–435.
- [208] Liu T, Moore A W, Gray A G. New algorithms for efficient high-dimensional nonparametric classification[J]. J. Mach. Learn. Res., 2006, 7: 1135–1158.
- [209] Omohundro S M. Five balltree construction algorithms[M]. International Computer Science Institute Berkeley, 1989.
- [210] Dolatshah M, Hadian A, Minaei-Bidgoli B. Ball*-tree: Efficient spatial indexing for constrained nearest-neighbor search in metric spaces[J]. CoRR, 2015.
- [211] Zhang X, Ray S, Shoeleh F, et al. Efficient contact similarity query over uncertain trajectories[C]. EDBT, 2021: 403–408.
- [212] Liang A, Yao B, Wang B, et al. Sub-trajectory clustering with deep reinforcement learning[J]. VLDB J., 2024, 33(3): 685–702.
- [213] Li K, Wang H, Chen Z, et al. Relaxed group pattern detection over massive-scale trajectories[J]. Future Generation Computer Systems, 2023, 144: 131–139.

- [214] Nutanong S, Zhang R, Tanin E, et al. Analysis and evaluation of v^* -knn: an efficient algorithm for moving knn queries[J]. VLDB J., 2010, 19(3): 307–332.
- [215] Ward P G D, He Z, Zhang R, et al. Real-time continuous intersection joins over large sets of moving objects using graphic processing units[J]. VLDB J., 2014, 23(6): 965–985.
- [216] Chang Y, Tanin E, Cong G, et al. Trajectory similarity measurement: An efficiency perspective[J]. Proceedings of the VLDB Endowment, 2024, 17(9): 2293–2306.
- [217] Ding Y, Zhou X, Wu G, et al. Mining spatio-temporal reachable regions with multiple sources over massive trajectory data[J]. IEEE Trans. Knowl. Data Eng., 2021, 33(7): 2930–2942.
- [218] Chen Y, Patel J M. Design and evaluation of trajectory join algorithms[C]. 17th ACM SIGSPATIAL International Symposium on Advances in Geographic Information Systems, Washington, USA: ACM, 2009: 266–275.
- [219] Tampakakis P, Doukeridis C, Pelekis N, et al. Distributed subtrajectory join on massive datasets[J]. ACM Trans. Spatial Algorithms Syst., 2020, 6(2): 8:1–8:29.
- [220] Pfoser D, Jensen C S. Capturing the uncertainty of moving-object representations[C]. SSD, 1999: 111–132.
- [221] Trajcevski G, Choudhary A, Wolfson O, et al. Uncertain range queries for necklaces[C]. MDM, 2010: 199–208.
- [222] Moore A W. The anchors hierarchy: Using the triangle inequality to survive high dimensional data[C]. UAI, 2000: 397–405.
- [223] Samet H. The quadtree and related hierarchical data structures[J]. ACM Comput. Surv., 1984, 16(2): 187–260.
- [224] Zheng Y, Li Q, Chen Y, et al. Understanding mobility based on GPS data[C]. UbiComp, 2008: 312–321.
- [225] Moreira-Matias L, Gama J, Ferreira M, et al. Predicting taxi-passenger demand using streaming data[J]. IEEE Trans. Intell. Transp. Syst., 2013, 14(3): 1393–1402.