

目 录

第一章 前截断章节	1
1.1 当前版本编译时间	1
第二章 联合移动模式挖掘	2
2.1 引言	2
2.1.1 研究背景与意义	2
2.1.2 研究内容与挑战	5
2.1.3 研究成果与贡献	5
2.2 相关工作	5
2.3 问题定义	7
2.4 精确联合移动计算的精确搜索算法 (ES-ECMC)	7
2.5 基于近似协同行为计算的社区感知搜索 (CS-ACMC)	9
2.5.1 近似协同行为对搜索	10
2.5.2 社区感知聚类	12
2.6 实验评估	12
2.6.1 实验设置	13
2.6.2 性能评估	14
2.7 本章小结	17
致 谢	18
参考文献	19

图目录

图 2-1 伴随群体示例	3
图 2-2 轨迹标记及标记序列示例	11
图 2-3 轨迹数量的影响	15
图 2-4 协同行为持续时间阈值的影响	15
图 2-5 Effect of parameter m	16
图 2-6 结构相似度的影响	17

表目录

表 2-1	Parameter Settings	13
-------	--------------------------	----

主要符号表

第一章 前截断章节

1.1 当前版本编译时间

二零二六年二月十一日 16:53

第二章 联合移动模式挖掘

2.1 引言

本章通过分析个体和群体的移动轨迹，揭示城市运动模式，为城市规划和交通管理提供数据支持。开发高效的算法来发现大规模轨迹数据中的特定群体模式，即识别在特定时间内频繁共同出现在相同地点的移动对象集合。提高轨迹数据分析的准确性和效率，为城市规划、交通管理和社会行为研究提供更深入的洞察。为了实现该目标，需要采用数据挖掘技术，设计高效地数据索引结构，从大规模轨迹数据中挖掘出有用的城市移动规律和模式。需要形式化地定义特定群体模式检测问题，并考虑到在大规模轨迹数据中实现的挑战。在研究背景上，调研了现有工作在联合移动模式搜索以及轨迹聚类问题取得的研究进展。随后，通过分析现有工作的不足进而引出本章研究工作的研究内容和面临的研究挑战。在问题描述上，一一定义了移动对象及其轨迹、协同行为持续时间以及协同行为。本章提出了一个全新的简化的伴随群体发现问题。

大规模性、灵活性、效率与动态性共同构成了该问题的技术难点，也为算法框架与系统设计提出了更高要求。针对 CGD 问题，我们首先设计了精确算法以及一种新颖的社区感知聚类模型。基于两个真实世界数据集进行了大量实验评估，实验结果表明，所提出的社区感知算法能够在用户可交互时间内从大规模轨迹数据中发现伴随群体，体现了其在实际应用中的重要价值。

2.1.1 研究背景与意义

随着位置追踪设备（如车载导航系统和智能手机）以及 GPS 智能服务的持续普及，轨迹数据的规模正呈现爆炸式增长。作为轨迹数据分析中的一项基础功能，联合移动模式（co-movement pattern）挖掘问题已经受到数据科学领域的广泛关注。一般而言，联合移动模式表示一组在一段时间内共同移动的对象。该类模式的典型表示形式包括 flock [1, 2]、convoy [3]、swarm [4]、group [5]、platoon [6] 以及 gathering [7, 8] 等。

高效且准确地从移动对象轨迹中发现联合移动模式在诸多实际应用具有重要意义，包括拼车推荐、交通拥堵缓解（即通过及早发现道路上的高密度群体来规避潜在拥堵）、COVID-19 等传染病的暴露与风险分析 [9, 10]、移动行为分析及异常轨迹检测 [11] 等。

现有研究大多基于移动对象随时间演化的轨迹设计搜索算法。然而，这类算




图 2-1 伴随群体示例

法通常具有较高的计算代价，尤其是在联合移动模式（如 flock、swarm、group）不稳定的情况下（即对象可能在时间上暂时离开群体）。为了挖掘目标联合移动模式，现有方法往往需要在每一个时间快照上计算对象聚类，这在实时应用场景中具有极高的计算开销。此外，其基于“过滤-精炼”的处理框架往往会产生大量候选结果，从而进一步加重计算负担。随着轨迹数量的增加，这些方法的性能会显著下降。

在现实应用中，尤其是在疫情预警与防控场景下，及时获得最新的联合移动结果至关重要。因此，联合移动挖掘任务需要以连续的方式执行。这对算法在效率和效果两方面都提出了更高要求。然而，现有的群体模式定义及其相关方法在同时兼顾有效性与高效性方面仍然存在明显不足。

为了解决上述问题，本文提出了一种新的联合移动模式概念——伴随群体，其定义相对更加宽松。具体而言，一个伴随群体由至少 m 个移动对象组成，这些对象在至少 k 个时间段内共同移动（例如，其两两距离不超过预定义的距离阈值 ϵ ），且允许对象在时间上暂时离开其伴随群体。基于伴随群体，我们进一步定义了伴随群体发现问题。给定一组移动对象及其轨迹，CGD 问题旨在在用户可交互时间内发现所有伴随群体。在我们的设定中，若某一对象能够与其他对象形成多个伴随群体，则该对象归属于成员规模最大的伴随群体。CGD 问题可广泛应用于交通监测与管理、疫情防控以及暴力事件预防等实际场景。

下面通过图 2-1 给出一个示例说明。设 o_1, o_2, o_3, o_4 为四个移动对象，且所有对象每分钟上报一次位置信息。图 2-1 展示了它们在时间区间 $[t_1, t_7]$ 内的轨迹。设距离阈值 $\epsilon = 10$ 米，联合移动持续时间阈值 $k = 3$ 分钟，群体规模阈值 $m = 3$ 。可

以观察到, 对象 o_2 与 o_3 在时间集合 $T = \{t_1, t_2, t_4, t_5, t_6, t_7\}$ 内始终共同移动, 且 $|T| = 6$ 超过持续时间阈值 k , 因此二者可构成一个联合移动对。同样, o_3 与 o_4 也可以构成一个联合移动对。此外, 对象 o_2, o_3, o_4 在时间点 t_2, t_4, t_5, t_6 内的两两距离均不超过 ϵ , 因此我们将 $g = \{o_2, o_3, o_4\}$ 视为一个伴随群体。需要注意的是, 对象 o_1 仅在 t_1 和 t_6 与 o_2 短暂接近, 无法与其他对象形成联合移动对或伴随群体。

为了高效回答该问题, 系统在算法设计与实现层面面临以下关键技术挑战:

- **大规模数据处理:** 在真实应用场景中, 轨迹数据通常来源于海量移动对象, 例如车辆、移动终端或传感设备, 其数据规模可能达到千万级甚至更高。如何在如此庞大的数据规模下进行高效存储、索引与计算, 尤其是在需要实时或近实时发现群体模式的场景中, 成为首要挑战。这不仅要求算法具备良好的时间复杂度, 还需要设计高效的空间组织结构以降低内存开销。
- **模式定义的灵活性:** 不同应用场景对群体模式的定义存在差异。例如, 有的应用关注空间邻近性, 有的强调时间持续性, 还有的强调成员数量或运动一致性。因此, 如何构建一个既支持多种模式定义, 又能够灵活调整约束参数的统一算法框架, 是实现广泛适用性的关键。同时, 该框架在保证表达能力的前提下, 还需避免因过度泛化而导致计算复杂度急剧上升。
- **准确性与效率的平衡:** 群体模式发现通常涉及复杂的空间-时间约束匹配与频繁子结构检测, 若采用精确算法往往计算代价高昂。如何在保证模式发现准确性的同时, 通过剪枝策略、近似计算或分层索引机制降低计算开销, 是提升整体性能的核心问题。尤其在数据规模极大时, 算法需要在结果质量与运行效率之间取得合理权衡。
- **动态性的处理:** 轨迹数据具有天然的动态特征, 移动对象的位置和行为随时间不断变化。在流式数据环境下, 新数据持续到达, 旧数据逐渐失效, 群体结构也随之演化。因此, 如何设计支持增量更新的算法机制, 在无需重复计算全部数据的前提下及时更新群体模式检测结果, 是保证系统实时性与稳定性的关键技术挑战。

综上所述, 大规模性、灵活性、效率与动态性共同构成了该问题的技术难点, 也为算法框架与系统设计提出了更高要求。针对 CGD 问题, 我们首先设计了一种精确搜索算法, 即 Exact Search with Exact Co-Movement Computation (ES-ECMC), 该算法能够获得精确结果, 但计算代价较高。为进一步提升效率, 我们提出了一种社区感知的近似搜索算法, 即 Community-aware Search with Approximate Co-Movement Computation (CS-ACMC), 在兼顾结果质量与严格效率需求的前提下解决 CGD 问题。

CS-ACMC 算法主要包括两个阶段: 近似联合移动对搜索与社区感知群体发

现。在近似联合移动对搜索阶段，首先采用网格划分方法（如 [12–14]）将每个轨迹位置映射为对应的网格单元编号（即 `token`），从而将每条轨迹表示为一个 `token` 序列；随后，通过计算轨迹之间的公共 `token` 来生成近似联合移动对。在群体发现阶段，我们利用 SCAN 算法 [15] 对联合移动对进行高效聚类。本文算法的实现已开源发布^①。

本文的主要贡献总结如下：

- 提出了伴随群体这一新的联合移动模式定义，该定义更加宽松，适用于需要实时结果更新的多种应用场景，如传染病（SARS、埃博拉、COVID-19 等）传播监测与防控。
- 设计了一种精确算法以及一种新颖的社区感知聚类模型，用于解决 CGD 问题。
- 基于两个真实世界数据集进行了大量实验评估，实验结果表明，所提出的社区感知算法能够在用户可交互时间内从大规模轨迹数据中发现伴随群体，体现了其在实际应用中的重要价值。

本文其余部分组织如下：第 2.3 节介绍问题定义与相关预备知识；第 2.4 节给出精确算法；第 2.5 节介绍社区感知的高效近似算法；第 2.6 节展示实验结果与分析；第 2.2 节回顾相关研究工作；第 2.7 节给出总结。

2.1.2 研究内容与挑战

2.1.3 研究成果与贡献

2.2 相关工作

大规模轨迹数据的管理、挖掘与分析问题已受到数据科学领域的广泛关注。该方向的代表性研究主要包括轨迹搜索与推荐 [16–28]、位置搜索与推荐 [29–35]、路径规划与推荐 [36–43]，以及区域查询与交通模式挖掘等其他轨迹分析任务 [44–48]。在上述研究中，联合移动模式搜索与轨迹聚类问题与本文所研究的群体模式发现问题关系最为密切。

2.2.0.0.1 联合移动模式搜索 现有研究已经提出并讨论了多种有意义的联合移动模式 [3–6]，并在不同应用场景下得到了广泛应用。具体而言，`flock` [1, 2] 是最早提出的联合移动模式，用于刻画在 k 个连续时间间隔内共同移动的 m 个对象组成的群体。后续研究 [3] 指出，`flock` 所采用的圆形约束难以准确刻画真实移动对象群体的形态，并提出了支持任意形状聚类的 `convoy` 模式。然而，`flock` 与 `convoy` 均

^① https://github.com/Like-China/gathering_mining.git

对时间连续性提出了较为严格的约束。为支持对模式持续时间要求更加宽松的应用场景,研究者进一步提出了多种联合移动模式 [4–6]。

在这些研究中,Zheng 等人 [7] 提出了 gathering 模式,用于交通拥堵的早期发现,该模式允许成员在任意时间离开群体。Fan 等人 [49] 提出了更加通用的联合移动定义,并设计了并行框架用于模式发现。类似地,Naserian 等人 [50] 在轨迹数据流环境下提出了一种宽松的伴随群体发现方法。需要指出的是,Shein 等人 [51] 揭示了上述方法所需的高计算代价,并提出了一种增量式算法,但该方法在效率上仍然不足,难以支持实时发现需求。

值得注意的是,一些方法(如 [7, 8, 52])能够处理轨迹数据流,而另一些方法则仅适用于静态轨迹数据(如 [1, 3, 4])。与本文最为相关的研究之一是 Chen 等人 [53],其提出了一种实时联合移动模式挖掘方法,定义了一种更加通用的联合移动模式,并通过 L -连续性和 G -连通性来刻画轨迹之间的连续性与连通性。然而,由于问题定义的不同,该方法无法直接应用于本文的问题设置:本文不要求时间上的连续性与连通性,也不要求轨迹在每个时间点均属于同一聚类;此外,当一个对象能够形成多个群体时,本文始终选择成员规模最大的群体。

为处理轨迹数据流,Fang 等人 [52] 提出了一个实时联合移动模式挖掘系统,用于在特定时空约束下实时发现联合移动对象;Chen 等人 [53] 进一步研究了分布式环境下的实时联合移动模式检测,并通过基于双层索引的范围连接操作来加速聚类过程、减少不必要的验证。

尽管近年来已有大量研究尝试利用深度学习技术加速轨迹挖掘任务,包括轨迹聚类、异常轨迹检测 [11]、轨迹相似性计算 [54] 以及风险检测 [55] 等,但据我们所知,尚无基于深度学习的方法能够直接用于解决本文所研究的问题。

2.2.0.0.2 轨迹聚类 该方向的大多数研究 [54, 56, 57] 采用深度表示学习方法来加速轨迹相似性计算,其核心思想是将变长轨迹转换为固定长度的表示向量。Yao 等人 [58] 通过滑动窗口提取轨迹特征序列,并利用自编码器学习固定长度的深度表示;Boyle 等人 [59] 使用训练后自编码器最小隐藏层的输出作为轨迹表示;Fang 等人 [60] 提出了一种基于自训练的端到端聚类框架,无需人工特征提取。

除轨迹聚类外,通用的基于位置的群体搜索问题也得到了广泛研究 [61],例如基于位置的群体查询处理 [62, 63]、基于位置的连续查询处理 [64]、局部高频模式发现 [65, 66]、局部事件探索 [67–69]、位置感知传播模式挖掘 [70] 以及邻域模式挖掘 [71] 等。

然而,上述针对轨迹聚类提出的解决方案均无法直接应用于本文的问题,因为处于同一聚类中的移动对象并不一定在时空上真实地共同移动。

2.3 问题定义

本节介绍本文所需的基础概念，并给出问题的形式化定义。给定一组移动对象，我们依次定义轨迹、协同行为对、伴随群体以及伴随群体发现问题。

2.3.0.0.1 移动对象及其轨迹 一个移动对象 o 由其轨迹 $\tau = \{s_1, \dots, s_n\}$ 表示，其中轨迹是一个有限的、按时间顺序排列的离散时空点序列。该序列由位置追踪设备（如 GPS）从对象 o 的真实运动轨迹中采样获得。

为简化描述，我们使用 $s_i = ([x, y], t)$ 表示二维空间中的一个离散时空点，其中 $[x, y]$ 表示空间坐标， t 表示该位置被记录时对应的时间戳。对于一组移动对象 O ，我们用 $\mathcal{T} = \{\tau_1, \dots, \tau_{|O|}\}$ 表示其轨迹集合，其中 τ_i 为对象 o_i 的轨迹。需要说明的是，本文对移动对象及轨迹的建模方式与已有研究保持一致 [12, 72, 73]。

2.3.0.0.2 协同行为持续时间 设 o_i 与 o_j 为两个移动对象。当 o_i 与 o_j 之间的空间距离小于给定的空间距离阈值 ϵ_s ，且时间距离小于给定的时间阈值 ϵ_t 时，它们被认为处于协同行为状态。 o_i 与 o_j 的协同行为持续时间定义为满足上述条件的总行程时间长度。

2.3.0.0.3 协同行为对 设 τ_i 与 τ_j 分别为对象 o_i 与 o_j 的轨迹。若 τ_i 与 τ_j 之间的协同行为持续时间不少于阈值 k （其中 k 为协同行为持续时间阈值），则称对象 o_i 与 o_j 构成一个协同行为对。

定义 2.1（伴随群体） 给定一组移动对象 $O = \{o_1, o_2, \dots, o_{|O|}\}$ 以及最小群体规模阈值 m ，若对象子集 $g \subseteq O$ 满足以下两个条件，则称 g 为一个伴随群体：(1) $|g| \geq m$ ；(2) 对任意两个对象 $o_i, o_j \in g$ ， o_i 与 o_j 均能够构成协同行为对。

2.3.0.0.4 伴随群体发现 (CGD) 问题 给定一组移动对象 O ，伴随群体发现 (Companion Group Discovery, CGD) 问题旨在从 O 中发现一组伴随群体 $\mathcal{G}$ ，并满足对任意两个群体 $g_i, g_j \in \mathcal{G}$ ，均有 $g_i \cap g_j = \emptyset$ 。

2.4 精确联合移动计算的精确搜索算法 (ES-ECMC)

本节提出一种用于发现伴随群体的精确解法：精确搜索并进行精确联合移动计算的算法 (Exact Search with Exact Co-Movement Computation, 简称 ES-ECMC)。

ES-ECMC 算法主要包含三个步骤。首先，从输入数据（即一组对象轨迹）中枚举并发现所有联合移动对；其次，基于这些联合移动对，以增量方式生成伴随群

体候选；最后，从候选集中选取成员规模最大的伴随群体作为最终结果。在介绍 ES-ECMC 算法之前，我们首先给出伴随群体候选的定义。

2.4.0.0.1 伴随群体候选 一个伴随群体候选 g' 是一个对象集合，满足其中任意两个对象都可以形成一个联合移动对。若存在至少一个对象 $o \notin g'$ ，使得 $g'' = \{g', o\}$ 仍然是一个伴随群体候选，则称 g' 可以通过加入对象 o 进行扩展；否则，称 g' 不可扩展。

下面将详细介绍 ES-ECMC 算法。算法 2-1 给出了 ES-ECMC 的伪代码。算法输入包括一组轨迹 $\mathcal{T}$ 、空间距离阈值 ϵ_s 、时间距离阈值 ϵ_t 、群体规模阈值 m 以及联合移动持续时间阈值 k ；输出为一组伴随群体 $G = \{g_1, g_2, \dots, g_{|G|}\}$ （其中 $g_i \subseteq \mathcal{T}$ ）。我们使用 P 和 G_c 分别存储所有联合移动对和伴随群体候选。

算法 2-1: ES-ECMC Algorithm

```

输入: Trajectory set  $\mathcal{T} = \{\tau_1, \tau_2, \dots, \tau_{|\mathcal{O}|}\}$ ;
        空间距离阈值  $\epsilon_s$ ;
        时间距离阈值  $\epsilon_t$ ;
        群体规模阈值  $m$ ;
        联合移动持续时间阈值  $k$ .

输出: A set of approximate companion groups  $G$ .

1  $P \leftarrow \emptyset$ ;    // 有效轨迹对集合  $G_c \leftarrow \emptyset$ ;    // 候选群体集合  $G \leftarrow \emptyset$ ;    // 最终结果集合
2 for  $i = 1$  to  $|\mathcal{T}|$  do                                /* 生成有效轨迹对 */
3     for  $j = i + 1$  to  $|\mathcal{T}|$  do
4         if  $|\tau_i \cap \tau_j| \geq k$  then
5              $P \leftarrow P \cup \{(\tau_i, \tau_j)\}$ ;

6 foreach  $(\tau_i, \tau_j) \in P$  do                            /* 扩展候选群体 */
7      $g_i \leftarrow \{\tau_i, \tau_j\}$ ;
8     foreach  $(\tau_i, \tau_k) \in P$  do
9         if  $\forall \tau_p \in g_i, (\tau_k, \tau_p) \in P$  then          /* 两两有效且所有成员均在  $g_i$  中 */
10             $g_i \leftarrow g_i \cup \{\tau_k\}$ ;
11         if  $|g_i| \geq m$  then                                /* 群体规模约束 */
12             $G_c \leftarrow G_c \cup \{g_i\}$ ;

13  $G \leftarrow \text{select\_max}(G_c)$ ;                            // 选择最大或最优群体
14 return  $G$ ;
    
```

步骤 1:（枚举联合移动对）对于任意一对移动对象 $o_i, o_j \in \mathcal{O}$ ，我们计算其轨迹中任意两个采样位置 $s \in \tau_i$ 与 $s' \in \tau_j$ 之间的精确距离。若空间距离与时间距离分别不超过阈值 ϵ_s 与 ϵ_t ，则将其联合移动持续时间 $|\tau_i \cap \tau_j|$ 加 1。具体而言，

对于每一对对象 $\langle o_i, o_j \rangle$ ，当其累计的联合移动持续时间不少于 k 时，我们将其视为一个联合移动对^①。当所有对象对均被评估后，该步骤结束（第 2–8 行）。

步骤 2:（生成伴随群体候选）在获得所有联合移动对之后，我们基于这些联合移动对以增量方式生成伴随群体候选。具体而言，首先选择一个以轨迹 τ_i 为起点的联合移动对，例如 $\langle \tau_i, \tau_j \rangle$ ，然后考察所有与其共享对象 o_i 的联合移动对 $\langle \tau_i, \tau_k \rangle$ 。初始群体记为 $g_i = (\tau_i, \tau_j)$ 。若 τ_k 与 g_i 中的所有成员均构成联合移动对，则将 τ_k 加入 g_i 。当 g_i 仍可扩展时，重复上述扩展过程。若 g_i 的成员规模不少于 m ，则将其加入候选集合 G_c 。随后选择新的联合移动对作为初始群体并继续扩展。当所有联合移动对均被访问作为初始群体后，该步骤结束（第 9–19 行）。

步骤 3:（选择伴随群体）在获得所有候选之后，从中选取成员规模最大的伴随群体作为最终结果。具体而言，若某个对象属于多个候选群体，则选择其中成员规模最大的一个。该步骤在遍历完所有候选后结束（第 20 行）。

我们再次考虑图 2-1 中的示例。假设首先选择联合移动对 $\langle o_2, o_3 \rangle$ 进行扩展。显然，对 $\langle o_2, o_4 \rangle$ 与 $\langle o_2, o_3 \rangle$ 共享对象 o_2 ，且对象 o_2, o_3, o_4 两两之间均可形成联合移动对。因此，我们将 $g' = \{o_2, o_3, o_4\}$ 视为一个伴随群体候选。由于对象 o_1 无法与 g' 中的任一对象形成联合移动对， g' 不可进一步扩展。接着，由于 $|g'|$ 不小于预设的群体规模阈值 3，我们将 g' 加入候选集合 G_c 。最终，由于 g' 具有最大的成员规模，我们从 G_c 中选取 g' 并将其加入结果集合 G 。

定理 2.1 ES-ECMC 算法的时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|^2)$ ，其中 $|\mathcal{T}|$ 表示移动对象（轨迹）的数量， $|\tau|$ 表示单条轨迹的长度（即采样位置数）。

证明：ES-ECMC 在枚举所有联合移动对时，需要对每一对轨迹计算其位置之间的距离，其时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|^2)$ 。对于共享同一对象的联合移动对（例如 $\langle o_i, o_j \rangle$ 与 $\langle o_i, o_k \rangle$ ），需要进一步判断其是否能够构成伴随群体候选，并在满足条件时持续扩展该候选。生成所有伴随群体候选在最少情况下需要 $O(|\mathcal{T}|)$ 时间（例如不存在任何共享对象的联合移动对）；在最坏情况下，所有对象均可形成共享同一对象的联合移动对，此时生成候选的时间复杂度为 $O(|\mathcal{T}|^2)$ 。最后，从候选集合中生成最终的伴随群体需要 $O(|G_c|)$ 时间，其中 $|G_c| < |\mathcal{T}|$ 。综上所述，ES-ECMC 算法的总体时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|^2)$ 。 ■

2.5 基于近似协同行为计算的社区感知搜索（CS-ACMC）

尽管 ES-ECMC 算法直观且结果精确，但其高昂的计算开销使其难以应用于实际场景中，尤其是在移动对象数量极大的情况下。其主要计算瓶颈来源于通过

^① 在上下文清晰的情况下，我们使用 $\langle o_i, o_j \rangle$ 或 $\langle \tau_i, \tau_j \rangle$ 表示一个联合移动对。

精确计算协同行为持续时间来枚举所有协同行为对。为了解决效率问题，我们提出了一种基于社区感知的搜索算法，结合近似协同行为计算，即 Community-aware Search with Approximate Co-Movement Computation (CS-ACMC)。

CS-ACMC 算法由两个阶段组成：近似协同行为对搜索，以及基于社区感知的聚类以获取伴随群体。下面我们将依次介绍轨迹标记序列、近似协同行为对搜索方法以及社区感知聚类算法。

2.5.1 近似协同行为对搜索

在该阶段中，我们提出了一种高效的方法，用于计算两个对象轨迹之间协同行为持续时间的近似值。生成的近似协同行为对将作为后续社区感知聚类的输入，以高效地发现伴随群体。

步骤 1: (生成轨迹标记序列)

该方法受到群体 (flock) 圆形结构的启发 [3]。我们将底层空间划分为大小相等的网格单元。具体而言，将二维欧氏空间划分为空间等距的网格单元，同时将时间维度划分为等长的时间片。

因此，对象轨迹中的每一个数据点 (位置) $s = ([x, y], t)$ 都可以表示为一个标记 (token)，记为 $o(s) = f(x, y, t)$ ，其中 $f(\cdot)$ 为一个单射函数。由此可以得到轨迹的标记序列：

$$O(\tau) = \{o(s_1), \dots, o(s_{|\tau|})\}.$$

图 2-2 展示了空间与时间维度的划分方式以及轨迹标记序列的生成过程。假设空间被划分为 5×4 个网格单元，每个单元边长为 10 米，时间维度被划分为 3 个时间片，每个时间片长度为 10 秒。给定两条轨迹 τ_1 和 τ_2 ，其位置均落入单元 $\{([0, 0], 0), ([3, 1], 1), ([2, 1], 2)\}$ 。

基于该划分方式，我们定义单射函数

$$o(s) = f(x, y, t) = t \times (5 \times 4) + y \times 5 + x,$$

其中 $x \in \{0, 1, 2, 3, 4\}$ ， $y \in \{0, 1, 2, 3\}$ ， $t \in \{0, 1, 2\}$ 。例如，对于位置 $([3, 1], 1)$ ，其标记值为

$$1 \times (5 \times 4) + 1 \times 5 + 3 = 28.$$

如图 2-2 所示，尽管 τ_1 与 τ_2 在每个时间点的具体位置不同，但由于它们落入相同的空间与时间单元，因此可被表示为相同的标记序列 $\{0, 28, 47\}$ 。

定理 2.2 若将空间划分为边长为 ϵ 的等大小网格单元，其中 ϵ 等于协同行为距离阈值，则若两个对象 o_i 与 o_j 的轨迹标记序列共享 p 个相同标记，说明它们的协

同行为持续时间至少为 p 个时间段。

证明：位置 s 的标记值由单射函数 $o(s) = f(x, y, t)$ 计算得到。两个位置具有相同标记值意味着它们位于同一个空间网格单元中，因此二者之间的空间距离不超过 ϵ ，同时记录于同一时间片内。若两条轨迹标记序列共享一个标记，则表示对应对象在该时间段内保持不超过 ϵ 的空间距离共同移动。故共享 p 个标记意味着至少存在 p 个协同行为时间段。 ■




图 2-2 轨迹标记及标记序列示例

步骤 2: （搜索近似协同行为对）

基于轨迹标记序列，我们通过统计两个轨迹之间的公共标记数量来近似计算其协同行为持续时间。对于两个轨迹标记序列 $O(\tau_i)$ 和 $O(\tau_j)$ ，若其公共标记数 $|O(\tau_i) \cap O(\tau_j)|$ 不小于阈值 k ，则将其记录为一个近似协同行为对。该过程在所有轨迹标记序列均被评估后终止。

2.5.2 社区感知聚类

对于轨迹集合 $\mathcal{T} = \{\tau_1, \tau_2, \dots, \tau_{|\mathcal{O}|}\}$ ，通过第一阶段可获得轨迹标记序列集合

$$O(\mathcal{T}) = \{O(\tau_1), O(\tau_2), \dots, O(\tau_{|\mathcal{T}|})\},$$

以及一组近似协同行为对。在第二阶段中，我们的目标是发现所有满足以下条件的子集 $\mathcal{T}' \subseteq \mathcal{T}$ ：(1) $|\mathcal{T}'| \geq m$ ；(2) 对任意 $\tau_i, \tau_j \in \mathcal{T}'$ ，均有 $|O(\tau_i) \& O(\tau_j)| \geq k$ ，即伴随群体。为此，我们采用聚类技术以实现高效检测。

现有轨迹聚类方法主要包括基于划分的聚类 [74, 75]、基于密度的聚类 [76, 77] 以及基于深度学习的聚类 [54, 56, 57]。然而，这些方法难以刻画对象之间的内在连接关系，且基于密度的方法通常具有较高的计算复杂度。

我们的核心思想是将协同行为关系建模为网络或图结构，其中节点表示移动对象，边表示协同行为对。一个伴随群体由至少 m 个相互协同行为的对象组成。受同质性假设启发——即共享大量协同行为邻居的对象更可能属于同一群体——我们采用基于共享邻居的社区感知聚类方法。

SCAN 算法 [15] 是一种典型的社区感知聚类方法，其基于顶点结构与连通性进行聚类，时间复杂度为 $O(|P|)$ ，其中 $|P|$ 为协同行为对的数量（即图中的边数）。因此，SCAN 能够高效地用于伴随群体检测。

定理 2.3 CS-ACMC 算法的时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|)$ ，其中 $|\mathcal{T}|$ 表示轨迹数量， $|\tau|$ 表示单条轨迹的长度。

证明：CS-ACMC 算法需要对每一对轨迹计算其公共标记，时间复杂度为 $O(|\mathcal{T}|^2 \times |\tau|)$ 。在社区感知聚类阶段，SCAN 算法的时间复杂度为 $O(|P|)$ ，其中 $|P| \leq |\mathcal{T}|^2$ 。因此，总体时间复杂度为

$$O(|\mathcal{T}|^2 \times |\tau| + |P|) = O(|\mathcal{T}|^2 \times |\tau|).$$

■

2.6 实验评估

在本节中，首先介绍实验设定，包括实验所使用的数据集，运行环境等，然后给出实验结果与分析。实验结果主要关注所提出的搜索算法的运行时间，即高效性方面的表现。实验的目的在于，通过设置不同的参数（路线长度，位置点密度，空间-文本相似度阈值等），对比不同的算法的运行时间并进行分析。

表 2-1 Parameter Settings

	Beijing	Porto
Longitude	[116.250, 116.550]	[-8.735, -8.156]
Latitude	[39.830, 40.030]	[40.953, 41.307]
Length	[20, 100]	[20, 100]
ϵ_s	200 meters	200 meters
ϵ_t	200 seconds	200 seconds
$ \mathcal{T} $	2K–10K /default 6K	20K–100K /default 20K
k	2–6 (periods) /default 4	2–6 (periods) /default 4
m	2–6 (members) /default 4	2–6 (members) /default 4
μ	0.42–0.50 /default 0.50	0.42–0.50 /default 0.50

2.6.1 实验设置

2.6.1.0.1 数据准备 本文实验基于两个真实世界的出租车轨迹数据集。第一个数据集来自北京出租车轨迹数据 [78, 79]^①，该数据集包含 10,357 辆出租车在中国北京一周内的轨迹记录。该数据集共包含约 1,500 万个位置点，轨迹总行程约为 900 万公里。第二个数据集^② 采集自葡萄牙波尔图市，时间跨度为 19 个月，包含超过 170 万条轨迹。

在北京数据集中，轨迹的平均采样时间间隔为 177 秒，对应的平均采样距离约为 623 米；而在波尔图数据集中，每辆出租车以 15 秒为间隔上报其位置信息。时间戳的取值范围被统一映射到 24 小时内。对于波尔图数据集，每条轨迹的出发时间被随机设置在 24 小时范围内。所有轨迹均被预先转换为轨迹标记序列（trajectory token sequence）。

生成标记序列及伴随群体的默认参数设置如表 2-1 所示。同时，我们对轨迹的经纬度范围以及轨迹长度进行了限制，具体设置亦列于表 2-1 中。

2.6.1.0.2 对比算法 本文对以下两种算法进行性能比较：*Exact Search with Exact Co-Movement Computation*（ES-ECMC）算法，以及 *Community-aware Search with Approximate Co-Movement Computation*（CS-ACMC）算法。此外，采用 R-tree 索引结构 [80] 以在早期阶段剪枝不满足条件的对象，从而提升整体计算效率。

① <https://www.microsoft.com/en-us/research/publication/t-drive-trajectory-data-sample/>

② <https://www.kaggle.com/c/pkdd-15-predict-taxi-service-trajectory-i/data>

2.6.1.0.3 评估指标 为了评估 CS-ACMC 算法的有效性, 我们采用 ES-ECMC 算法中发现的协同行为对 (参见问题定义) 作为基准, 并使用 *协同行为对的平均命中率* 作为评估指标。

具体而言, 对于 ES-ECMC 算法发现的每一个精确伴随群体 g , 若其中任意一个协同行为对 $\langle o_i, o_j \rangle$ (其中 $o_i \in g, o_j \in g$) 存在于 CS-ACMC 算法发现的任意一个伴随群体中, 则认为该协同行为对被命中, 命中计数加一; 否则认为其未被命中。为简化描述, 本文使用“命中率 (hit ratio)”表示该指标。该指标能够有效反映近似算法所得伴随群体的结果质量。

在效率评估方面, 我们采用平均 CPU 运行时间作为主要性能指标。需要注意的是, 在默认参数设置下, ES-ECMC 算法在北京数据集上使用单线程至少需要 1 天的运行时间, 因此在实验中我们为 ES-ECMC 启用了 40 个线程, 而 CS-ACMC 仅使用单线程。所有算法均使用 Python 实现, 并在 Ubuntu 平台上运行, 实验环境配置为: 2 颗 Intel(R) Xeon(R) Silver 4214R CPU (2.40GHz) 以及 128GB 内存。除非特别说明, 所有实验结果均为 20 次不同测试轨迹输入下的平均值。

2.6.2 性能评估

2.6.2.0.1 轨迹数量的影响 首先, 我们在默认参数设置下, 研究轨迹数量变化对算法性能的影响。具体而言, 在波尔图数据集中, 轨迹数量从 20,000 增加至 100,000; 在北京数据集中, 轨迹数量从 2,000 增加至 10,000。之所以采用该设置, 是因为北京数据集的轨迹密度高于波尔图, 因此北京数据集中任意两条轨迹更容易形成协同行为对。

随着轨迹数量的增加, 可以观察到波尔图数据集上的命中率呈现上升趋势 (见图 2-3(c)), 而北京数据集上的命中率变化趋势并不明显 (见图 2-3(a))。值得注意的是, 波尔图数据集中捕获的协同行为对数量明显多于北京数据集, 从而带来更高的计算开销。从图 2-3(b) 和 2-3(d) 可以看出, 我们的模型在运行时间上至少比 ES-ECMC 快一个数量级。即便 ES-ECMC 采用了多线程计算, 当轨迹数量分别达到 10,000 (北京) 和 100,000 (波尔图) 时, 其运行时间仍超过 8,000 秒和 20,000 秒。这些结果表明, 我们的方法在保证较高有效性的同时, 也具备显著的效率优势。

2.6.2.0.2 协同行为持续时间阈值的影响 图 2-4 展示了当协同行为持续时间阈值 k 从 2 增加到 6 时算法的性能表现。直观上, 较大的 k 会减少协同行为对和伴随群体的数量, 从而可能降低计算成本。然而, 如图 2-4(a) 和 2-4(c) 所示, 运行时间并未随着 k 的增大而呈现明显下降趋势。其原因在于, 主要计算开销来自于协同行




图 2-3 轨迹数量的影响





图 2-4 协同行为持续时间阈值的影响


 图 2-5 Effect of parameter m

为对的枚举过程，而从协同行为对中发现伴随群体的成本相对较低。此外，当 k 增大时，北京数据集上的命中率有所提升，而波尔图数据集上的命中率则有所下降，这可能与两者不同的数据分布特性有关。在所有参数设置下，我们的方法在 CPU 运行时间方面均显著优于 ES-ECMC。

2.6.2.0.3 群体规模阈值的影响 图 2-5 展示了当群体规模阈值 m 从 2 变化到 6 时的算法性能。更大的群体规模阈值或协同行为持续时间阈值通常会导致伴随群体数量减少。随着 m 的增加，北京数据集上的命中率呈现上升趋势，而波尔图数据集上的命中率则有所下降，这同样可归因于数据分布差异。实验结果表明，在所有设置下，我们的方法在运行时间方面始终优于 ES-ECMC。

2.6.2.0.4 聚类参数的影响 图 2-6 展示了当结构相似度阈值 μ 从 0.42 增加到 0.50 时的命中率和运行时间变化情况。直观而言，较小的 μ 值意味着两个对象更容易被连接，从而更多对象可能被划分到同一群体中，最终生成的群体数量减少。如图 2-6(c) 所示，在波尔图数据集中，随着 μ 的增大，命中率呈现下降趋势，其中 $\mu = 0.42$ 时取得最佳效果。相比之下，北京数据集上的命中率始终高于 0.9，且随 μ 变化不明显，这可能是由于北京数据集具有更高的采样密度。即便 ES-ECMC 采用多线程实现，其运行时间仍显著高于 CS-ACMC，至少相差一个数量级。实验结




图 2-6 结构相似度的影响

果进一步验证了本文方法在效率和效果上的优越性。

2.7 本章小结

最后，我们提出了一种放宽的协同行为模式（co-movement pattern）定义，并研究了伴随群组发现（companion group discovery）问题，分别设计了精确算法和近似算法。在交通管理领域，本研究有助于理解特定的移动行为，并通过提前检测潜在的协同行为，从而帮助避免交通拥堵。最后，我们在两个真实世界数据集上进行了大量实验，验证了所提出方法的有效性和优越性。

致 谢

本论文的完成，凝聚了诸多师长、亲友和同窗的关心与帮助。值此论文付梓之际，谨向所有给予我支持与帮助的人致以最诚挚的感谢。

本研究及学位论文是在我的导师商烁教授的亲切关怀和悉心指导下完成的。商老师严谨求实的治学态度、敏锐深刻的学术洞察力以及精益求精的科研精神，始终激励着我不断进步。在论文选题、研究思路构建、关键技术突破以及论文整体结构把握等方面，商老师都给予了我耐心细致的指导。每一次讨论都让我受益匪浅，使我在学术视野与研究能力上不断提升。老师不仅在科研上给予我悉心培养，也在思想和生活上给予我关怀与支持，使我在攻读博士学位的过程中始终保持坚定与从容。在此谨向商烁教授致以最诚挚的谢意和崇高的敬意。

衷心感谢我的副导师陈力思教授。陈老师在科研方法、论文写作以及学术表达方面给予了我重要指导。在论文撰写与修改过程中，陈老师多次提出宝贵意见，从整体框架到细节表述均给予认真审阅与精心修改，使论文更加严谨和完善。每当科研工作遇到困难时，陈老师都耐心分析问题、指引方向，使我能够理清思路、稳步推进研究工作。在此谨向陈力思教授表示衷心的感谢与敬意。

感谢学院与实验室为我提供良好的科研环境与学术氛围。浓厚的学术交流氛围和开放包容的研究环境，使我能够专注于学术探索，不断拓展研究视野。感谢实验室的各位老师们在学术讨论中的启发与帮助，感谢师兄师姐、师弟师妹以及同窗好友在学习与生活中的支持与陪伴。与大家并肩奋斗的时光，是我博士生涯中最宝贵的记忆之一。

同时，感谢论文中所引用文献的作者们，他们严谨而卓越的研究成果为本论文奠定了重要的理论基础，使我得以在前人工作的基础上不断探索与创新。

最后，我要特别感谢我的父母和家人。无论在顺境还是逆境，你们始终给予我理解、包容与坚定的支持，是我坚持学术道路最坚实的后盾。你们无私的付出与默默的守护，使我能够心无旁骛地完成学业。未来我将以更加努力的工作与生活来回报你们的关爱与期望。

谨以此文，向所有关心、帮助和支持过我的师长、亲友和同学们致以最诚挚的感谢！

参考文献

- [1] Vieira M R, Bakalov P, Tsotras V J. On-line discovery of flock patterns in spatio-temporal data[C]. GIS, ACM, 2009: 286–295.
- [2] Tanaka P S, Vieira M R, Kaster D S. An improved base algorithm for online discovery of flock patterns in trajectories[J]. J. Inf. Data Manag., 2016, 7(1): 52–67.
- [3] Jeung H, Yiu M L, Zhou X, et al. Discovery of convoys in trajectory databases[J]. Proc. VLDB Endow., 2008, 1(1): 1068–1080.
- [4] Li Z, Ding B, Han J, et al. Swarm: Mining relaxed temporal moving object clusters[J]. Proc. VLDB Endow., 2010, 3(1): 723–734.
- [5] Wang Y, Lim E, Hwang S. Efficient mining of group patterns from user movement data[J]. Data Knowl. Eng., 2006, 57(3): 240–282.
- [6] Li Y, Bailey J, Kulik L. Efficient mining of platoon patterns in trajectory databases[J]. Data Knowl. Eng., 2015, 100: 167–187.
- [7] Zheng K, Zheng Y, Yuan N J, et al. On discovery of gathering patterns from trajectories[C]. ICDE, IEEE Computer Society, 2013: 242–253.
- [8] Zheng K, Zheng Y, Yuan N J, et al. Online discovery of gathering patterns over trajectories[J]. TKDE, 2014, 26(8): 1974–1988.
- [9] Xu J, Lu H, Bao Z. IMO: A toolbox for simulating and querying ”infected” moving objects[J]. Proc. VLDB Endow., 2020, 13(12): 2825–2828.
- [10] Alarabi L, Basalamah S M, Hendawi A M, et al. Traceall: A real-time processing for contact tracing using indoor trajectories[J]. Inf., 2021, 12(5): 202.
- [11] Liu Y, Zhao K, Cong G, et al. Online anomalous trajectory detection with deep generative sequence modeling[C]. ICDE, IEEE, 2020: 949–960.
- [12] Li K, Chen L, Shang S, et al. Towards controlling the transmission of diseases: Continuous exposure discovery over massive-scale moving objects[C]. IJCAI, 2022: 3891–3897.
- [13] Chen Z, Li K, Zhou S, et al. Towards robust trajectory similarity computation: Representation-based spatio-temporal similarity quantification[J]. World Wide Web, 2022: 1–24.
- [14] Zheng B, Xu J, Lee W C, et al. Grid-partition index: a hybrid method for nearest-neighbor queries in wireless location-based services[J]. The VLDB Journal, 2006, 15(1): 21–39.
- [15] Xu X, Yuruk N, Feng Z, et al. SCAN: a structural clustering algorithm for networks[C]. SIGKDD, ACM, 2007: 824–833.

- [16] Han P, Wang J, Yao D, et al. A graph-based approach for trajectory similarity computation in spatial networks[C]. KDD, ACM, 2021: 556–564.
- [17] Yang C, Chen L, Wang H, et al. Towards efficient selection of activity trajectories based on diversity and coverage[C]. AAAI, AAAI Press, 2021: 689–696.
- [18] Chen L, Shang S, Feng S, et al. Parallel subtrajectory alignment over massive-scale trajectory data[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3613–3619.
- [19] Shang S, Ding R, Zheng K, et al. Personalized trajectory matching in spatial networks[J]. VLDB J., 2014, 23(3): 449–468.
- [20] Shang S, Zheng K, Jensen C S, et al. Discovery of path nearby clusters in spatial networks[J]. TKDE, 2015, 27(6): 1505–1518.
- [21] Shang S, Chen L, Jensen C S, et al. Searching trajectories by regions of interest[J]. TKDE, 2017, 29(7): 1549–1562.
- [22] Shang S, Chen L, Wei Z, et al. Trajectory similarity join in spatial networks[J]. Proc. VLDB Endow., 2017, 10(11): 1178–1189.
- [23] Shang S, Chen L, Wei Z, et al. Parallel trajectory similarity joins in spatial networks[J]. VLDB J., 2018, 27(3): 395–420.
- [24] Chen L, Shang S, Jensen C S, et al. Parallel semantic trajectory similarity join[C]. ICDE, IEEE, 2020: 997–1008.
- [25] Zhao Y, Shang S, Wang Y, et al. REST: A reference-based framework for spatio-temporal trajectory compression[C]. Guo Y, Farooq F, (Eds.) SIGMOD, ACM, 2018: 2797–2806.
- [26] Liu J, Zhao K, Sommer P, et al. A novel framework for online amnesic trajectory compression in resource-constrained environments[J]. IEEE Trans. Knowl. Data Eng., 2016, 28(11): 2827–2841.
- [27] Liu J, Zhao K, Sommer P, et al. Bounded quadrant system: Error-bounded trajectory compression on the go[C]. Gehrke J, Lehner W, Shim K, et al., (Eds.) ICDE, IEEE Computer Society, 2015: 987–998.
- [28] Shang S, Yuan B, Deng K, et al. PNN query processing on compressed trajectories[J]. GeoInformatica, 2012, 16(3): 467–496.
- [29] Yao B, Chen Z, Gao X, et al. Flexible aggregate nearest neighbor queries in road networks[C]. ICDE, IEEE Computer Society, 2018: 761–772.
- [30] Han P, Li Z, Liu Y, et al. Contextualized point-of-interest recommendation[C]. Bessiere C, (Ed.) IJCAI, ijcai.org, 2020: 2484–2490.
- [31] Han P, Shang S, Sun A, et al. AUC-MF: point of interest recommendation with AUC maximization[C]. ICDE, IEEE, 2019: 1558–1561.

- [32] Shang S, Chen L, Zheng K, et al. Parallel trajectory-to-location join[J]. TKDE, 2019, 31(6): 1194–1207.
- [33] Feng S, Tran L V, Cong G, et al. HME: A hyperbolic metric embedding approach for next-poi recommendation[C]. SIGIR, ACM, 2020: 1429–1438.
- [34] Rao X, Chen L, Liu Y, et al. Graph-flashback network for next location recommendation[C]. KDD, ACM, 2022: 1463–1471.
- [35] Guo D, Zhu Y, Xu W, et al. How to find appropriate automobile exhibition halls: Towards a personalized recommendation service for auto show[J]. Neurocomputing, 2016, 213: 95–101.
- [36] Li K, Chen L, Shang S, et al. Traffic congestion alleviation over dynamic road networks: Continuous optimal route combination for trip query streams[C]. Zhou Z, (Ed.) IJCAI, ijcai.org, 2021: 3656–3662.
- [37] Li K, Chen L, Shang S. Towards alleviating traffic congestion: Optimal route planning for massive-scale trips[C]. IJCAI, ijcai.org, 2020: 3400–3406.
- [38] Chen L, Shang S, Jensen C S, et al. Effective and efficient reuse of past travel behavior for route recommendation[C]. KDD, ACM, 2019: 488–498.
- [39] Chen L, Shang S, Guo T. Real-time route search by locations[C]. AAAI, AAAI Press, 2020: 574–581.
- [40] Chen L, Shang S, Yao B, et al. Pay your trip for traffic congestion: Dynamic pricing in traffic-aware road networks[C]. AAAI, AAAI Press, 2020: 582–589.
- [41] Shang S, Ding R, Yuan B, et al. User oriented trajectory search for trip recommendation[C]. 15th International Conference on Extending Database Technology, EDBT '12, Berlin, Germany, March 27-30, 2012, Proceedings, ACM, 2012: 156–167.
- [42] Liu K, Li Y, Ding Z, et al. Benchmarking big data for trip recommendation[C]. ICCCN, IEEE, 2014: 1–6.
- [43] Shang S, Guo D, Liu J, et al. Prediction-based unobstructed route planning[J]. Neurocomputing, 2016, 213: 147–154.
- [44] Shang S, Chen L, Wei Z, et al. Collective travel planning in spatial networks[J]. TKDE, 2016, 28(5): 1132–1146.
- [45] Shang S, Lu H, Pedersen T B, et al. Finding traffic-aware fastest paths in spatial networks[C]. SSTD, Springer, vol. 8098 of Lecture Notes in Computer Science, 2013: 128–145.
- [46] Shang S, Lu H, Pedersen T B, et al. Modeling of traffic-aware travel time in spatial networks[C]. MDM (1), IEEE Computer Society, 2013: 247–250.
- [47] Rao X, Wang H, Zhang L, et al. FOGS: first-order gradient supervision with learning-based graph for traffic flow forecasting[C]. Raedt L D, (Ed.) IJCAI, ijcai.org, 2022: 3926–3932.

- [48] Liu A, Wang W, Shang S, et al. Efficient task assignment in spatial crowdsourcing with worker and task privacy protection[J]. *GeoInformatica*, 2018, 22(2): 335–362.
- [49] Fan Q, Zhang D, Wu H, et al. A general and parallel platform for mining co-movement patterns over large-scale trajectories[J]. *Proc. VLDB Endow.*, 2016, 10(4): 313–324.
- [50] Naserian E, Wang X, Xu X, et al. Discovery of loose travelling companion patterns from human trajectories[C]. *HPCC*, IEEE Computer Society, 2016: 1238–1245.
- [51] Shein T T, Puntheeranurak S, Imamura M. Discovery of loose group companion from trajectory data streams[J]. *IEEE Access*, 2020, 8: 85856–85868.
- [52] Fang Z, Gao Y, Pan L, et al. Coming: A real-time co-movement mining system for streaming trajectories[C]. Maier D, Pottinger R, Doan A, et al., (Eds.) *SIGMOD*, ACM, 2020: 2777–2780.
- [53] Chen L, Gao Y, Fang Z, et al. Real-time distributed co-movement pattern detection on streaming trajectories[J]. *Proc. VLDB Endow.*, 2019, 12(10): 1208–1220.
- [54] Li X, Zhao K, Cong G, et al. Deep representation learning for trajectory similarity computation[C]. *ICDE*, IEEE Computer Society, 2018: 617–628.
- [55] Zhao Y, Chen Q, Cao W, et al. Deep learning for risk detection and trajectory tracking at construction sites[J]. *IEEE Access*, 2019, 7: 30905–30912.
- [56] Zhang Y, Liu A, Liu G, et al. Deep representation learning of activity trajectory similarity computation[C]. *ICWS*, IEEE, 2019: 312–319.
- [57] Yao D, Cong G, Zhang C, et al. Computing trajectory similarity in linear time: A generic seed-guided neural metric learning approach[C]. *ICDE*, IEEE, 2019: 1358–1369.
- [58] Yao D, Zhang C, Zhu Z, et al. Trajectory clustering via deep representation learning[C]. *IJCNN*, IEEE, 2017: 3880–3887.
- [59] Boyle J, Nawaz T, Ferryman J M. Deep trajectory representation-based clustering for motion pattern extraction in videos[C]. *AVSS*, IEEE Computer Society, 2017: 1–6.
- [60] Fang Z, Du Y, Chen L, et al. E²dtc: An end to end deep trajectory clustering framework via self-training[C]. *ICDE*, IEEE, 2021: 696–707.
- [61] Chen L, Shang S, Yang C, et al. Spatial keyword search: a survey[J]. *GeoInformatica*, 2020, 24(1): 85–106.
- [62] Li M, Chen L, Cong G, et al. Efficient processing of location-aware group preference queries[C]. *CIKM*, ACM, 2016: 559–568.
- [63] Shang S, Guo D, Liu J, et al. Finding regions of interest using location based social media[J]. *Neurocomputing*, 2016, 173: 118–123.
- [64] Chen L, Shang S. Approximate spatio-temporal top-k publish/subscribe[J]. *World Wide Web*, 2019, 22(5): 2153–2175.

-
- [65] Xu Y, Chen L, Yao B, et al. Location-based top-k term querying over sliding window[C]. WISE (1), Springer, vol. 10569 of Lecture Notes in Computer Science, 2017: 299–314.
- [66] Chen L, Shang S, Jensen C S, et al. Top-k term publish/subscribe for geo-textual data streams[J]. VLDB J., 2020, 29(5): 1101–1128.
- [67] Zhao K, Chen L, Cong G. Topic exploration in spatio-temporal document collections[C]. SIGMOD, ACM, 2016: 985–998.
- [68] Chen L, Shang S. Region-based message exploration over spatio-temporal data streams[C]. AAAI, AAAI Press, 2019: 873–880.
- [69] Chen L, Shang S, Zheng K, et al. Cluster-based subscription matching for geo-textual data streams[C]. ICDE, IEEE, 2019: 890–901.
- [70] Li X, Cheng Y, Cong G, et al. Discovering pollution sources and propagation patterns in urban area[C]. KDD, ACM, 2017: 1863–1872.
- [71] Han J, Zheng K, Sun A, et al. Discovering neighborhood pattern queries by sample answers in knowledge base[C]. ICDE, IEEE Computer Society, 2016: 1014–1025.
- [72] Ranu S, P D, Telang A D, et al. Indexing and matching trajectories under inconsistent sampling rates[C]. ICDE, IEEE Computer Society, 2015: 999–1010.
- [73] Su H, Zheng K, Wang H, et al. Calibrating trajectory data for similarity-based analysis[C]. SIGMOD, ACM, 2013: 833–844.
- [74] Pelekis N, Kopanakis I, Kotsifakos E E, et al. Clustering trajectories of moving objects in an uncertain world[C]. ICDM, IEEE Computer Society, 2009: 417–427.
- [75] Lee J, Han J, Whang K. Trajectory clustering: a partition-and-group framework[C]. SIGKDD, ACM, 2007: 593–604.
- [76] Li Z, Lee J, Li X, et al. Incremental clustering for trajectories[C]. DASFAA, Springer, vol. 5982 of Lecture Notes in Computer Science, 2010: 32–46.
- [77] Li H, Liu J, Wu K, et al. Spatio-temporal vessel trajectory clustering based on data mapping and density[J]. IEEE Access, 2018, 6: 58939–58954.
- [78] Yuan J, Zheng Y, Xie X, et al. Driving with knowledge from the physical world[C]. Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, ACM, 2011: 316–324.
- [79] Yuan J, Zheng Y, Zhang C, et al. T-drive: driving directions based on taxi trajectories[C]. ACM-GIS, ACM, 2010: 99–108.
- [80] Guttman A. R-trees: A dynamic index structure for spatial searching[C]. SIGMOD, 1984: 47–57.